

MWS GPT (ex. LLMOps Platform)

MWS GPT (ex. LLMOps Platform)

Exported on 04/02/2026

Table of Contents

1	Как начать работу?.....	10
2	FAQ	11
3	Полезный контент:	12
3.1	Полезные ссылки:	12
3.1.1	Внутренние:.....	12
3.1.2	Внешние:	12
3.1.3	API Документация:	12
3.1.4	Внутренняя:.....	12
3.1.5	Внешняя:.....	13
3.2	Пользовательская документация:	13
3.3	Записи вебинаров:	13
4	Все у вас получится	15
5	Коммерция	16
5.1	Коммерческие материалы	16
5.1.1	GTM	16
5.1.2	Системные требования.....	16
5.1.3	Sales Deck	16
5.1.4	Список конкурентов	17
5.1.5	Внешние исследования рынка.....	17
5.1.6	Заказ (MWS)	17
5.1.7	Sales Kit (MWS)	17
5.1.8	Спец. условия облачного сервиса (MWS)	17
5.1.9	Расчет маржинальности (MWS).....	18
5.1.10	Тарифы (MWS).....	18
5.1.11	Чек-лист по передаче продукта на ТП (MWS)	18
5.1.12	Onepager (MWS).....	19
5.2	Внешняя документация.....	19

6	Разработка	20
6.1	Product Backlog Refinement	20
6.2	QA	22
6.2.1	Core.....	22
6.2.2	No-Code.....	22
6.2.2.1	Агенты	22
6.2.2.2	Компоненты No-code	22
6.2.2.3	Модели.....	25
6.2.2.4	Рабочие сценарии.....	25
6.3	VLM.....	38
6.3.1	Бенчмаркинг.....	38
6.3.1.1	LLaVaRU	41
6.3.1.2	LLaVaTranslated.....	42
6.3.1.3	Text-only benchmark:	43
6.3.2	Исследования	43
6.3.3	Таблица экспериментов.....	44
6.4	Анализ задержки запуска Flow в Langflow	65
6.4.1	Общая схема выполнения.....	65
6.4.2	Выявленные проблемы.....	66
6.4.2.1	1. Граф пересоздается с нуля при каждом запуске.....	66
6.4.2.2	2. Деер сору всех данных flow.....	67
6.4.2.3	3. Последовательное инстанцирование компонентов.....	67
6.4.2.4	4. Двухфазный HTTP-запрос на фронтенде.....	68
6.4.2.5	5. Загрузка flow из БД (большой JSON-блób)	69
6.4.2.6	6. Инициализация сервиса трассировки	70
6.5	Как работают связи компонентов в воркфлоу Langflow и почему они ломаются при обновлении версии	70
6.5.1	1. Как устроены связи компонентов	70
6.5.1.1	1.1 Модель данных	70

6.5.1.2	1.2 Что хранится в ноде	71
6.5.1.3	1.3 Хранение в базе данных.....	71
6.5.1.4	1.4 Создание связи на фронтенде	72
6.5.1.5	1.5 Последовательность загрузки flow	72
6.5.1.6	1.6 Валидация на фронтенде - cleanEdges().....	73
6.5.1.7	1.7 Валидация на бэкенде	73
6.5.1.8	1.8 Система шаблонов и определение устаревших компонентов	74
6.5.2	2. Где ломается при обновлении	74
6.5.2.1	2.1 Сценарий обновления.....	74
6.5.2.2	2.2 Точка отказа 1 - строковое сравнение в cleanEdges()	75
6.5.2.3	2.3 Точка отказа 2 - output не найден по имени.....	75
6.5.2.4	2.4 Точка отказа 3 - несовпадение output_types в сериализованном handle	75
6.5.2.5	2.5 Точка отказа 4 - скрытые поля удаляют edge-и	76
6.5.2.6	2.6 Точка отказа 5 - валидация на бэкенде при запуске	76
6.5.2.7	2.7 Почему это тихо	76
6.5.2.8	2.8 Почему это необратимо.....	76
6.5.3	3. Найденные баги	77
6.5.3.1	Баг 1: cleanEdges() сравнивает строки вместо проверки совместимости типов	77
6.5.3.2	Баг 2: шаблоны не обновляются до очистки edge-ей	77
6.5.3.3	Баг 3: auto-save делает потерю edge-ей необратимой	77
6.5.3.4	Баг 4: detectBrokenEdgesEdges() и cleanEdges() по-разному ищут source output.....	78
6.5.3.5	Баг 5: selected_output ссылается на удаленный output	78
6.6	Компоненты LLMOps.....	79
6.7	Описание требований и архитектуры.....	79
6.7.1	Копия Stack [AS IS].....	79
6.7.1.1	Текущий стек реализуется компонентами:.....	79
6.7.2	Сценарии использования	82

6.7.2.1	Сценарии использования LibreChat [UI].....	82
6.7.2.2	Сценарии использования LiteLLM [UI]	107
6.7.2.3	Сценарии использования NoCode aka LangFlow [UI]	107
6.8	Передача репозитория в деплой (Infra / DevOps)	107
6.8.1	Цель документа.....	107
6.8.2	Минимальные требования к сервису.....	107
6.8.2.1	1. Healthcheck endpoint.....	107
6.8.2.2	2. Метрики (если применимо).....	108
6.8.2.3	3. Алерты (при интеграции с инфровым алертингом).....	108
6.8.3	Требования к репозиторию.....	108
6.8.3.1	4. Репозиторий с кодом	108
6.8.3.2	5. Ссылка на репозиторий в задаче	108
6.8.4	Обязательная структура репозитория.....	109
6.8.4.1	6. Dockerfile	109
6.8.4.2	7. Файл зависимостей	109
6.8.4.3	8. README.md (обязательно)	109
6.8.4.4	9. Production docker-compose (если требуется)	110
6.8.5	Процесс передачи в Infra / DevOps	110
6.9	Ролевая модель в Langflow (NoCode).....	111
6.9.1	Цели создания ролевой модели.....	111
6.9.2	Открытые вопросы.....	111
6.9.3	Основные сущности.....	111
6.9.4	Роли.....	112
6.9.4.1	Админ организации.....	112
6.9.4.2	Админ проекта.....	112
6.9.4.3	Тестировщик (Tester / Reviewer)	113
6.9.4.4	Пользователь проекта.....	113
6.9.4.5	Наблюдатель проекта.....	113
6.9.5	Схематичное изображение ролевой модели.....	115

6.9.6	RBAC в Langflow с использованием Casbin.....	115
6.9.6.1	1. Что сейчас есть	115
6.9.6.2	2. Выбранный подход	116
6.9.6.3	3. Два варианта реализации	117
6.9.6.4	4. Вариант А (MVP) - что конкретно делаем.....	118
6.9.6.5	5. Вариант Б (полный) - что добавляется сверх Варианта А.....	123
6.9.6.6	6. Матрица ролей и действий.....	124
6.9.6.7	7. Переменные окружения.....	126
6.9.6.8	8. Какие файлы Langflow меняются	127
6.9.6.9	9. Как проходит запрос (Вариант А)	127
6.9.6.10	10. Риски и митигация	128
6.9.6.11	11. Плюсы и минусы выбранного подхода.....	129
6.9.6.12	12. Миграция с Варианта А на Вариант Б.....	130
6.9.7	Анализ кодовой базы по ролевке LF и оценка предлагаемых решений.....	130
6.9.7.1	1. Текущее состояние архитектуры Langflow	130
6.9.7.2	2. Требования к решению для форка	132
6.9.7.3	3. Четыре подхода к интеграции RBAC	132
6.9.7.4	Выводы	136
6.9.7.5	5. Почему Casbin подходит для RBAC в Langflow.....	136
6.9.7.6	6. Интеграция требований ролевой модели с Casbin.....	137
6.9.7.7	7. Заключение	138
6.9.8	Проектирование UI-ролевки для NoCode	139
6.9.8.1	Ссылка на макет.....	139
6.9.8.2	Введение	139
6.9.8.3	Основные принципы проектирования	140
6.9.8.4	Описание пользовательских ролей.....	142
6.9.8.5	Сценарии использования	145
6.9.8.6	Раздел UI-архитектура: страницы и компоненты	148

6.10	Чат MWS GPT	155
6.10.1	Интеграция получения статуса премиум-подписки через MTS ID	155
6.10.1.1	Ссылки	155
6.10.1.2	Описание задачи.....	156
6.10.1.3	Реализация	156
7	Техническая поддержка MWS GPT	167
7.1	FAQ	167
7.1.1	Как начать работу?.....	167
7.1.2	Какие модели у вас есть?	167
7.1.3	Какая модель лучше для ... ?.....	167
7.1.4	Отправляю запрос с локального компьютера из внутренней сети, а он не проходит	168
7.1.5	Отправляю запрос а он ругается на сертификаты	168
7.1.6	Как сделать RAG ?	168
7.1.7	Как сделать агента ?	169
7.1.8	Почему запрос обрабатывается так долго?	169
7.1.9	Модель лежит, я получаю ошибку APITimeoutError: Request timed out, что делать?.....	169
7.1.10	Как посмотреть доступность платформы?.....	170
7.1.11	Кто может проконсультировать по внедрению LLM в мой продукт?..	171
7.1.12	Где посмотреть полезный контент по внедрению LLM?	171
7.1.13	Как понять, какая LLM локальная, а какая внешняя?	171
7.1.14	Как понять, какие LLM можно использовать с чувствительной информацией?	171
7.1.15	У меня техническая проблема/нужна консультация.....	172
7.1.16	У меня ключ старого формата (ASGK), что делать?	172
7.1.17	У меня еще остались вопросы, где задать?.....	172
7.2	Как начать работу?.....	173
7.2.1	Получение ключа	173
7.2.1.1	Заполнение формы в MWS Tables	174

7.2.1.2	Как заполнять поля в форме?	174
7.2.2	Настройка доступов на Firewall	175
7.2.2.1	Заявка на Firewall	176
7.2.3	Отправляем запросы в MWS GPT	177
7.2.3.1	Спецификация OpenAI API	177
7.2.3.2	Postman коллекция	177
7.2.3.3	Библиотеки для интеграции	177
7.2.3.4	Интеграция с 3rd-party сервисами и библиотеками	178
7.2.4	Я все сделал, но у меня еще остались вопросы	178
7.3	Модели и Бенчмарки	179
7.4	Чек-лист технологической зрелости MWS GPT	183

MWS GPT — это облачная B2B-платформа от МТС Web Services (MWS), предназначенная для работы бизнеса с большими языковыми моделями (LLM). Она позволяет использовать, дообучать и внедрять как собственные, так и сторонние (open source) модели, предлагая инструменты вроде чат-интерфейса и no-code конструктора для создания приложений.

Основные функции и возможности:

- **Доступ к LLM:** Платформа объединяет и предоставляет доступ к различным большим языковым моделям, включая собственные разработки МТС и модели с открытым исходным кодом.
- **Работа с моделями:** Пользователи могут дообучать модели на своих данных и внедрять их в бизнес-процессы через инфраструктуру MWS.
- **Удобный интерфейс:** Включает чат, который позволяет сохранять и обмениваться запросами (промптами), а также no-code конструктор для создания приложений без привлечения программистов.
- **Агентская архитектура:** В основе платформы лежит агентская архитектура, которая позволяет моделям самостоятельно выбирать необходимые навыки для решения конкретной задачи.
- **Гибкая оплата:** Стоимость зависит от количества использованных токенов, что делает платформу доступной для компаний разного размера, включая малый и средний бизнес.
- **Инфраструктура:** Работает на облачной инфраструктуре МТС, что обеспечивает отказоустойчивость и масштабируемость, и планируется возможность развертывания на серверах заказчика.

Наш сайт: <https://mws.ru/services/mws-gpt/>

1 Как начать работу?

[Как начать работу?](#) (see page 173)

2 FAQ

[FAQ \(see page 167\)](#)

3 Полезный контент:

3.1 Полезные ссылки:

3.1.1 Внутренние:

Внутренний UI Chat - <https://ui.llmops.mts-corp.ru/login>

Внутренний No-Code конструктор - <https://langflow.llmops.mts-corp.ru/login>

Внутренний API - <https://api.llmops.mts-corp.ru/>

Внутренний мониторинг - <https://grafana-gbp.genai.mts-corp.ru/login> (login: reader; password: reader)

Внутренний продукт - https://product.mts.ru/product/BI_3060/main

3.1.2 Внешние:

Внешний Demo UI Chat - <https://ui.gpt.mws.ru/login>

Внешний Demo No-Code конструктор - <https://nocode.gpt.mws.ru/login>

Внешний B2C Chat - <https://gpt.mws.ru/>

Внешний API - <https://api.gpt.mws.ru/>

Внешний продукт - https://product.mts.ru/product/BI_3508/main

3.1.3 API Документация:

3.1.4 Внутренняя:

[API Документация-v4-20250210_115130.pdf](#)¹

¹ https://confluence.mts.ru/download/attachments/1227141129/API%20%D0%94%D0%BE%D0%BA%D1%83%D0%BC%D0%B5%D0%BD%D1%82%D0%B0%D1%86%D0%B8%D1%8F-v4-20250210_115130.pdf?api=v2&modificationDate=1763109694231&version=1

3.1.5 Внешняя:

[API Документация mws-v1-20250210_150202.pdf²](#)

3.2 Пользовательская документация:

[3_1_Инструкция_по_установке_и_информацией,_необходимой_для_эксплуатации.pdf³](#)

3.3 Записи вебинаров:

[Вебинар_модели ИИ_зоопарк_Аня Щеникова⁴](#)

[Курс по искусственному интеллекту⁵](#)

[Мастер-класс по работе с искусственным интеллектом⁶](#)

[Митап True Tech AI - июль 2024⁷](#)

[Митап по GenAI от Центра RnD TechGov⁸](#)

[Prompt Engineering — как найти общий язык с LLM | Наталья Бруй и Алёна Шувар | True Tech Day 2.0⁹](#)

[ML в эпоху LLM. Доклад Даниила Киреева | True Tech Champ 2024¹⁰](#)

[Как мы адаптировали токенайзеры вместе с ВШЭ — и нашли баланс между скоростью генерации и качеством русской речи | TTD 2025¹¹](#)

[10 правил, как проектировать LLM-приложение. Доклад Всеволода Викулина | True Tech Day 2025¹²](#)

[Ландшафт LLM. модели, бенчмарки, применение. Доклад Даниила Киреева | True Tech Day 2025¹³](#)

[Реальные прикладные кейсы использования LLM. Доклад Павла Бабина | True Tech Day 2025¹⁴](#)

² [https://confluence.mts.ru/download/attachments/1227141129/](https://confluence.mts.ru/download/attachments/1227141129/API%20%D0%94%D0%BE%D0%BA%D1%83%D0%BC%D0%B5%D0%BD%D1%82%D0%B0%D1%86%D0%B8%D1%8F%20mws-v1-20250210_150202.pdf?api=v2&modificationDate=1763109660080&version=1)

[API%20%D0%94%D0%BE%D0%BA%D1%83%D0%BC%D0%B5%D0%BD%D1%82%D0%B0%D1%86%D0%B8%D1%8F%20mws-v1-20250210_150202.pdf?api=v2&modificationDate=1763109660080&version=1](https://confluence.mts.ru/download/attachments/1227141129/API%20%D0%94%D0%BE%D0%BA%D1%83%D0%BC%D0%B5%D0%BD%D1%82%D0%B0%D1%86%D0%B8%D1%8F%20mws-v1-20250210_150202.pdf?api=v2&modificationDate=1763109660080&version=1)

³ [https://confluence.mts.ru/download/attachments/](https://confluence.mts.ru/download/attachments/1227141129/3_1_%D0%98%D0%BD%D1%81%D1%82%D1%80%D1%83%D0%BA%D1%86%D0%B8%D1%8F_%D0%BF%D0%BE_%D1%83%D1%81%D1%82%D0%B0%D0%BD%D0%BE%D0%B2%D0%BA%D0%B5_%D0%B8_%D0%B8%D0%BD%D1%84%D0%BE%D1%80%D0%BC%D0%B0%D1%86%D0%B8%D0%B5%D0%B8%CC%86%2C_%D0%BD%D0%B5%D0%BE%D0%B1%D1%85%D0%BE%D0%B4%D0%B8%D0%BC%D0%BE%D0%B8%CC%86_%D0%B4%D0%BB%D1%8F_%D1%8D%D0%BA%D1%81%D0%BF%D0%BB%D1%83%D0%B0%D1%82%D0%B0%D1%86%D0%B8%D0%B8.pdf?api=v2&modificationDate=1763118539344&version=1)

[1227141129/3_1_%D0%98%D0%BD%D1%81%D1%82%D1%80%D1%83%D0%BA%D1%86%D0%B8%D1%8F_%D0%BF%D0%BE_%D1%83%D1%81%D1%82%D0%B0%D0%BD%D0%BE%D0%B2%D0%BA%D0%B5_%D0%B8_%D0%B8%D0%BD%D1%84%D0%BE%D1%80%D0%BC%D0%B0%D1%86%D0%B8%D0%B5%D0%B8%CC%86%2C_%D0%BD%D0%B5%D0%BE%D0%B1%D1%85%D0%BE%D0%B4%D0%B8%D0%BC%D0%BE%D0%B8%CC%86_%D0%B4%D0%BB%D1%8F_%D1%8D%D0%BA%D1%81%D0%BF%D0%BB%D1%83%D0%B0%D1%82%D0%B0%D1%86%D0%B8%D0%B8.pdf?api=v2&modificationDate=1763118539344&version=1](https://confluence.mts.ru/download/attachments/1227141129/3_1_%D0%98%D0%BD%D1%81%D1%82%D1%80%D1%83%D0%BA%D1%86%D0%B8%D1%8F_%D0%BF%D0%BE_%D1%83%D1%81%D1%82%D0%B0%D0%BD%D0%BE%D0%B2%D0%BA%D0%B5_%D0%B8_%D0%B8%D0%BD%D1%84%D0%BE%D1%80%D0%BC%D0%B0%D1%86%D0%B8%D0%B5%D0%B8%CC%86%2C_%D0%BD%D0%B5%D0%BE%D0%B1%D1%85%D0%BE%D0%B4%D0%B8%D0%BC%D0%BE%D0%B8%CC%86_%D0%B4%D0%BB%D1%8F_%D1%8D%D0%BA%D1%81%D0%BF%D0%BB%D1%83%D0%B0%D1%82%D0%B0%D1%86%D0%B8%D0%B8.pdf?api=v2&modificationDate=1763118539344&version=1)

⁴ <https://confluence.mts.ru/pages/viewpage.action?pagelId=1102153391>

⁵ <https://confluence.mts.ru/pages/viewpage.action?pagelId=1252747135>

⁶ <https://confluence.mts.ru/pages/viewpage.action?pagelId=1244788534>

⁷ <https://confluence.mts.ru/pages/viewpage.action?pagelId=1230080153>

⁸ <https://confluence.mts.ru/pages/viewpage.action?pagelId=1071925503>

⁹ <https://www.youtube.com/watch?v=-epG5fF074o>

¹⁰ <https://www.youtube.com/watch?v=Kcp8Yk9K6ul>

¹¹ https://vkvideo.ru/video-226874221_456239458?t=7s&ref_domain=truetechday.ru

¹² https://vkvideo.ru/video-226874221_456239453?t=1s&ref_domain=truetechday.ru

¹³ https://vkvideo.ru/video-226874221_456239459?t=1s&ref_domain=truetechday.ru

¹⁴ https://vkvideo.ru/video-226874221_456239462?t=0s&ref_domain=truetechday.ru

[Как взять LLM за RAGa. Доклад Александра Абрамова | True Tech Day 2025¹⁵](#)

[KODIFY 2.0 – сервис генерации и дополнения кода. Доклад Валентина Малых | True Tech Day 2025¹⁶](#)

[Cost of Ownership: LLM in-house vs SaaS¹⁷](#)

[AI – эволюция облака, а не опция¹⁸](#)

[Онлайн-дискуссия «Как создать AI-агента без кода»¹⁹](#)

[Расскажите про MWS. AI-автоматизация: как построить команду с нуля и перестать перекладывать задачи руками?²⁰](#)

[MWS GPT: заблуждения и мифы про внедрение LLM в бизнес²¹](#)

[Онлайн-дискуссия «Почему не стоит инвестировать 2 года в платформу инференса LLM?»²²](#)

15 https://vkvideo.ru/video-226874221_456239457?t=1s&ref_domain=truetechday.ru

16 https://vkvideo.ru/video-226874221_456239455?t=0s&ref_domain=truetechday.ru

17 https://vkvideo.ru/video-38818370_456239332

18 https://vkvideo.ru/video-38818370_456239327

19 https://vkvideo.ru/video-38818370_456239300

20 https://vkvideo.ru/video-38818370_456239290

21 https://vkvideo.ru/video-38818370_456239264

22 https://vkvideo.ru/video-38818370_456239241

4

Все у вас получится

5 Коммерция

5.1 Коммерческие материалы

5.1.1 GTM

Версия	Документ
v1.0	


5.1.2 Системные требования

5.1.3 Sales Deck

Версия	Документ

5.1.4 Список конкурентов

5.1.5 Внешние исследования рынка



5.1.6 Заказ (MWS)

Версия	Документ

5.1.7 Sales Kit (MWS)

Версия	Документ

5.1.8 Спец. условия облачного сервиса (MWS)

Версия	Документ

5.1.9 Расчет маржинальности (MWS)

Версия	Документ

5.1.10 Тарифы (MWS)

Версия	Документ																																																																				
0.1	<table><tr><th></th><th colspan="2">Cloud</th><th colspan="2">On Premise</th></tr><tr><td rowspan="2">Base</td><td>Потребление</td><td>1.1J / 1000 токенов</td><td>Лицензия</td><td>8 150000J</td></tr><tr><td></td><td></td><td>Развертывание</td><td>1 574 400J</td></tr><tr><td rowspan="4">Standard</td><td>Потребление</td><td>1.1J / 1000 токенов</td><td>Потребление</td><td>0.55J / 1000 токенов</td></tr><tr><td>Consulting</td><td>AI Developer 14720J/час</td><td>Лицензия</td><td>8 150000J</td></tr><tr><td></td><td></td><td>Consulting</td><td>AI Ops 14100J/час AI Developer 14720J/час</td></tr><tr><td></td><td></td><td>Потребление</td><td>0.55J / 1000 токенов</td></tr><tr><td rowspan="17">Complete</td><td></td><td></td><td>Развертывание</td><td>1 574 400J</td></tr><tr><td></td><td></td><td>GPU</td><td>N/A (параллельно)</td></tr><tr><td>Потребление</td><td>1.1J / 1000 токенов</td><td>Лицензия</td><td>8 150000J</td></tr><tr><td>Professional</td><td>AI Developer 14720J/час ML Engineer 14720J/час Data Engineer 14200J/час Full Stack Developer 13550J/час Analyst 12850J/час AI 13700J/час</td><td>Professional</td><td>AI Developer 14720J/час ML Engineer 14720J/час Data Engineer 14200J/час Full Stack Developer 13550J/час Analyst 12850J/час AI 13700J/час AI Ops 14100J/час Dev SecOps 1450J/час</td></tr><tr><td></td><td></td><td>Потребление</td><td>0.55J / 1000 токенов</td></tr><tr><td></td><td></td><td>Развертывание</td><td>1 574 400J</td></tr><tr><td></td><td></td><td>Поддержка платформы</td><td>N/A (требуется токены)</td></tr><tr><td></td><td></td><td>Поддержка оборудования</td><td>N/A (требуется токены)</td></tr><tr><td></td><td></td><td>GPU</td><td>N/A (параллельно)</td></tr></table>		Cloud		On Premise		Base	Потребление	1.1J / 1000 токенов	Лицензия	8 150000J			Развертывание	1 574 400J	Standard	Потребление	1.1J / 1000 токенов	Потребление	0.55J / 1000 токенов	Consulting	AI Developer 14720J/час	Лицензия	8 150000J			Consulting	AI Ops 14100J/час AI Developer 14720J/час			Потребление	0.55J / 1000 токенов	Complete			Развертывание	1 574 400J			GPU	N/A (параллельно)	Потребление	1.1J / 1000 токенов	Лицензия	8 150000J	Professional	AI Developer 14720J/час ML Engineer 14720J/час Data Engineer 14200J/час Full Stack Developer 13550J/час Analyst 12850J/час AI 13700J/час	Professional	AI Developer 14720J/час ML Engineer 14720J/час Data Engineer 14200J/час Full Stack Developer 13550J/час Analyst 12850J/час AI 13700J/час AI Ops 14100J/час Dev SecOps 1450J/час			Потребление	0.55J / 1000 токенов			Развертывание	1 574 400J			Поддержка платформы	N/A (требуется токены)			Поддержка оборудования	N/A (требуется токены)			GPU	N/A (параллельно)
	Cloud		On Premise																																																																		
Base	Потребление	1.1J / 1000 токенов	Лицензия	8 150000J																																																																	
			Развертывание	1 574 400J																																																																	
Standard	Потребление	1.1J / 1000 токенов	Потребление	0.55J / 1000 токенов																																																																	
	Consulting	AI Developer 14720J/час	Лицензия	8 150000J																																																																	
			Consulting	AI Ops 14100J/час AI Developer 14720J/час																																																																	
			Потребление	0.55J / 1000 токенов																																																																	
Complete			Развертывание	1 574 400J																																																																	
			GPU	N/A (параллельно)																																																																	
	Потребление	1.1J / 1000 токенов	Лицензия	8 150000J																																																																	
	Professional	AI Developer 14720J/час ML Engineer 14720J/час Data Engineer 14200J/час Full Stack Developer 13550J/час Analyst 12850J/час AI 13700J/час	Professional	AI Developer 14720J/час ML Engineer 14720J/час Data Engineer 14200J/час Full Stack Developer 13550J/час Analyst 12850J/час AI 13700J/час AI Ops 14100J/час Dev SecOps 1450J/час																																																																	
			Потребление	0.55J / 1000 токенов																																																																	
			Развертывание	1 574 400J																																																																	
			Поддержка платформы	N/A (требуется токены)																																																																	
			Поддержка оборудования	N/A (требуется токены)																																																																	
			GPU	N/A (параллельно)																																																																	

5.1.11 Чек-лист по передаче продукта на ТП (MWS)

Версия	Документ

5.1.12 Онеpager (MWS)

Версия	Документ
v1.0	

5.2 Внешняя документация

6 Разработка

6.1 Product Backlog Refinement

Встречи проводятся еженедельно по ПН.

Цели встречи:

1. Выработать единое понимание приоритетов;
2. Провалидировать запросы со стороны Стейкхолдеров;
3. Определить, какие задачи готовы войти в ближайшие спринты, какие deprecated

Итог встречи:

1. Список задач и статусов к изменению по ним
2. Список открытых вопросов
3. Назначены ответственные по пунктам выше

№ задачи	Статус	Дата запроса	Срок	Отв.
нет	Стабилизация LangFlow			Горинов Д.
LLMPLA-312 ²³	librechat & langflow integration			-
LLMPLA-238 ²⁴	Биллинг для SaaS			Зависимость с MWS Console
нет	RateLimit			Горинов Д.
нет	BudgetLimit		не срочно	Зависимость с MWS Console

²³ <https://jira.mts.ru/browse/LLMPLA-312>

²⁴ <https://jira.mts.ru/browse/LLMPLA-238>

LLMPLA-239 ²⁵	Прокси для внешним моделей для image generation и sst/tts Пробросить внешние модели			Горинов Д.
LLMPLA-373 ²⁶	Выполнено			Криванков Д.
Нет	Выдача клиентам реселлерам токенов для их потребителей			Криванков Д.
Нет	RoadMap доп конца года			Горинов Д.
нет	RateLimit BudgetLimit Завести задачу на исследование	08.09.2025		Игорь Кочелков
нет	Ввести эпик Интеграция с MWS			Горинов Д.
нет	Апдейт Виспера			Горинов Д.
нет	RnD по биллингу модальностей			Горинов Д.
нет	Завести задачу на обновление версии во внешнем стенде LibreChat Версия либо из Инсайда, либо самая последняя у Максима Красильникова Доп: повторить тестирование.	22.09.2025		Горинов Д.

²⁵ <https://jira.mts.ru/browse/LLMPLA-239>

²⁶ <https://jira.mts.ru/browse/LLMPLA-373>

LLMPLA-596 ²⁷	Нужна отдельная встреча с проработкой данного вопроса. Пока не приоритезируем	15.09.2025		Криванков Д.
нет	Добавить Идею: Политика чистки/хранения загруженных файлов в LibreChat	15.09.2025		Гуров О.
	Привести в порядок Ocean (Inside)			

6.2 QA

6.2.1 Core

6.2.2 No-Code

6.2.2.1 Агенты

6.2.2.2 Компоненты No-code

- [Agents](#) (see page 22)
- [Data](#) (see page 23)
- [Helpers](#) (see page 23)
- [Input/Output](#) (see page 23)
- [Logic](#) (see page 23)
- [Processing](#) (see page 23)
- [Vector stores](#) (see page 24)

6.2.2.2.1 Agents

Agent

MCP Tool

²⁷ <https://jira.mts.ru/browse/LLMPLA-596>

6.2.2.2.2 Data

Api Request
Directory
File
News Search
RSS Reader
SQL Database
URL
Web Search
Webhook

6.2.2.2.3 Helpers

Calculator
Current Date
Message History

6.2.2.2.4 Input/Output

Chat Input
Chat Output
Text Input
Text Output

6.2.2.2.5 Logic

If-else
Listen (beta)
Loop
Notify (beta)
Run Flow (beta)

6.2.2.2.6 Processing

Prompt Template
Batch Run
Data Operations

Dataframe Operations

LLM Router

Parser

Python Interpreter

Save File

Smart Function

Split Text

Structured Output

Type Convert

6.2.2.2.7 Vector stores

Astra DB Graph

Cassandra

Cassandra Graph

Chroma DM

Clickhouse

Couchbase

Elasticsearch

FAISS

Graph RAG

Hyper-Converged Database

Local DB

Milvus

MongoDB Atlas

OpenSearch

PGVector

Pinecone

Qdrant

Redis

Supabase

Upstash

Vectara

Vectara RAG

Weaviate

6.2.2.3 Модели

6.2.2.4 Рабочие сценарии

№	Имя	Описание	На ли чи е	С т а т у с	А в т о м а т и з и р о в а н	Дат а изм ене ния	Ком мент арий
1	Транскрибация аудио	LLM для извлечения информации из аудио записи и её последующего анализа Данный пример служит для демонстрации возможностей LLM для извлечения информации из аудио записи и её последующего анализа 1. Пользователь загружает файл в компонент Audio File (есть возможность сделать аналогичный компонент для загрузки audio file из URL или API эндпоинта). 2. Компонент Audio File выполняет преобразование файла в base64 строку, и передает в формате data в следующий компонент. 3. Audio Files to Text компонент выполняет подключение к MWS GPT модели и с её помощью преобразует аудио запись в текст. 4. Далее извлеченный из записи текст передается в языковую модель, куда также поступает и пользовательский вопрос, таким образом модель может отвечать на вопросы о записи.	+	done	✓	16.03.26	

№	Имя	Описание	На ли чи е	С т а т у с	А в т о м а т и з и р о в а н	Дат а изм ене ния	Ком мент арий
		Сценарии применения: 1. Сделать аналитику записи разговора/ВКС/подкаста. 2. Автоматически извлечь из записи какие-то детали, например, договоренности, идентифицированные сложности, и т.д. --- Внимание! Для работы этого пайплайна требуется доступ к Whisper audio модели в MWS GPT - просьба согласовать с вашим менеджером доступ к этой модели.					

№	Имя	Описание	На ли чи е	С т а т у с	А в т о м а т и з и р о в а н	Дат а изм ене ния	Ком мент арий
2	Транскрибация аудио (как есть)	Агенты, автоматически преобразующий аудио в текст и выполняющие последующую аналитику. Данный пример служит для демонстрации возможностей LLM для извлечения текста из аудио записи 1. Пользователь загружает файл в компонент Audio File. 2. Компонент Audio File выполняет преобразование файла в base64 строку, и передает в формате data в следующий компонент. 3. Audio Files to Text компонент выполняет подключение к MWS GPT модели и с её помощью преобразует аудио запись в текст. Сценарии применения - перевести запись в текст. --- Внимание! Для работы этого пайплайна требуется доступ к Whisper audio модели в MWS GPT - просьба согласовать с вашим менеджером доступ к этой модели.	+	d o n e	✓	05.0 3.26	

№	Имя	Описание	На ли чи е	С т а т у с	А в т о м а т и з и р о в а н	Дат а изм ене ния	Ком мент арий
3	Документац ия из URL	Агент, загружающий и анализирующий документы, доступные по URL. (вопрос встроен) Инструкция к запуску агента 1. Убедитесь, что во всех компонентах, которые подключаются к языковым моделям (например, "MWS GPT Model", "MWS GPT Embeddings", "Agent" и другие), указан API Base URL и API ключ для подключения к платформе (выдается нашим менеджером). Ключ выглядит как "sk-xxxxxxxxxxxxxxxx". 2. Убедитесь, что во всех компонентах, которые подключаются к языковым моделям, указана Model name - модель, к которой производится обращение. Пример имени LLM модели: llama-3.3-70b-instruct. Пример имени модели для Embeddings: bge-m3 3. Если используете компонент для подключения к векторной базе данных (Vector Stores) указаны настройки для подключения. Например, для компонента FAISS указана уникальная Persist Directory для вашего сценария, например, "test1234_mycompanyname". 4. Если используете компонент File (или аналогичные для аудиофайлов и других типов файлов), то убедитесь, что в каждый такой компонент загружен нужный вам файл.	+	d o n e	✓	05.0 3.26	Вопро с с импо рт поля ми, если встат ь в начал о и удаля ть, курсо р идет В конец

№	Имя	Описание	На ли чи е	С т а т у с	А в т о м а т и з и р о в а н	Дат а изм ене ния	Ком мент арий
4	Классификация обращений мед (текст, анализ)	Агент, классифицирующий медицинские обращения на основе текстового анализа. Инструкция к запуску агента 1. Убедитесь, что во всех компонентах, которые подключаются к языковым моделям (например, "MWS GPT Model", "MWS GPT Embeddings", "Agent" и другие), указан API Base URL и API ключ для подключения к платформе (выдается нашим менеджером). Ключ выглядит как "sk-xxxxxxxxxxxxxxxx". 2. Убедитесь, что во всех компонентах, которые подключаются к языковым моделям, указана Model name - модель, к которой производится обращение. Пример имени LLM модели: llama-3.3-70b-instruct. Пример имени модели для Embeddings: bge-m3 3. Если используете компонент для подключения к векторной базе данных (Vector Stores) указаны настройки для подключения. Например, для компонента FAISS указана уникальная Persist Directory для вашего сценария, например, "test1234_mycompanyname". 4. Если используете компонент File (или аналогичные для аудиофайлов и других типов файлов), то убедитесь, что в каждый такой компонент загружен нужный вам файл.	+	done	✓	05.03.26	

№	Имя	Описание	На ли чи е	С т а т у с	А в т о м а т и з и р о в а н	Дат а изм ене ния	Ком мент арий
5	Речевая аналитика- диаризация транскрибаци а анализ	Агент, объединяющий диаризацию, транскрибацию и анализ речи для комплексной аналитики – подходит для анализа качества работы контакт-центра. Агент Инструкция к запуску агента 1. Убедитесь, что во всех компонентах, которые подключаются к языковым моделям (например, "MWS GPT Model", "MWS GPT Embeddings", "Agent" и другие), указан API Base URL и API ключ для подключения к платформе (выдается нашим менеджером). Ключ выглядит как "sk-xxxxxxxxxxxxxxxx". 2. Убедитесь, что во всех компонентах, которые подключаются к языковым моделям, указана Model name - модель, к которой производится обращение. Пример имени LLM модели: llama-3.3-70b-instruct. Пример имени модели для Embeddings: bge-m3 3. Если используете компонент для подключения к векторной базе данных (Vector Stores) указаны настройки для подключения. Например, для компонента FAISS указана уникальная Persist Directory для вашего сценария, например, "test1234_mycompanyname". 4. Если используете компонент File (или аналогичные для аудиофайлов и других типов файлов), то убедитесь, что в каждый такой компонент загружен нужный вам файл.	+	d o n e	✓	05.0 3.26	

№	Имя	Описание	На ли чи е	С т а т у с	А в т о м а т и з и р о в а н	Дат а изм ене ния	Ком мент арий
6	Контакт центр	Агент, оптимизирующий маршрутизацию и обработку обращений в контакт-центре. Пример общения пример запроса: ▪ ничего не работает ▪ мобильный интернет не работает ▪ вчера ▪ в одном месте ▪ нет проблем у знакомых ▪ +79998887766 -выключил режим в полете, все заработало, спасибо!	+	d o n e	✓	05.0 3.26	
7	Деперсонал изация с шифровани ем	Описание Агент, который выполняет обратимое шифрование данных до отправки их во внешнюю модель, затем отправляет во внешнюю модель для обработки, получает ответ, и в ответе дешифрует данные для пользователя. Шифрование проходит прозрачно для пользователя, а обработка во внешней модели с шифрованием обеспечивает безопасность при обработке данных компании.	+	d o n e	✓	05.0 3.26	Немн ого смуц ает вре мя испол нения (уточ нить)

№	Имя	Описание	На ли чи е	С т а т у с	А в т о м а т и з и р о в а н	Дат а изм ене ния	Ком мент арий
8	Агент базовый	Функции: калькулятор, загрузка инфо из URL, получение актуальной погоды из url Инструкция к запуску агента 1. Убедитесь, что во всех компонентах, которые подключаются к языковым моделям (например, "MWS GPT Model", "MWS GPT Embeddings", "Agent" и другие), указан API Base URL и API ключ для подключения к платформе (выдается нашим менеджером). Ключ выглядит как "sk-xxxxxxxxxxxxxxxx". 2. Убедитесь, что во всех компонентах, которые подключаются к языковым моделям, указана Model name - модель, к которой производится обращение. Пример имени LLM модели: llama-3.3-70b-instruct. Пример имени модели для Embeddings: bge-m3 3. Если используете компонент для подключения к векторной базе данных (Vector Stores) указаны настройки для подключения. Например, для компонента FAISS указана уникальная Persist Directory для вашего сценария, например, "test1234_mycompanyname". 4. Если используете компонент File (или аналогичные для аудиофайлов и других типов файлов), то убедитесь, что в каждый такой компонент загружен нужный вам файл.	+	done	✓	13.03.26	(требуется сломать и проверить автотест)

№	Имя	Описание	На ли чи е	С т а т у с	А в т о м а т и з и р о в а н	Дат а изм ене ния	Ком мент арий
9	Мульти- агент аэро + рейсы	Агент, демонстрирующий возможности мульти-агентной схемы для интегрирования в едином боте текущих данных о рейсах в аэропорту и информации как что-то провезти из информационной системы аэропорта. Агент Внутри 2:1 связанные агенты для помощи с полетом и авиа-расписанием	+	d on e	✓	05.0 3.26	

№	Имя	Описание	На ли чи е	С т а т у с	А в т о м а т и з и р о в а н	Дат а изм ене ния	Ком мент арий
10	Разбор контента на изображени и через VL модель	Агент, анализирующий визуальный контент изображений с помощью VLM модели.	+	d o n e	✗ н у ж е н Д о с т у п Д о https://devapi.gpt.mws.ru/v1	05.0 3.26	


№	Имя	Описание	На ли чи е	С т а т у с	А в т о м а т и з и р о в а н	Дат а изм ене ния	Ком мент арий
11	Деперсонализация и обработка во внешней модели	Агент, демонстрирующий деперсонализацию данных в MCP GPT и их дальнейшую обработку с помощью внешней модели.	+	d o n e	✓	05.0 3.26	Попр обова ть более мощн ую моде ль
12	Договор парсинг + api (vl модель ocr)	Агент, автоматически извлекающий информацию из договоров с помощью VLM и API.	+	d o n e	✓	05.0 3.26	Teste d on llama 3.3 model .
13	RAG PGvector + file excel	Агент, использующий Postgresql+Pgvector базу данных для хранения как векторное хранилище, и позволяющий на вход подавать xlsx документы.	+	d o n e	✓	05.0 3.26	
14	RAG faiss + multi-file template	Простой агент, использующий FAISS для быстрого поиска и шаблоны для обработки нескольких файлов.	+	d o n e	✓	05.0 3.26	Teste d on llama 3.3 model .


№	Имя	Описание	На ли чи е	С т а т у с	А в т о м а т и з и р о в а н	Дат а изм ене ния	Ком мент арий
15	Multi-modal RAG from Files	Агент, извлекающий информацию из файлов, объединяя данные разных модальностей (автоматическое извлечение инфо из картинок + текста), помещение этого в базу, и обеспечение возможности ответов в чат-боте пользователям на основе инфо из текста и картинок.	+	d o n e	✓	05.0 3.26	
16	Multi-modal RAG from URL	Агент, загружающий файлы через URL , объединяя данные разных модальностей (автоматическое извлечение инфо из картинок + текста), помещение этого в базу, и обеспечение возможности ответов в чат-боте пользователям на основе инфо из текста и картинок.	+	d o n e	✓	05.0 3.26	Errors
17	Агент db process демо	Агент для извлечения инфо из базы данных	+	d o n e	✓	05.0 3.26	
18	Агент базовый + mcp streamable http custom server	Функции: подключение к mcp серверу, калькулятор, загрузка инфо из URL, получение актуальной погоды из url	+	d o n e	✓	05.0 3.26	
19	Агент базовый + mcp sse custom server	Функции: подключение к mcp серверу, калькулятор, загрузка инфо из URL, получение актуальной погоды из url	+	no ne	✓	10.0 3.26	fixed 11.03. 26

№	Имя	Описание	На ли чи е	С т а т у с	А в т о м а т и з и р о в а н	Дат а изм ене ния	Ком мент арий
20	Договор парсинг	Агент для извлечения ключевой информации из договоров посредством обработки LLM моделью.	+	d o n e	✓	05.0 3.26	


6.3 VLM

6.3.1 Бенчмаркинг

Бенчмарк	Комментарий	Язык
math_vision	Показывает как решаются различные разделы математики:  В среднем, каждая из моделей показывает достаточно хороший уровень + ответы открытые исходя из этого не самый показательный для нас бенчмарк, хотя он показывает, на сколько в целом драматично падает модель не показательный потому что закрывает одну конкретную задачу - решение математических задач	en

Бенчмарк	Комментарий	Язык
mm_bench_en	Многие модели видно, что заучиваются на бенчмарк, в целом все модели показывают высокий перформанс: 	en
mm_bench_ru	с русским картина чуть хуже, однако дообучение тоже сразу очень бросается в глаза, потому что относительно слабая для русского языка модель становится топовой: 	ru

Бенчмарк	Комментарий	Язык																																																																																																								
mm_star	Хороший бенчмарк разбитый по подтемам, однако: <table><thead><tr><th></th><th>Overall</th><th>coarse perception</th><th>fine-grained perception</th><th>instance reasoning</th><th>logical reasoning</th><th>math</th><th>science & technology</th></tr></thead><tbody><tr><td>model</td><td></td><td></td><td></td><td></td><td></td><td></td><td></td></tr><tr><td>molmo-7B-D-0924</td><td>0.562000</td><td>0.652</td><td>0.520</td><td>0.676</td><td>0.564</td><td>0.516</td><td>0.444</td></tr><tr><td>Qwen2-VL-7B-Instruct-tuned-dpo</td><td>0.594667</td><td>0.696</td><td>0.552</td><td>0.656</td><td>0.592</td><td>0.588</td><td>0.484</td></tr><tr><td>Llama-3.2-11B-Vision-Instruct-lora-32-32-big</td><td>0.474000</td><td>0.632</td><td>0.456</td><td>0.600</td><td>0.480</td><td>0.332</td><td>0.344</td></tr><tr><td>Qwen2-VL-7B-Instruct-tuned</td><td>0.594667</td><td>0.696</td><td>0.556</td><td>0.648</td><td>0.596</td><td>0.592</td><td>0.480</td></tr><tr><td>Llama-3.2-11B-Vision-Instruct-lora-16-16-big</td><td>0.435333</td><td>0.580</td><td>0.368</td><td>0.532</td><td>0.436</td><td>0.396</td><td>0.300</td></tr><tr><td>Qwen2-VL-7B-GRPO-8k</td><td>0.564667</td><td>0.680</td><td>0.488</td><td>0.632</td><td>0.564</td><td>0.572</td><td>0.452</td></tr><tr><td>Llama-3.2-11B-Vision-Instruct</td><td>0.467333</td><td>0.644</td><td>0.420</td><td>0.596</td><td>0.492</td><td>0.376</td><td>0.276</td></tr><tr><td>Llama-3.2-11B-Vision-Instruct-lora-32-32-small</td><td>0.488667</td><td>0.636</td><td>0.480</td><td>0.588</td><td>0.504</td><td>0.380</td><td>0.344</td></tr><tr><td>Pixtral-12B</td><td>0.544667</td><td>0.668</td><td>0.444</td><td>0.648</td><td>0.576</td><td>0.572</td><td>0.360</td></tr><tr><td>Qwen2-VL-7B-Instruct</td><td>0.611333</td><td>0.704</td><td>0.580</td><td>0.688</td><td>0.604</td><td>0.584</td><td>0.508</td></tr><tr><td>Llama-3.2-11B-Vision-Instruct-lora-32-32-small-lang-attn</td><td>0.461333</td><td>0.604</td><td>0.420</td><td>0.588</td><td>0.444</td><td>0.368</td><td>0.344</td></tr></tbody></table>		Overall	coarse perception	fine-grained perception	instance reasoning	logical reasoning	math	science & technology	model								molmo-7B-D-0924	0.562000	0.652	0.520	0.676	0.564	0.516	0.444	Qwen2-VL-7B-Instruct-tuned-dpo	0.594667	0.696	0.552	0.656	0.592	0.588	0.484	Llama-3.2-11B-Vision-Instruct-lora-32-32-big	0.474000	0.632	0.456	0.600	0.480	0.332	0.344	Qwen2-VL-7B-Instruct-tuned	0.594667	0.696	0.556	0.648	0.596	0.592	0.480	Llama-3.2-11B-Vision-Instruct-lora-16-16-big	0.435333	0.580	0.368	0.532	0.436	0.396	0.300	Qwen2-VL-7B-GRPO-8k	0.564667	0.680	0.488	0.632	0.564	0.572	0.452	Llama-3.2-11B-Vision-Instruct	0.467333	0.644	0.420	0.596	0.492	0.376	0.276	Llama-3.2-11B-Vision-Instruct-lora-32-32-small	0.488667	0.636	0.480	0.588	0.504	0.380	0.344	Pixtral-12B	0.544667	0.668	0.444	0.648	0.576	0.572	0.360	Qwen2-VL-7B-Instruct	0.611333	0.704	0.580	0.688	0.604	0.584	0.508	Llama-3.2-11B-Vision-Instruct-lora-32-32-small-lang-attn	0.461333	0.604	0.420	0.588	0.444	0.368	0.344	en
	Overall	coarse perception	fine-grained perception	instance reasoning	logical reasoning	math	science & technology																																																																																																			
model																																																																																																										
molmo-7B-D-0924	0.562000	0.652	0.520	0.676	0.564	0.516	0.444																																																																																																			
Qwen2-VL-7B-Instruct-tuned-dpo	0.594667	0.696	0.552	0.656	0.592	0.588	0.484																																																																																																			
Llama-3.2-11B-Vision-Instruct-lora-32-32-big	0.474000	0.632	0.456	0.600	0.480	0.332	0.344																																																																																																			
Qwen2-VL-7B-Instruct-tuned	0.594667	0.696	0.556	0.648	0.596	0.592	0.480																																																																																																			
Llama-3.2-11B-Vision-Instruct-lora-16-16-big	0.435333	0.580	0.368	0.532	0.436	0.396	0.300																																																																																																			
Qwen2-VL-7B-GRPO-8k	0.564667	0.680	0.488	0.632	0.564	0.572	0.452																																																																																																			
Llama-3.2-11B-Vision-Instruct	0.467333	0.644	0.420	0.596	0.492	0.376	0.276																																																																																																			
Llama-3.2-11B-Vision-Instruct-lora-32-32-small	0.488667	0.636	0.480	0.588	0.504	0.380	0.344																																																																																																			
Pixtral-12B	0.544667	0.668	0.444	0.648	0.576	0.572	0.360																																																																																																			
Qwen2-VL-7B-Instruct	0.611333	0.704	0.580	0.688	0.604	0.584	0.508																																																																																																			
Llama-3.2-11B-Vision-Instruct-lora-32-32-small-lang-attn	0.461333	0.604	0.420	0.588	0.444	0.368	0.344																																																																																																			
mm_vet	<table><thead><tr><th>Category model</th><th>Overall</th><th>gen</th><th>know</th><th>math</th><th>ocr</th><th>rec</th><th>spat</th></tr></thead><tbody><tr><td>Llama-3.2-11B-Vision-Instruct</td><td>55.045872</td><td>36.125</td><td>36.428571</td><td>66.538462</td><td>65.000000</td><td>53.636364</td><td>66.266667</td></tr><tr><td>Llama-3.2-11B-Vision-Instruct-lora-16-16-big</td><td>42.522936</td><td>23.000</td><td>25.119048</td><td>20.769231</td><td>48.611111</td><td>46.737968</td><td>48.666667</td></tr><tr><td>Llama-3.2-11B-Vision-Instruct-lora-32-32-big</td><td>48.807339</td><td>31.250</td><td>31.547619</td><td>26.923077</td><td>52.870370</td><td>53.582888</td><td>53.333333</td></tr><tr><td>Llama-3.2-11B-Vision-Instruct-lora-32-32-small</td><td>42.293578</td><td>23.125</td><td>23.333333</td><td>44.230769</td><td>48.425926</td><td>44.919786</td><td>46.133333</td></tr><tr><td>Llama-3.2-11B-Vision-Instruct-lora-32-32-small-lang-attn</td><td>45.550459</td><td>26.250</td><td>30.595238</td><td>21.153846</td><td>48.703704</td><td>51.122995</td><td>46.133333</td></tr><tr><td>Pixtral-12B</td><td>55.779817</td><td>36.625</td><td>32.976190</td><td>66.923077</td><td>67.222222</td><td>55.187166</td><td>64.666667</td></tr><tr><td>Qwen2-VL-7B-GRPO-8k</td><td>54.862385</td><td>35.625</td><td>34.047619</td><td>76.153846</td><td>63.240741</td><td>53.796791</td><td>60.000000</td></tr><tr><td>Qwen2-VL-7B-Instruct</td><td>58.119266</td><td>41.500</td><td>39.642857</td><td>61.153846</td><td>67.129630</td><td>59.251337</td><td>61.866667</td></tr><tr><td>Qwen2-VL-7B-Instruct-tuned</td><td>59.128440</td><td>41.375</td><td>40.952381</td><td>65.384615</td><td>65.277778</td><td>61.657754</td><td>61.733333</td></tr><tr><td>Qwen2-VL-7B-Instruct-tuned-dpo</td><td>58.990826</td><td>39.375</td><td>39.523810</td><td>65.384615</td><td>66.296296</td><td>61.122995</td><td>62.533333</td></tr><tr><td>molmo-7B-D-0924</td><td>40.045872</td><td>11.375</td><td>12.023810</td><td>26.923077</td><td>47.222222</td><td>43.636364</td><td>51.333333</td></tr></tbody></table>	Category model	Overall	gen	know	math	ocr	rec	spat	Llama-3.2-11B-Vision-Instruct	55.045872	36.125	36.428571	66.538462	65.000000	53.636364	66.266667	Llama-3.2-11B-Vision-Instruct-lora-16-16-big	42.522936	23.000	25.119048	20.769231	48.611111	46.737968	48.666667	Llama-3.2-11B-Vision-Instruct-lora-32-32-big	48.807339	31.250	31.547619	26.923077	52.870370	53.582888	53.333333	Llama-3.2-11B-Vision-Instruct-lora-32-32-small	42.293578	23.125	23.333333	44.230769	48.425926	44.919786	46.133333	Llama-3.2-11B-Vision-Instruct-lora-32-32-small-lang-attn	45.550459	26.250	30.595238	21.153846	48.703704	51.122995	46.133333	Pixtral-12B	55.779817	36.625	32.976190	66.923077	67.222222	55.187166	64.666667	Qwen2-VL-7B-GRPO-8k	54.862385	35.625	34.047619	76.153846	63.240741	53.796791	60.000000	Qwen2-VL-7B-Instruct	58.119266	41.500	39.642857	61.153846	67.129630	59.251337	61.866667	Qwen2-VL-7B-Instruct-tuned	59.128440	41.375	40.952381	65.384615	65.277778	61.657754	61.733333	Qwen2-VL-7B-Instruct-tuned-dpo	58.990826	39.375	39.523810	65.384615	66.296296	61.122995	62.533333	molmo-7B-D-0924	40.045872	11.375	12.023810	26.923077	47.222222	43.636364	51.333333	en								
Category model	Overall	gen	know	math	ocr	rec	spat																																																																																																			
Llama-3.2-11B-Vision-Instruct	55.045872	36.125	36.428571	66.538462	65.000000	53.636364	66.266667																																																																																																			
Llama-3.2-11B-Vision-Instruct-lora-16-16-big	42.522936	23.000	25.119048	20.769231	48.611111	46.737968	48.666667																																																																																																			
Llama-3.2-11B-Vision-Instruct-lora-32-32-big	48.807339	31.250	31.547619	26.923077	52.870370	53.582888	53.333333																																																																																																			
Llama-3.2-11B-Vision-Instruct-lora-32-32-small	42.293578	23.125	23.333333	44.230769	48.425926	44.919786	46.133333																																																																																																			
Llama-3.2-11B-Vision-Instruct-lora-32-32-small-lang-attn	45.550459	26.250	30.595238	21.153846	48.703704	51.122995	46.133333																																																																																																			
Pixtral-12B	55.779817	36.625	32.976190	66.923077	67.222222	55.187166	64.666667																																																																																																			
Qwen2-VL-7B-GRPO-8k	54.862385	35.625	34.047619	76.153846	63.240741	53.796791	60.000000																																																																																																			
Qwen2-VL-7B-Instruct	58.119266	41.500	39.642857	61.153846	67.129630	59.251337	61.866667																																																																																																			
Qwen2-VL-7B-Instruct-tuned	59.128440	41.375	40.952381	65.384615	65.277778	61.657754	61.733333																																																																																																			
Qwen2-VL-7B-Instruct-tuned-dpo	58.990826	39.375	39.523810	65.384615	66.296296	61.122995	62.533333																																																																																																			
molmo-7B-D-0924	40.045872	11.375	12.023810	26.923077	47.222222	43.636364	51.333333																																																																																																			
	Аналогично и на этом бенчмарке, он разбит скорее по задачам CV направлений, нежели чем контекста вопросов, в отличие от предыдущего. Видно заучивание моделей на ответах (более слабые модели сильнее отвечают)																																																																																																									

Бенчмарк	Комментарий	Язык																																																															
llava bench	Слабые стороны бенчмарка: он очень маленький (всего 60 вопросов) по 3 направлениям: опиши что-то, ответь на вопрос, что за объект на картинке? Бенчмарк на английском <table><thead><tr><th>Модель</th><th>a_better_b</th><th>both_bad</th><th>both_good</th><th>b_better_a</th><th>model vs gpt_4o</th><th>model vs gpt_4o reversed eval</th></tr></thead><tbody><tr><td>VLM-R1</td><td>47</td><td>1</td><td>4</td><td>8</td><td>19.05 vs 80.95</td><td>17.91 vs 82.09</td></tr><tr><td>Qwen2.5-VL-3B-Instruct</td><td>29</td><td>1</td><td>8</td><td>22</td><td>44.78 vs 55.22</td><td>34.85 vs 65.15</td></tr><tr><td>Qwen2-VL-7B-Instruct-tuned</td><td>53</td><td>1</td><td>0</td><td>6</td><td>10.17 vs 89.83</td><td>11.94 vs 88.06</td></tr><tr><td>Qwen2-VL-7B-GRPO-8k-raw-output</td><td>51</td><td>0</td><td>2</td><td>7</td><td>14.52 vs 85.48</td><td>21.88 vs 78.12</td></tr><tr><td>Qwen2-VL-7B-GRPO-8k</td><td>53</td><td>1</td><td>2</td><td>4</td><td>9.84 vs 90.16</td><td>10.45 vs 89.55</td></tr><tr><td>Llama-3.2-11B-Vision-Instruct</td><td>29</td><td>1</td><td>3</td><td>27</td><td>48.39 vs 51.61</td><td>34.92 vs 65.08</td></tr><tr><td>Qwen2-VL-7B-Instruct</td><td>45</td><td>1</td><td>1</td><td>13</td><td>23.33 vs 76.67</td><td>20.9 vs 79.1</td></tr><tr><td>VLM-R1-raw-output</td><td>47</td><td>2</td><td>1</td><td>10</td><td>18.64 vs 81.36</td><td>23.81 vs 76.19</td></tr></tbody></table> Сильная сторона: это SBS бенчмарк, то есть его оценивает модель судья, которая учитывает, что изображено на картинке и оценивает ответы двух моделей	Модель	a_better_b	both_bad	both_good	b_better_a	model vs gpt_4o	model vs gpt_4o reversed eval	VLM-R1	47	1	4	8	19.05 vs 80.95	17.91 vs 82.09	Qwen2.5-VL-3B-Instruct	29	1	8	22	44.78 vs 55.22	34.85 vs 65.15	Qwen2-VL-7B-Instruct-tuned	53	1	0	6	10.17 vs 89.83	11.94 vs 88.06	Qwen2-VL-7B-GRPO-8k-raw-output	51	0	2	7	14.52 vs 85.48	21.88 vs 78.12	Qwen2-VL-7B-GRPO-8k	53	1	2	4	9.84 vs 90.16	10.45 vs 89.55	Llama-3.2-11B-Vision-Instruct	29	1	3	27	48.39 vs 51.61	34.92 vs 65.08	Qwen2-VL-7B-Instruct	45	1	1	13	23.33 vs 76.67	20.9 vs 79.1	VLM-R1-raw-output	47	2	1	10	18.64 vs 81.36	23.81 vs 76.19	en
Модель	a_better_b	both_bad	both_good	b_better_a	model vs gpt_4o	model vs gpt_4o reversed eval																																																											
VLM-R1	47	1	4	8	19.05 vs 80.95	17.91 vs 82.09																																																											
Qwen2.5-VL-3B-Instruct	29	1	8	22	44.78 vs 55.22	34.85 vs 65.15																																																											
Qwen2-VL-7B-Instruct-tuned	53	1	0	6	10.17 vs 89.83	11.94 vs 88.06																																																											
Qwen2-VL-7B-GRPO-8k-raw-output	51	0	2	7	14.52 vs 85.48	21.88 vs 78.12																																																											
Qwen2-VL-7B-GRPO-8k	53	1	2	4	9.84 vs 90.16	10.45 vs 89.55																																																											
Llama-3.2-11B-Vision-Instruct	29	1	3	27	48.39 vs 51.61	34.92 vs 65.08																																																											
Qwen2-VL-7B-Instruct	45	1	1	13	23.33 vs 76.67	20.9 vs 79.1																																																											
VLM-R1-raw-output	47	2	1	10	18.64 vs 81.36	23.81 vs 76.19																																																											
MMMU	Сильный бенчмарк, но снова только на английском языке	en																																																															

6.3.1.1 LLaVaRU

Основная идея - взять llava bench и перевести вопросы (не ответы) на русский язык.

Так же внедрили обратную оценку, модель оценивала только на первом месте ответ от эталонной модели, на втором - ответ от нашей модели. Тем самым получили бенчмарк:

	a_better_b	b_better_a	both_bad	both_good	model vs gpt_4o	model vs gpt_4o reversed eval
VLM-R1	50	8	2	0	13.79 vs 86.21	17.74 vs 82.26
Qwen2.5-VL-3B-Instruct	47	9	2	2	18.33 vs 81.67	16.13 vs 83.87
Qwen2-VL-7B-Instruct-tuned	54	3	3	0	5.26 vs 94.74	12.5 vs 87.5
Qwen2-VL-7B-GRPO-8k-raw-output	53	3	3	1	6.9 vs 93.1	9.84 vs 90.16
Qwen2-VL-7B-GRPO-8k	53	2	5	0	3.64 vs 96.36	11.29 vs 88.71
Llama-3.2-11B-Vision-Instruct	47	6	3	4	16.39 vs 83.61	14.75 vs 85.25
Qwen2-VL-7B-Instruct	52	7	1	0	11.86 vs 88.14	14.06 vs 85.94
VLM-R1-raw-output	50	6	3	1	12.07 vs 87.93	17.24 vs 82.76

На самом деле, это не самый корректный способ сравнивать качество модели между английским и русским бенчмарком. Поэтому нужно было разработать еще один, чтобы иметь потенциальную верхнюю границу.

6.3.1.2 LLaVaTranslated

Идея бенчмарка:

Мы берем английский входной вопрос → генерируем ответ на англ → переводим (как, чем?) → сравниваем ответы эталонной модели, полученные генерацией с русским входом.

Были замеряны два разные способа перевода:

6.3.1.2.1 GPT_3.5-turbo

	a_better_b	b_better_a	both_bad	both_good	model vs gpt_4o	model vs gpt_4o reversed eval
VLM-R1	48	9	1	2	18.03 vs 81.97	20.31 vs 79.69
Qwen2.5-VL-3B-Instruct	37	18	0	5	35.38 vs 64.62	33.33 vs 66.67
Qwen2-VL-7B-Instruct-tuned	46	12	2	0	20.69 vs 79.31	12.9 vs 87.1
Qwen2-VL-7B-GRPO-8k-raw-output	45	8	2	5	20.63 vs 79.37	14.29 vs 85.71
Qwen2-VL-7B-GRPO-8k	54	3	3	0	5.26 vs 94.74	12.9 vs 87.1
Llama-3.2-11B-Vision-Instruct	38	19	0	3	34.92 vs 65.08	35.0 vs 65.0
Qwen2-VL-7B-Instruct	45	14	1	0	23.73 vs 76.27	16.39 vs 83.61
VLM-R1-raw-output	45	12	0	3	23.81 vs 76.19	22.22 vs 77.78

6.3.1.2.2 claude-3-opus

	a_better_b	b_better_a	both_bad	both_good	model vs gpt_4o	model vs gpt_4o reversed eval
VLM-R1	46	12	1	1	21.67 vs 78.33	20.63 vs 79.37
Qwen2.5-VL-3B-Instruct	29	27	0	4	48.44 vs 51.56	41.94 vs 58.06
Qwen2-VL-7B-Instruct-tuned	45	13	2	0	22.41 vs 77.59	14.29 vs 85.71
Qwen2-VL-7B-GRPO-8k-raw-output	48	8	1	3	17.74 vs 82.26	11.48 vs 88.52
Qwen2-VL-7B-GRPO-8k	54	4	2	0	6.9 vs 93.1	9.68 vs 90.32
Qwen2-VL-7B-Instruct	43	16	1	0	27.12 vs 72.88	19.35 vs 80.65
VLM-R1-raw-output	43	14	0	3	26.98 vs 73.02	30.0 vs 70.0

Еще была итерация перевода с deepseek, но дип сик зачастую в перевод вставлял иероглифы.

Выводы: это наша потенциальная граница. Из интересного:

1. Модель


Qwen2-VL-7B-Instruct-tuned

в русском и английском бенчмарке драматично падает по результату ответа по сравнению с байзлайн моделью, однако в бенчмарке переводном, она показывает очень сходное качество, вне зависимости от перевода - это может говорить о том, что перевод улучшает качество, выбрасывает лишнее и как-то редактирует текст

2. перевод

claude-3-opus оценивается gpt-4o (эталонная модель) в среднем выше, чем перевод gpt-3.5-turbo. Это может быть связано с тем, что первая модель выше в рейтинге lmsys и умнее

6.3.1.3 Text-only benchmark:



Картина которую мы наблюдаем, показывает, что при адаптации, содержащей текстовые данные мы видим улучшение метрик базовой модели на нашем бенчмарке. Однако из-за этого драматично падает качество на vision задачах. Поэтому на данный момент отдается сильное внимание результатам именно визуальных бенчмарков в совокупности с SBS оценкой.

6.3.2 Исследования

- ☐ Датасет, где одинаковые картинки имеют вопросы разные на 2ух языках
- ☐ большая лора (256 на 256) на все внимание и MLP (визуал-мерж-текст)

☐ Одинаковые и неодинаковые вопросы на одну картинку

6.3.3 Таблица экспериментов

i d	модель	бенчмарки	комментарий
1	Llama-3.2-11B-Vision-Instruct	LLavaBench 48.39/34.92 LlavaBenchRU 16.39/14.75 TranslatedLLavaB ench gpt3.5: 34.92 / 35.0 claude:	бейзлайн
2	Qwen2.5-VL-3B-Instruct	LLavaBench 44.78/34.85 LlavaBenchRU 18.33/16.13 TranslatedLLavaB ench gpt3.5: 35.38 / 33.33 claude:	бейзлайн
3	VLM-R1	LLavaBench 19.05/17.91 LlavaBenchRU 13.79/17.74 TranslatedLLavaB ench gpt3.5: 18.03 / 20.31 claude:	бейзлайн - R1 поверх пункта 2

i d	модель	бенчмарки	комментарий
4	VLM-R1-raw-output	LLavaBench 18.64/23.81 LlavaBenchRU 12.07/17.24 TranslatedLLavaBench gpt3.5: 23.81 / 22.22 claude: 26.98 / 30.0	бейзлайн - R1 поверх пункта 2 + оценка вместе с <think>
5	Qwen2-VL-7B-Instruct	LLavaBench 23.33/20.9 LlavaBenchRU 11.86/14.06 TranslatedLLavaBench gpt3.5: 23.73/16.39 claude:	бейзлайн
6	Qwen2-VL-7B-GRPO-8k-raw-output	LLavaBench 14.52/21.88 LlavaBenchRU 6.9 /9.84 TranslatedLLavaBench gpt3.5: 20.63/14.29 claude: 17.74/ 11.48	бейзлайн - R1 поверх пункта 5 + оценка вместе с <think>

id	модель	бенчмарки	комментарий
7	Qwen2-VL-7B-GRPO-8k	LLavaBench 9.84/10.45 LlavaBenchRU 3.64/11.29 TranslatedLLavaBench gpt3.5: 5.26 /12.9 claude: 6.9 / 3.45	бейзлайн - R1 поверх пункта 5
8	idefics fine-tune	LLavaBench 0.0/9.23 LlavaBenchRU 5.26/6.56 TranslatedLLavaBench gpt3.5: 7.02/8.2 claude: 6.78/6.67	
9	Qwen2.5-VL-7B-Instruct	LLavaBench 54.41/47.06 LlavaBenchRU 43.08/30.65 TranslatedLLavaBench gpt3.5: 74.19/ 55.38 claude: 76.56/ 53.12	
10	VL-Rethinker-7B	LLavaBench 63.93/53.33 LlavaBenchRU TranslatedLLavaBench gpt3.5: 81.67/ 66.67 claude: 81.67/60.0	GRPO_SSR от Qwen2.5-VL-7B-Instruct

id	статус	модель	данные SFT	данные DPO	лора(префикс) параметры	бенчмарки	комментарий
1	завершено	Qwen2-VL-7B-Instruct	"the_cauldron", "LLaVA_Instruct_ru", "GQA", "ocra_ru_mtsai_50k", "gusev", "spellcheck_benchmark", "ocra_ru_summary_mtsai_50k", "gsm8k-ru", "spellcheck_benchmark", "wikiomnia", "CodeExercise_Python_27k_ru", "HC3_ru", "logic_tasks_ru", "samsum_ru"		"lora": { "r": 32, "lora_alpha": 32, "target_modules": : ["q_proj", "v_proj", "k_proj", "o_proj", "mlp.0", "mlp.2"], "bias": "none", "lora_dropout": 0.05, "task_type": "CAUSAL_LM", "use_dora": false, "init_lora_weights": "gaussian" }, num_virtual_tokens=20	LlamaBench 10.17 / 11.94 LlamaBenchRu 5.26 / 12.5 TranslatedLavaBench gpt3.5: 20.69 / 12.9 claude: 22.41 / 14.29	повтор пайплайна для MTS ANYA

id	статус	модель	данные SFT	данные DPO	лора(префикс) параметры	бенчмарк и	комментарий
2	завершено	Qwen2-VL-7B-Instruct	"the_cauldron", "LLaVA_Instruct_r u", "GQA", "ocra_ru_mtsai_50k", "gusev", "spellcheck_benchmark", "ocra_ru_summary_mtsai_50k", "gsm8k-ru", "spellcheck_benchmark", "wikiomnia", "CodeExercise_Python_27k_ru", "HC3_ru", "logic_tasks_ru", "samsum_ru"	"0x7o/fialka-v2-dpo", "0x7o/oasst-ru-dpo-v1-rm", "argilla/distilabel-math-preference-dpo", "argilla/dpo-mix-7k", "llamafactory/RLHF-V"	"train_arg": { "warmup_steps": 3, "per_device_train_batch_size": 2, "per_device_eval_batch_size": 2, "gradient_accumulation_steps": 64, "eval_accumulation_steps": 64, "num_train_epochs": 1, "fp16": true, "bf16": false, "learning_rate": 2.5e-05, "optim": "adamw_torch", "logging_steps": 5, "save_strategy": "steps", "save_steps": 500, "eval_strategy": "steps", "eval_steps": 500, "do_eval": true }, "max_length": 8124	LlamaBench 8.47 / LlamaBenchRU 6.9/	DPO над пунктом 1 повтор пайплайна для MTS ANYA

id	статус	модель	данные SFT	данные DPO	лора(префикс) параметры	бенчмарк и	комментарий
					<pre> "lora": { "target_modules" : ["fc1", "qkv", "proj", "fc2", "q_proj", "v_proj", "k_proj", "o_proj", "mlp.0", "mlp.2", "lm_head", "down_proj", "up_proj", "gate_proj"] }, </pre>		
3	завершено	Llama-3.2-11B-Visi on-Instruct	"the_cauldron", "GQA", "ocra_ru_mtsai_50k", "gusev", "spellcheck_benchmark", "ocra_ru_summary_mtsai_50k", "gsm8k-ru", "samsum_ru", "LLaVA_Instruct_ru"		<pre> "lora": { "r": 16, "lora_alpha": 16, "target_modules" : ["q_proj", "v_proj", "k_proj", "o_proj"], "bias": "none", "lora_dropout": 0, "task_type": "CAUSAL_LM" } </pre>	LLamaBench 21.31/21.13 LlamaBenchRU 8.77/9.84 gpt: 20.0/16.92 claude: 15.25 / 18.46	Итерация с ограниченным числом данных при малых параметрах и чисто лора, потому что Prefix падает с ошибкой

id	статус	модель	данные SFT	данные DPO	лора(префикс) параметры	бенчмарк и	комментарий
4	завершено	Llama-3.2-11B-Visi on-Instruct	"the_cauldron", "GQA", "ocra_ru_mtsai_50k", "gusev", "spellcheck_benchmark", "ocra_ru_summary_mtsai_50k", "gsm8k-ru", "samsum_ru", "LLaVA_Instruct_ru"		"lora": { "r": 32, "lora_alpha": 32, "target_modules": ["q_proj", "v_proj", "k_proj", "o_proj"], "bias": "none", "lora_dropout": 0.05, "task_type": "CAUSAL_LM" }	LLamaBench 15.87/25.0 LlamaBenchRU 10.17/12.7 gpt: 18.64 / 15.62 claude: 16.95 / 14.52	
5	завершено	Llama-3.2-11B-Visi on-Instruct	["the_cauldron", "GQA", "LLaVA_Instruct_ru"]		"lora": { "r": 32, "lora_alpha": 32, "target_modules": ["q_proj", "v_proj", "k_proj", "o_proj"], "bias": "none", "lora_dropout": 0.05, "task_type": "CAUSAL_LM" }	LLamaBench 24.19/21.13 LlamaBenchRU 10.17/12.7 gpt: 18.33/14.52 claude: 20.0/11.29	пункт 4: поменьше датасет

id	статус	модель	данные SFT	данные DPO	лора(префикс) параметры	бенчмарк и	комментарий
6	завершено	Llama-3.2-11B-Vision-Instruct	["the_cauldron", "GQA", "LLaVA_Instruct_ru"]		"lora": { "r": 32, "lora_alpha": 32, "target_modules" : ["q_proj", "v_proj", "k_proj", "o_proj"], "bias": "none", "lora_dropout": 0.05, "task_type": "CAUSAL_LM" } только внимание	LLamaBench 14.29/20.0 LlamaBenchRU 10.34/11.29 gpt: 10.34/12.7 claude: 10.17/14.06	пункт 5, но только внимание
7	завершено	Qwen2.5-VL-3B-Instruct	"LLaVA_Instruct_ru"		"lora": { "r": 16, "lora_alpha": 16, "target_modules" : ["q_proj", "v_proj", "k_proj", "o_proj"], "bias": "none", "lora_dropout": 0.05, "task_type": "CAUSAL_LM" }, p_tuning num_virtual_ tokens=30	положительных результатов нет, модель предсказывала один токен	

id	статус	модель	данные SFT	данные DPO	лора(префикс) параметры	бенчмарк и	комментарий
8	завершено	Qwen2.5-VL-3B-Instruct	"LLaVA_Instruct_ru"		<pre> "lora": { "r": 16, "lora_alpha": 16, "target_modules" : ["q_proj", "v_proj", "k_proj", "o_proj"], "bias": "none", "lora_dropout": 0.05, "task_type": "CAUSAL_LM" }, prompt_tuning num_virtual_ tokens=30 </pre>	положительных результатов нет, модель предсказывала один токен	
9	завершено	Qwen2-VL-7B-Instruct	"LLaVA_Instruct_ru"		<pre> "lora": { "r": 16, "lora_alpha": 16, "target_modules" : ["q_proj", "v_proj", "k_proj", "o_proj"], "bias": "none", "lora_dropout": 0.05, "task_type": "CAUSAL_LM" }, prefix_tuning num_virtual_ tokens=30 </pre>	положительных результатов нет, модель предсказывала мракобесие	отдельный пайплайн, сначала префикс, потом лора, все по статье

id	статус	модель	данные SFT	данные DPO	лора(префикс) параметры	бенчмарк и	комментарий
10	завершено	Qwen2-VL-7B-Instruct	"ocra_ru_mtsai_50k", "gusev", "spellcheck_benchmark", "ocra_ru_summary_mtsai_50k", "gsm8k-ru", "samsum_ru",		"lora": { "r": 32, "lora_alpha": 32, "target_modules": : ["q_proj", "v_proj", "k_proj", "o_proj", "gate_proj", "up_proj", "down_proj"], "bias": "none", "lora_dropout": 0.05, "task_type": "CAUSAL_LM", "use_dora": false, "init_lora_weights": ": "gaussian" }, num_virtual_tokens=20 учим текст декодер внимание + mlp	LLamaBench 52.94/39.71 LlamaBenchRU 24.59/21.88 gpt: 55.38/37.31 claude:60.94/40.3	полный пайпани, без визуальных данных

id	статус	модель	данные SFT	данные DPO	лора(префикс) параметры	бенчмарк и	комментарий
11	завершено	Qwen2-VL-7B-Instruct	"ocra_ru_mtsai_50k", "gusev", "spellcheck_benchmark", "ocra_ru_summary_mtsai_50k", "gsm8k-ru", "samsum_ru",		"lora": { "r": 32, "lora_alpha": 32, "target_modules": : ["q_proj", "v_proj", "k_proj", "o_proj",], "bias": "none", "lora_dropout": 0.05, "task_type": "CAUSAL_LM", "use_dora": false, "init_lora_weights": ": "gaussian" }, num_virtual_tokens=20 учим только текст декодер внимание	LLamaBench 47.14/39.13 LlamaBenchRU 24.59/22.22 gpt: 56.25 / 40.3 claude: 69.23/40.9	

id	статус	модель	данные SFT	данные DPO	лора(префикс) параметры	бенчмарк и	комментарий
12	завершено	Qwen2-VL-7B-Instruct	"ocra_ru_mtsai_50k", "gusev", "spellcheck_benchmark", "ocra_ru_summary_mtsai_50k", "gsm8k-ru", "samsum_ru" "GQA", "optic_QA_pdf_russian_distill", "text_meme_distill"		"lora": { "r": 32, "lora_alpha": 32, "target_modules": ["q_proj", "v_proj", "k_proj", "o_proj", "gate_proj", "up_proj", "down_proj"], "bias": "none", "lora_dropout": 0.05, "task_type": "CAUSAL_LM", "use_dora": false, "init_lora_weights": "gaussian" }, num_virtual_tokens=20 учим все: проджектор текст декодер	LLamaBench 44.93/40.0 LlamaBenchRU 24.59/22.22 gpt: 59.38/36.36 claude: 62.5/39.39	полный пайпани с картинками, сравнение с пунктом 1

id	статус	модель	данные SFT	данные DPO	лора(префикс) параметры	бенчмарк и	комментарий
13	завершено	Qwen2.5-VL-3B-Instruct	"LLaVA_Instruct_ru"		<pre> "lora": { "r": 16, "lora_alpha": 16, "target_modules" : ["q_proj", "v_proj", "k_proj", "o_proj"], "bias": "none", "lora_dropout": 0.05, "task_type": "CAUSAL_LM" }, lora merger + text </pre>	LLamaBench 38.1/29.85 LlamaBenchRU 8.33/11.11 gpt: 41.27 / 31.75 claude: 43.75/31.75	

id	статус	модель	данные SFT	данные DPO	лора(префикс) параметры	бенчмарк и	комментарий
14	завершено	Qwen2.5-VL-3B-Instruct	"LLaVA_Instruct_ru"		<pre> "lora": { "r": 16, "lora_alpha": 16, "target_modules" : ["q_proj", "v_proj", "k_proj", "o_proj"], "bias": "none", "lora_dropout": 0.05, "task_type": "CAUSAL_LM" }, lora visual + merger + text </pre>	LLamaBench 40.62/28.36 LlamaBenchRU 6.9/11.48 gpt: 40.62/28.57 claude: 45.16/32.26	

id	статус	модель	данные SFT	данные DPO	лора(префикс) параметры	бенчмарк и	комментарий
16	нужны подготовительные работы по данным	Qwen2.5-VL-3B-Instruct	"LLaVA_Instruct_ru" + какие-то хорошие данные		"lora": { "r": 256, "lora_alpha": 256, "target_modules" : ["q_proj", "v_proj", "k_proj", "o_proj"], "bias": "none", "lora_dropout": 0.05, "task_type": "CAUSAL_LM" }, lora visual + merger + text		
17	завершено	Qwen2.5-VL-3B-Instruct	"xgqa" - параллельные данные		"lora": { "r": 16, "lora_alpha": 16, "target_modules" : ["q_proj", "v_proj", "k_proj", "o_proj"], "bias": "none", "lora_dropout": 0.05, "task_type": "CAUSAL_LM" }, lora merger + text	LLaMA-Bench 54.69 / 45.16 Llama-BenchRU 30.0 / 23.33 gpt: 60.94/49.18 claude: 64.62/55.74	

id	статус	модель	данные SFT	данные DPO	лора(префикс) параметры	бенчмарк и	комментарий
18	завершено	Qwen2.5-VL-3B-Instruct	"xgqa" - разные данные		<pre> "lora": { "r": 16, "lora_alpha": 16, "target_modules": ["q_proj", "v_proj", "k_proj", "o_proj"], "bias": "none", "lora_dropout": 0.05, "task_type": "CAUSAL_LM" }, lora merger + text </pre>	LLamaBench 50.0/43.75 LlamaBenchRU 16.95/16.39 gpt: 57.81/44.26 claude: 61.9 /47.54	
19	завершено	Qwen2.5-VL-3B-Instruct	"GQA", "optic_QA_pdf_russian_distill", "text_meme_distill"		<pre> "lora": { "r": 16, "lora_alpha": 16, "target_modules": ["q_proj", "v_proj", "k_proj", "o_proj"], "bias": "none", "lora_dropout": 0.05, "task_type": "CAUSAL_LM" }, lora merger + text </pre>	LLamaBench 57.35/53.73 LlamaBenchRU 41.38/26.23 gpt: 67.19/52.38 claude: 69.7/57.38	

id	статус	модель	данные SFT	данные DPO	лора(префикс) параметры	бенчмарк и	комментарий
20	завершено	Qwen2-VL-7B-Instruct	"ocra_ru_mtsai_50k", "gusev", "spellcheck_benchmark", "ocra_ru_summarizing_mtsai_50k", "gsm8k-ru", "samsum_ru" "GQA", "optic_QA_pdf_russian_distill", "text_meme_distill"		"lora": { "r": 32, "lora_alpha": 32, "target_modules": ["q_proj", "v_proj", "k_proj", "o_proj", "gate_proj", "up_proj", "down_proj"], "bias": "none", "lora_dropout": 0.05, "task_type": "CAUSAL_LM", "use_dora": false, "init_lora_weights": "gaussian" }, num_virtual_tokens=20 учим все: проджектор текст декодер	LLamaBench 47.83/36.36 LlamaBenchRU 20.97/17.19 gpt: 47.62 / 29.85 claude: 53.97/40.3	с системным промптом, обученная итерация от 12

id	статус	модель	данные SFT	данные DPO	лора(префикс) параметры	бенчмарк и	комментарий
21	завершено	Qwen2-VL-7B-Instruct	"ocra_ru_mtsai_50k", "gusev", "spellcheck_benchmark", "ocra_ru_summary_mtsai_50k", "gsm8k-ru", "samsum_ru" "GQA", "optic_QA_pdf_russian_distill", "text_meme_distill" "xgqa_distill"		"lora": { "r": 32, "lora_alpha": 32, "target_modules": ["q_proj", "v_proj", "k_proj", "o_proj", "gate_proj", "up_proj", "down_proj" "mlp.0", "mlp.2"], "bias": "none", "lora_dropout": 0.05, "task_type": "CAUSAL_LM", "use_dora": false, "init_lora_weights": "gaussian" }, num_virtual_tokens=20 учим все: визуал проджектор текст декодер	LLamaBench 44.29/39.71 LlamaBenchRU 27.42/18.75 gpt: 60.0/35.82 claude: 69.23/40.91	

id	статус	модель	данные SFT	данные DPO	лора(префикс) параметры	бенчмарк и	комментарий
22	завершено	Qwen2.5-VL-3B-Instruct	"GQA", "optic_QA_pdf_russian_distill", "text_meme_distill" "xgqa_distill" не полное		"lora": { "r": 16, "lora_alpha": 16, "target_modules": ["q_proj", "v_proj", "k_proj", "o_proj"], "bias": "none", "lora_dropout": 0.05, "task_type": "CAUSAL_LM" }, lora merger + text	LLamaBench 56.06/46.15 LlamaBenchRU 33.9/33.9 gpt: 70.31/57.14 claude: 67.19/58.06	
23	оценивается	Qwen2.5-VL-3B-Instruct	"GQA", "optic_QA_pdf_russian_distill", "text_meme_distill" "xgqa_distill" полное		"lora": { "r": 16, "lora_alpha": 16, "target_modules": ["q_proj", "v_proj", "k_proj", "o_proj"], "bias": "none", "lora_dropout": 0.05, "task_type": "CAUSAL_LM" }, lora merger + text	LLamaBench 58.82/50.0 LlamaBenchRU 32.79/32.26 gpt: 66.13/55.56 claude: 70.31/62.3	

id	статус	модель	данные SFT	данные DPO	лора(префикс) параметры	бенчмарк и	комментарий
24	оценивается	Qwen2.5-VL-7B-Instruct	"GQA", "optic_QA_pdf_russian_distill", "text_meme_distill" "xgqa_distill" полное		"lora": { "r": 16, "lora_alpha": 16, "target_modules": ["q_proj", "v_proj", "k_proj", "o_proj"], "bias": "none", "lora_dropout": 0.05, "task_type": "CAUSAL_LM" }, lora merger + text	LLamaBench 63.64/62.12 LlamaBenchRU 56.67/50.79 gpt: 82.26/79.03 claude: 85.25/75.41	
25	завершено	Qwen2.5-VL-3B-Instruct	"GQA", "optic_QA_pdf_russian_distill", "text_meme_distill" "xgqa_distill" не полное		"lora": { "r": 16, "lora_alpha": 16, "target_modules": ["q_proj", "v_proj", "k_proj", "o_proj"], "bias": "none", "lora_dropout": 0.05, "task_type": "CAUSAL_LM" }, lora merger + text	LLamaBench 60.29/53.85 LlamaBenchRU 26.32/23.73 gpt: 66.67/61.29 claude: 75.81/57.38	выбрасывание больших градиентов 5%

id	статус	модель	данные SFT	данные DPO	лора(префикс) параметры	бенчмарк и	комментарий
26	завершено	Qwen2.5-VL-3B-Instruct	"GQA", "optic_QA_pdf_russian_distill", "text_meme_distill"		"lora": { "r": 16, "lora_alpha": 16, "target_modules": ["q_proj", "v_proj", "k_proj", "o_proj"], "bias": "none", "lora_dropout": 0.05, "task_type": "CAUSAL_LM" }, lora merger + text	LLaMaBench 55.88/49.25 LlamaBenchRU 29.31/15.0 gpt: 59.38/50.0 claude: 61.54/53.23	выбрасывание больших градиентов 5%
27	завершено	Qwen2.5-VL-3B-Instruct		"0x7o/fialka-v2-dpo", "0x7o/oasst-ru-dpo-v1-rm", "argilla/distilabel-math-preference-dpo", "argilla/dpo-mix-7k", "llamafactory/RLHF-V"		LLaMaBench 38.81/37.31 LlamaBenchRU 16.67/16.13 gpt: 47.69/36.51 claude: 49.23/0	DPO

id	статус	модель	данные SFT	данные DPO	лора(префикс) параметры	бенчмарк и	комментарий
28	завершено	Qwen2.5-VL-3B-Instruct		"llamafactory/RLHF-V"		LLaMaBench 45.45/40.91 LlamaBenchRU 18.64/13.33 gpt: 47.69/37.1 claude: 50.0/40.32	DPO


6.4 Анализ задержки запуска Flow в Langflow



Контекст

Между нажатием кнопки для запуска пайплайна в UI и началом фактического выполнения компонентов на бэкенде наблюдается задержка 10+ секунд. Ниже представлен детальный анализ причин и предложения по оптимизации.

6.4.1 Общая схема выполнения



выполнение

```
8c. graph.initialize_run()
8d. sort_vertices()
8e. Кэширование графа
9. Событие on_vertices_sorted
10. build_vertices() -
```

6.4.2 Выявленные проблемы

6.4.2.1 1. Граф пересоздаётся с нуля при каждом запуске

Оценка влияния: примерно 2–5 секунд на запуск

Где смотреть:

- функция `build_graph_and_get_order()`
- функция `build_graph_from_db()`

Описание:

При каждом нажатии кнопки запуска вызывается цепочка:

```
build_graph_and_get_order() → create_graph() → build_graph_from_db() →
build_graph_from_db_no_cache() → build_graph_from_data() →
Graph.from_payload()
```

Кэш (`chat_service.set_cache`) записывается **после** построения графа, но **никогда не проверяется перед построением**. То есть даже для неизменённого flow граф строится заново каждый раз.

Это включает:

- Deep copy JSON-данных flow
- Создание объектов Vertex для всех узлов
- Создание и валидация объектов Edge
- Инстанцирование компонентов
- Топологическая сортировка

Предложения по решению:

1. Реализовать проверку кэша перед построением графа. В

`build_graph_and_get_order()` перед вызовом `create_graph()` проверять, существует ли в `chat_service` валидный кэшированный граф для данного `flow_id`. Использовать хеш `flow.data` (или `flow.updated_at`) для инвалидации.

2. **Инкрементальное обновление графа.** Метод `Graph.update()` (`base.py:1199`) уже существует и позволяет сравнивать вершины. Можно использовать его для обновления только изменённых узлов вместо пересоздания всего графа.
3. **Добавить версионирование flow.** При сохранении flow записывать хеш данных. При запуске сравнивать хеш - если не изменился, использовать кэшированный граф.

6.4.2.2 2. Deep copy всех данных flow

Оценка влияния: 100–500 мс

Где смотреть:

- `utils.py:87`

Описание:

```
def process_flow(flow_object):
    cloned_flow = copy.deepcopy(flow_object) # <-- полная глубокая копия
    ...
```

Функция `process_flow()` выполняет `copy.deepcopy` всей JSON-структуры flow, включающей все узлы, рёбра, шаблоны и параметры. Для сложных флоу с 20+ компонентами и объёмными шаблонами это может занимать сотни миллисекунд.

Предложения по решению:

1. **Заменить `deep copy` на `shallow copy` с точечным копированием.** Выполнять `deep copy` только для тех узлов, которые реально модифицируются в `process_node()` (узлы с вложенными flow/группами). Остальные узлы копировать поверхностно.
2. **Оптимизировать через `msgspec` или `orjson`.** Сериализация + десериализация через быструю библиотеку может быть быстрее, чем `copy.deepcopy` для больших структур.
3. **Выполнять `process_flow` один раз при сохранении flow,** а не при каждом запуске. Сохранять «развёрнутый» (`ungrouped`) вариант flow в БД.

6.4.2.3 3. Последовательное инстанцирование компонентов

Оценка влияния: примерно 500–3000 мс

Где смотреть:

- функция `_instantiate_components_in_vertice`

Описание:

```
def _instantiate_components_in_vertices(self) -> None:
    for vertex in self.vertices:
        vertex.instantiate_component(self.user_id)
```

Для каждой вершины последовательно вызывается `instantiate_component()`, который:

- Извлекает код компонента из параметров
- Вызывает `eval_custom_component_code(code)` - компиляция Python-кода
- Создает экземпляр класса компонента с параметрами

Для флюо с N компонентами это N последовательных вызовов `eval` + создание объекта.

Предложения по решению:

1. **Кэширование скомпилированных классов компонентов.** Результат `eval_custom_component_code(code)` - это класс Python. Можно кэшировать его по хешу исходного кода, чтобы не перекомпилировать при каждом запуске.
2. **Параллельное инстанцирование.** Если между компонентами нет зависимостей на этапе инстанцирования (а их нет - зависимости разрешаются позже при `build`), можно использовать `concurrent.futures.ThreadPoolExecutor` для параллельного создания (будет сложность при интеграции решения с Celery).
3. **Предварительная компиляция при загрузке компонентов.** При регистрации компонента в системе компилировать код один раз и сохранять объект класса в реестре.

6.4.2.4 4. Двухфазный HTTP-запрос на фронтенде

Оценка влияния: 100–300 мс

Где смотреть:

- - `src/frontend/src/utils/buildUtils.ts`
- - `src/frontend/src/stores/flowStore.ts`

Описание:

Фронтенд выполняет два последовательных HTTP-запроса:

1. `{{POST /build/`

Unknown macro: {flowId}

`/flow}} → получение job_id`

2. `{{GET /build/`

Unknown macro: {jobId}

`/events}}` → открытие streaming-соединения

Второй запрос может начаться только после завершения первого, что добавляет полный HTTP round-trip.

Предложения по решению:

1. **Использовать режим DIRECT.** В этом режиме (`EventDeliveryType.DIRECT`) POST-запрос сразу возвращает streaming-ответ, без промежуточного `job_id` . Уже реализовано в коде, но не используется по умолчанию.
2. **WebSocket-соединение.** Заменить HTTP-запросы на постоянное WebSocket-соединение для обмена событиями. Это исключит overhead на установку соединения.
3. **Параллельная инициализация.** Начинать подготовку streaming-соединения одновременно с отправкой POST-запроса, подключаясь к очереди событий сразу после получения `job_id` .

6.4.2.5 5. Загрузка flow из БД (большой JSON-блоч)

Оценка влияния: 50–200 мс

Где смотреть:

- функция `build_graph_from_db_no_cache`

Описание:

```
async def build_graph_from_db_no_cache(flow_id, session, **kwargs):
    flow = await session.get(Flow, flow_id) # <-- весь flow.data
    загружается
```

Вся структура flow (узлы, рёбра, шаблоны, параметры) хранится как единый JSON-блоч в поле `flow.data` . Для сложных flow это может быть десятки-сотни килобайт данных.

Предложения по решению:

1. **Кэширование flow.data в памяти.** Использовать in-memory кэш (например, `cachetools.TTLCache`) для хранения данных flow, инвалидируя по `flow.updated_at` .
2. **Сжатие данных flow.** Хранить `flow.data` в сжатом виде (gzip/zstd) в БД, распаковывать при чтении. Это уменьшит I/O и время передачи.

6.4.2.6 6. Инициализация сервиса трассировки

Оценка влияния: 0–500 мс (зависит от конфигурации)

Где смотреть:

- функция `initialize_run`

Описание:

```
async def initialize_run(self) -> None:
    if self.tracing_service:
        await self.tracing_service.start_tracers(
            run_id=uuid.UUID(self._run_id),
            run_name=run_name,
            user_id=self.user_id,
            session_id=self.session_id,
        )
```

При каждом запуске инициализируются трассировщики (LangSmith, LangWatch и т.д.), что может включать сетевые вызовы к внешним сервисам.

Предложения по решению:

1. **Ленивая инициализация трассировщиков.** Устанавливать соединение с внешним сервисом трассировки один раз при старте приложения, а не при каждом запуске flow.
2. **Асинхронная инициализация в фоне.** Запускать `start_tracers()` как фоновую задачу, не блокируя основной пайплайн выполнения.

6.5 Как работают связи компонентов в воркфлоу Langflow и почему они ломаются при обновлении версии

6.5.1 1. Как устроены связи компонентов

6.5.1.1 1.1 Модель данных

Каждая связь между двумя компонентами - это **edge**, который хранится как JSON. Edge содержит сериализованные метаданные "handle" для source (выход) и target (вход).

Source handle (правая сторона, выход компонента):

```
{
  "dataType": "ChatOpenAI",          // тип компонента
  "id": "abc-123",                   // ID ноды
  "output_types": ["Message"],       // типы выхода
  "name": "response"                 // имя порта
  // также: baseClasses (legacy), conditionalPath (условный роутинг)
}
```

Target handle (левая сторона, вход компонента):

```
{
  "type": "str",                     // тип поля
  "fieldName": "input_value",        // имя поля в template
  "id": "def-456",                   // ID ноды
  "inputTypes": ["Message"]          // какие типы принимает
  // также: output_types (для loop), proxy, name
}
```

Эти handle сериализуются в строку через специальную функцию `scapedJSONStringfy`, которая заменяет кавычки на символ "oe" чтобы не конфликтовать с атрибутами React Flow.

6.5.1.2 1.2 Что хранится в ноде

Каждая нода хранит полный снимок определения компонента на момент сохранения:

- **data.node.template** - словарь входных полей (type, input_types, value, show, advanced и т.д.)
- **data.node.outputs** - массив выходов (name, types, method, selected, display_name)
- **data.node.template.code.value** - Python-код компонента на момент сохранения
- **data.type** - тип компонента (например "ChatOpenAI")
- **data.selected_output** - какой выходной порт сейчас выбран

6.5.1.3 1.3 Хранение в базе данных

Flow хранится в таблице `flow` как JSON-колонка:

```
# src/backend/base/langflow/services/database/models/flow/model.py
class Flow(FlowBase, table=True):
    id: UUID
    data: dict | None = Field(sa_column=Column(JSON)) # {"nodes": [...], "edges": [...]}
    user_id: UUID | None
    name: str
    # + folder_id, tags, locked, endpoint_name и другие поля
```

Поле `data` содержит полный граф - ноды и связи в виде JSON-снимка. Никакой нормализации - бэкенд хранит ровно то, что прислал фронтенд.

6.5.1.4 1.4 Создание связи на фронтенде

Когда пользователь тянет от одного handle к другому:

1. Срабатывает **onConnect()** в flowStore.ts (строка ~568)
2. **isValidConnection()** в reactflowUtils.ts (строка ~370) проверяет совместимость типов:
 - inputTypes таргета должны пересекаться с output_types источника
 - у таргета еще нет связи (если не list и не loop)
 - связь не создает цикл (если не loop-компонент)
3. Создается edge с сериализованными handle в строках sourceHandle/targetHandle и объектах data.sourceHandle/data.targetHandle
4. Edge добавляется в состояние React Flow

6.5.1.5 1.5 Последовательность загрузки flow

Когда пользователь открывает flow, происходит следующее:

1. GET /api/v1/flows/{flow_id}
Бэкенд читает Flow из БД, возвращает сырой JSON без обработки
Файл: src/backend/base/langflow/api/v1/flows.py:280
2. Фронтенд useGetFlow() получает ответ, вызывает processFlows()
Файл: src/frontend/src/controllers/API/queries/flows/use-get-flow.ts:27
3. processFlows() вызывает processDataFromFlow()
Файл: src/frontend/src/utils/reactflowUtils.ts:508-534
4. processDataFromFlow() запускает по порядку:
 - a. processFlowEdges(flow) – миграция старых форматов handle
 - b. processFlowNodes(flow) – миграция старых форматов output
 - c. updateEdges() – добавление анимации
 - d. updateIds() – обновление ID нод
 Файл: src/frontend/src/utils/reactflowUtils.ts:540-560
5. setCurrentFlow() вызывает resetFlow()
Файл: src/frontend/src/stores/flowsManagerStore.ts:37-43
6. resetFlow() запускает:
 - a. detectBrokenEdgesEdges() – генерирует алерты о сломанных связях
 - b. cleanEdges() – валидирует ВСЕ edge-и и удаляет невалидные
 - c. updateComponentsToUpdate() – определяет устаревшие компоненты
 - d. Записывает очищенные edges + nodes в Zustand store
 Файл: src/frontend/src/stores/flowStore.ts:212-246
7. React рендерит канвас с очищенными edge-ами

Важно: бэкенд НЕ делает никакой валидации при отдаче flow. Он возвращает сырой JSON из базы. Вся валидация связей происходит на фронтенде.

6.5.1.6 1.6 Валидация на фронтенде - cleanEdges()

Файл: [src/frontend/src/utils/reactflowUtils.ts:76-177](#)

Это основная функция валидации связей. Для каждого edge она делает:

Проверка target handle (строки 91-134):

1. Парсит сохраненную строку targetHandle обратно в объект
2. Ищет fieldName в текущем template целевой ноды
3. Читает текущие type и inputTypes из поля template
4. Собирает "ожидаемый" handle ID из текущего состояния ноды
5. Сериализует его через scrapedJSONStringfy()
6. **Сравнивает строки - если отличаются, edge удаляется**

Проверка source handle (строки 136-171):

1. Парсит сохраненную строку sourceHandle
2. Ищет output по selected_output или по имени в sourceNode.data.node.outputs
3. Читает текущие types из найденного output
4. Собирает "ожидаемый" source handle ID
5. **Сравнивает строки - если отличаются или output не найден, edge удаляется**

Проверка скрытых полей (строка 174, определение строки 218-236):

- Если у поля show === false, edge удаляется

Проверка tool_mode (строка 131):

- Если у ноды tool_mode и поле isToolMode, edge удаляется независимо от совпадения строк

Удаление advanced полей (строки 179-211):

- Отдельная функция clearHandlesFromAdvancedFields() удаляет edge-и к полям с advanced === true
- Вызывается при изменении данных компонента, не при загрузке flow

6.5.1.7 1.7 Валидация на бэкенде

При сборке/запуске flow бэкенд создает объект Graph (graph/graph/base.py) и для каждой связи создает объект Edge.

Файл: [src/backend/base/langflow/graph/edge/base.py:84-109](#)

```
def _validate_handles(self, source, target):
    if self.target_handle.input_types is None:
        self.valid_handles = self.target_handle.type in
self.source_handle.output_types
    elif self.target_handle.type is None:
        # Loop edge - проверка пересечения output_types и input_types
        self.valid_handles = bool(self.source_handle.output_types) and (
            not self.target_handle.input_types
            or any(t in self.target_handle.input_types for t in
self.source_handle.output_types)
        )
```

```

elif self.source_handle.output_types is not None:
    self.valid_handles = (
        any(t in self.target_handle.input_types for t in
self.source_handle.output_types)
        or self.target_handle.type in self.source_handle.output_types
    )
if not self.valid_handles:
    raise ValueError(...)

```

Бэкенд валидирует по текущим определениям компонентов из кода, а не по сохраненным в flow данным. Если типы изменились - ValueError и flow не запускается.

6.5.1.8 1.8 Система шаблонов и определение устаревших компонентов

При старте приложения фронтенд загружает все определения компонентов с бэкенда и кладет в `useTypesStore`:

Файл: <src/frontend/src/stores/typesStore.ts>

```

setTypes: (data) => {
  set((old) => ({
    types: typesGenerator(data),
    data: { ...old.data, ...data },
    ComponentFields: extractFieldsFromComponents({ ...old.data, ...data }),
    templates: templatesGenerator(data),
  }));
}

```

Поле `templates` содержит "эталонные" определения компонентов из текущей версии Langflow.

Файл: <src/frontend/src/CustomNodes/helpers/check-code-validity.ts>:53-81

`checkCodeValidity()` сравнивает:

- Код компонента в ноде vs код в эталонном шаблоне
- Если код отличается - компонент "устаревший"
- Если изменились outputs, ключи template или input_types - это "breaking change"

Эта проверка кормит UI-уведомление "Updates available".

6.5.2 2. Где ломается при обновлении

6.5.2.1 2.1 Сценарий обновления

1. Клиент работает на Langflow v1, flow-ы сохранены в базе
2. Деплоится новый Docker-образ с Langflow v2
3. Бэкенд начинает отдавать шаблоны компонентов v2 (новый код, возможно другие inputs/outputs/types)
4. Пользователь открывает свой flow
5. Фронтенд получает старые ноды из БД, но useTypesStore уже имеет шаблоны v2

6. cleanEdges() запускается на старых данных нод - edge-и удаляются
7. Auto-save сохраняет flow без edge-ей обратно в базу

6.5.2.2 2.2 Точка отказа 1 - строковое сравнение в cleanEdges()

Файл: [src/frontend/src/utils/reactflowUtils.ts:129-134, 165-166](#)

cleanEdges() собирает "ожидаемый" handle ID из текущего состояния ноды и сравнивает посимвольно с сохраненной строкой:

```
if (scapedJSONStringfy(id) !== targetHandle) {
  newEdges = newEdges.filter((e) => e.id !== edge.id); // edge удален
}
```

Сравнение ломается когда **любое** свойство в handle изменилось, даже если связь все еще валидна по типам:

- input_types массив получил новый элемент или потерял старый
- type поля переименовано (например "str" на "text")
- output_types изменили порядок или содержимое
- fieldName переименовано в новой версии компонента

6.5.2.3 2.3 Точка отказа 2 - output не найден по имени

Файл: [src/frontend/src/utils/reactflowUtils.ts:140-170](#)

Для source handle cleanEdges() ищет output в sourceNode.data.node.outputs по имени:

```
const output =
  sourceNode.data.node!.outputs?.find(
    (output) => output.name === sourceNode.data.selected_output,
  ) ??
  sourceNode.data.node!.outputs?.find(
    (output) =>
      (output.selected || ...) && output.name === name,
  );
```

Если output переименовали между версиями, или selected_output ссылается на удаленный output - совпадение не найдено и **все edge-и от этого компонента удаляются** (строка 169).

6.5.2.4 2.4 Точка отказа 3 - несовпадение output_types в сериализованном handle

Сохраненный edge кодирует output_types на момент создания связи:

```
{"dataType": "ChatOpenAI", "id": "abc123", "output_types": ["Message"], "name": "response"}
```

Если в новой версии тип выхода изменился с ["Message" \(see page 70\)](#) на ["Data" \(see page 70\)](#), собранный handle ID будет содержать ["Data" \(see page 70\)](#), а сохраненный edge все еще ["Message" \(see page 70\)](#) - строки не совпадают - edge удален.

6.5.2.5 2.5 Точка отказа 4 - скрытые поля удаляют edge-и

Файл: [src/frontend/src/utils/reactflowUtils.ts:218-236](#)

```
if (nodeTemplates[fieldName]?.show === false) {
  newEdges = newEdges.filter((e) => e.id !== edge.id);
}
```

Если обновление шаблона меняет show на false (поле стало внутренним/advanced), edge-и к этому полю удаляются - хотя поле все еще существует.

6.5.2.6 2.6 Точка отказа 5 - валидация на бэкенде при запуске

Файл: [src/backend/base/langflow/graph/edge/base.py:84-109](#)

Даже если edge-и выжили на фронтенде, бэкенд валидирует их по текущим определениям компонентов при сборке графа. Несовпадение типов - ValueError и flow не работает.

6.5.2.7 2.7 Почему это тихо

- cleanEdges() удаляет edge-и без уведомления пользователя
- detectBrokenEdgesEdges() запускается до cleanEdges() и показывает UI-алерты через useAlertStore, но у нее другая логика поиска source output (см. Бар 4) - поэтому cleanEdges() может удалить edge-и, которые detectBrokenEdgesEdges() не заметила
- Проверка tool_mode в cleanEdges() вообще не имеет аналога в detectBrokenEdgesEdges()
- Пользователь просто открывает flow и видит что связей нет

6.5.2.8 2.8 Почему это необратимо

После того как resetFlow() удалил edge-и, auto-save записывает flow без связей обратно в базу. Оригинальный flow с edge-ами потерян. Восстановить можно только из бэкапа базы.

6.5.3 3. Найденные баги

6.5.3.1 Баг 1: cleanEdges() сравнивает строки вместо проверки совместимости типов

Файлы: src/frontend/src/utils/reactflowUtils.ts:129-134, 165-166

Проблема: Функция сериализует "ожидаемый" handle из текущего состояния ноды и сравнивает строку с сохраненной. Любое изменение inputTypes, type или output_types ломает совпадение, даже если связь все еще валидна по типам.

Пример: Новая версия добавляет тип в input_types ("[Message](#)" ([see page 70](#)) на "[Message](#)", "[Data](#)" ([see page 70](#))). Связь все еще валидна - Message как принимался, так и принимается. Но строки разные - edge удален.

Корневая причина: Используется строковое сравнение (scapedJSONStringfy(id) !== targetHandle) вместо проверки пересечения типов.

Направление фикса: Заменить строковое сравнение на семантическую валидацию - проверять что output_types источника пересекаются с input_types таргета.

6.5.3.2 Баг 2: шаблоны не обновляются до очистки edge-ей

Файлы: src/frontend/src/stores/flowStore.ts:212-246

Проблема: Последовательность при загрузке flow:

1. Загрузить старые ноды из БД (с устаревшими данными шаблона)
2. Запустить cleanEdges() на этих старых нодах
3. Запустить updateComponentsToUpdate() для определения устаревших компонентов

Но cleanEdges() валидирует edge-и по сохраненным данным нод, в которых старые input_types, output_types, type. Ноды еще не согласованы с новыми шаблонами. При этом processFlowNodes/processFlowEdges могли частично обновить данные, создавая рассогласование между handle в edge-ах и данными в нодах.

Корневая причина: Очистка edge-ей запускается до согласования шаблонов. updateComponentsToUpdate() (который определяет изменения) выполняется после того как cleanEdges() уже удалил edge-и.

Направление фикса: Либо согласовывать шаблоны нод до очистки edge-ей, либо откладывать очистку до момента когда пользователь явно обновит компоненты.

6.5.3.3 Баг 3: auto-save делает потерю edge-ей необратимой

Файлы: src/frontend/src/stores/flowStore.ts:212-246, механизм auto-save

Проблема: После того как resetFlow() удалил edge-и, очищенное состояние flow записывается в Zustand store. Auto-save затем сохраняет это состояние в базу. Оригинальный flow с edge-ами потерян навсегда.

Влияние: Пользователи не могут восстановить связи без бэкапа базы.

Направление фикса: Не запускать auto-save сразу после загрузки flow. Или: сохранять оригинальные данные flow до очистки и дать возможность восстановления. Или: спрашивать пользователя перед удалением edge-ей и сохранением.

6.5.3.4 Бар 4: detectBrokenEdgesEdges() и cleanEdges() по-разному ищут source output

Файлы: src/frontend/src/utils/reactflowUtils.ts:238+ vs src/frontend/src/utils/reactflowUtils.ts:76-177

Проблема: Обе функции используют одинаковое строковое сравнение для target handle. Но для source handle они работают по-разному:

- cleanEdges() (строки 141-152) сначала ищет по selected_output, потом fallback по name с доп. условиями (output.selected или единственный не-grouped output)
- detectBrokenEdgesEdges() (строки 334-336) просто ищет по name: outputs?.find((output) => output.name === name)

Плюс cleanEdges() имеет проверку tool_mode (строка 131), которая удаляет edge-и независимо от совпадения строк - а в detectBrokenEdgesEdges() такой проверки нет.

Из-за этого edge-и могут быть удалены cleanEdges() без появления в алерте - конкретно когда:

- selected_output находит другой output, чем detectBrokenEdgesEdges() находит по name
- tool_mode удаляет edge, а detectBrokenEdgesEdges() это не ловит

Направление фикса: Вынести логику валидации в одну общую функцию, чтобы все edge-и, которые cleanEdges() удалит, сначала попадали в алерт.

6.5.3.5 Бар 5: selected_output ссылается на удаленный output

Файлы: src/frontend/src/utils/reactflowUtils.ts:141-152, src/backend/base/langflow/custom/custom_component/component.py

Проблема: Если outputs компонента изменились между версиями (output переименован или удален), а в сохраненной ноте selected_output все еще указывает на старое имя - поиск в cleanEdges() не находит output:

```
const output = sourceNode.data.node!.outputs?.find(
  (output) => output.name === sourceNode.data.selected_output, // старое имя - не
  найдено
) ?? sourceNode.data.node!.outputs?.find(/* fallback тоже не сработает */);
```

Когда output не найден - **все edge-и от этого компонента удаляются** (строка 169).

На бэкенде component.py тоже валидирует selected_output против _outputs_map и кидает ValueError если output не существует.

Направление фикса: Когда selected_output не найден - фолбэчить на первый доступный output вместо удаления всех edge-ей. Или: мигрировать selected_output при согласовании шаблонов.

6.6 Компоненты LLMOps

6.7 Описание требований и архитектуры

6.7.1 Копия Stack [AS IS]

Дата актуализации	25.02.25
-------------------	----------

6.7.1.1 Текущий стек реализуется компонентами:

Components	Functionality	License	Link
LiteLLM	LLM and AI Tools	License-1.0	https://github.com/BerriAI/litellm?tab=License-1-ov-file
LibreChat	LLM and AI Tools	MIT	https://github.com/danny-avila/LibreChat?tab=MIT-1-ov-file
Langflow	LLM and AI Tools	MIT	https://github.com/langflow-ai/langflow
PostgreSQL	Databases and Caching	PostgreSQL License	https://opensource.org/license/postgresql
Patroni	Databases and Caching	MIT	https://github.com/patroni/patroni?tab=MIT-1-ov-file
KeyDB	Databases and Caching	BSD-3-Clause	https://github.com/Snapchat/KeyDB?tab=BSD-3-Clause-1-ov-file
MongoDB	Databases and Caching	Server Side Public License (SSPL)	https://www.mongodb.com/legal/licensing/server-side-public-license
OpenSearch	Databases and Caching	Apache-2.0	https://github.com/opensearch-project/OpenSearch?tab=Apache-2.0-1-ov-file

Components	Functionality	License	Link
VictoriaMetrics	Monitoring and Logging	Apache-2.0	https://github.com/VictoriaMetrics/VictoriaMetrics?tab=Apache-2.0-1-ov-file
Grafana	Monitoring and Logging	AGPL-3.0	https://github.com/grafana/grafana?tab=AGPL-3.0-1-ov-file
Vector	Monitoring and Logging	Apache-2.0	https://www.mozilla.org/en-US/MPL/2.0/
Alertmanager	Monitoring and Logging	Apache-2.0	https://github.com/prometheus/alertmanager?tab=Apache-2.0-1-ov-file
Blackbox_exporter	Monitoring and Logging	Apache-2.0	https://github.com/prometheus/blackbox_exporter?tab=Apache-2.0-1-ov-file
cAdvisor	Monitoring and Logging	License-1.0	https://github.com/google/cadvisor?tab=License-1-ov-file
Haproxy	Load Balancing and Proxying	License-1.0	https://github.com/haproxy/haproxy?tab=License-1-ov-file
Nginx	Load Balancing and Proxying	BSD-2-Clause	https://github.com/nginx/nginx?tab=BSD-2-Clause-1-ov-file
NSD	Networking and DNS Services	BSD-3-Clause	https://github.com/NLnetLabs/nsd/blob/master/LICENSE
Unbound	Networking and DNS Services	BSD-3-Clause	https://github.com/NLnetLabs/unbound/blob/master/LICENSE
Docker	Orchestration and Virtualization	Apache-2.0	https://github.com/docker/docker-install?tab=Apache-2.0-1-ov-file
Docker-compose	Orchestration and Virtualization	Apache-2.0	https://github.com/docker/compose?tab=Apache-2.0-1-ov-file

Components	Functionality	License	Link
Pyinfra	Infrastructure automation and server configuration management using Python	MIT	https://github.com/pyinfra-dev/pyinfra
Proxmox	Orchestration and Virtualization	AGPL-3.0	https://www.gnu.org/licenses/agpl-3.0.html
Consul	Configuration Management and High Availability	License-1.0	https://github.com/hashicorp/consul?tab=License-1-ov-file
Etc	Configuration Management and High Availability	Apache-2.0	https://github.com/etcd-io/etcd?tab=Apache-2.0-1-ov-file
Chrony	Configuration Management and High Availability	License-1.0	https://github.com/mlcivhar/chrony?tab=License-1-ov-file
Chrony_exporter	Prometheus Exporters for Metrics	Apache-2.0	https://github.com/SuperQ/chrony_exporter?tab=Apache-2.0-1-ov-file
Haproxy_exporter	Prometheus Exporters for Metrics	Apache-2.0	https://github.com/prometheus/haproxy_exporter?tab=Apache-2.0-1-ov-file
Redis_exporter	Prometheus Exporters for Metrics	MIT	https://github.com/oliver006/redis_exporter?tab=MIT-1-ov-file
Nginx_exporter	Prometheus Exporters for Metrics	Apache-2.0	https://github.com/nginxinc/nginx-prometheus-exporter?tab=Apache-2.0-1-ov-file
Node_exporter	Prometheus Exporters for Metrics	Apache-2.0	https://github.com/prometheus/node_exporter?tab=Apache-2.0-1-ov-file
NSD_exporter	Prometheus Exporters for Metrics	BSD-3-Clause	https://github.com/optix2000/nsd_exporter?tab=BSD-3-Clause-1-ov-file

Components	Functionality	License	Link
MongoDB_exporter	Prometheus Exporters for Metrics	Apache-2.0	https://github.com/percona/mongodb_exporter?tab=Apache-2.0-1-ov-file
Nvidia_gpu_exporter	Prometheus Exporters for Metrics	MIT	https://github.com/utkuozdemir/nvidia_gpu_exporter?tab=MIT-1-ov-file
Postgres_exporter	Prometheus Exporters for Metrics	Apache-2.0	https://github.com/prometheus-community/postgres_exporter?tab=Apache-2.0-1-ov-file
Unbound_exporter	Prometheus Exporters for Metrics	Apache-2.0	https://github.com/letsencrypt/unbound_exporter?tab=Apache-2.0-1-ov-file

6.7.2 Сценарии использования

6.7.2.1 Сценарии использования LibreChat [UI]

6.7.2.1.1 [Librechat.UC.01] Выбор моделей и управление параметрами - разделить!

6.7.2.1.1.1 Введение

Контекст	Платформа использует различные модели для генерации ответов. Ранее в проекте возникла необходимость разграничить «модели» и «агентов» (aka ассистенты) • Модели – сущности, отвечающие только за генерацию ответа. • Агенты (aka ассистенты) – более высокоуровневые абстракции, в которых параметры инференса зашиты хардкодом, то есть являются дефолтными. По мере развития платформы стало понятно, что конечным пользователям необходимо давать возможность гибко управлять такими параметрами, как температура, максимальная длина ответа, настройки «штрафов» и т. д.
Цель	Предоставить пользователю управляемый и прозрачный механизм выбора модели и настройки параметров инференса, при этом избежать конфликтов между существующими «агентами» и «моделями», а также унифицировать логику пресетов.

6.7.2.1.1.2 Описание проблематики

Текущее состояние	Модели: • Добавляются на платформу отдельно. • Пресеты привязаны к модели, что позволяет сохранять некоторые настройки, однако не все параметры учитываются. Агенты (ассистенты): • Параметры инференса (температура, penalty и др.) жёстко зашиты, чтобы упростить использование для конечного пользователя. • При попытке пользователя менять параметры напрямую происходят конфликты, поскольку пресеты не ожидают работу через «агента», а не напрямую через «модель». LibreChat: • Предусматривает работу с пресетами, опирающимися на понятие «модель». • При создании пресета для «агента» возникают проблемы, так как агент не ведёт себя как модель в архитектуре системы.
Примеры	
Критичность	• Уменьшает удобство для продвинутых пользователей, которым нужна гибкая настройка инференса (например, для экспериментов). • Снижает общее качество ответа моделей (при неправильных параметрах).

6.7.2.1.2 [Librechat.UC.02] Создание и использование пресета в LibreChat для регулярных типовых запросов


Цель использования	Упростить и ускорить регулярное взаимодействие с LibreChat, минимизируя повторяющиеся настройки и повышая стабильность результатов
Контекст	Пользователь регулярно обращается к LibreChat для выполнения типовых профессиональных задач. Для повышения качества и единообразия ответов он применяет заранее настроенный пресет

Пользовательские проблемы до использования пресета	- Регулярные запросы требуют повторного ручного ввода похожих настроек - Ответы часто отличаются по структуре или стилю - Отсутствует стандартизация при регулярном взаимодействии с моделью
Ценность для пользователя после применения пресета	Экономия времени: один раз настроив пресет, пользователь получает быстрый доступ к повторяющимся типовым запросам Консистентность результатов: пресет обеспечивает стабильность формата, стиля и содержания ответов Упрощение взаимодействия: минимизация ручных операций при регулярном использовании


6.7.2.1.2.1 Сценарий взаимодействия

[AS IS \[v.0.1\]](#) AS IS [v.0.1] - Schema

	Действие пользователя	Интерфейс
Описание	Пользователь регулярно обращается с типовыми запросами к LibreChat и хочет оптимизировать процесс взаимодействия, сократить время на ввод текста и обеспечить унификацию запросов за счёт заранее подготовленных шаблонов (пресетов)	
Участники	Пользователь — конечный пользователь системы LibreChat LibreChat — система интеллектуального помощника с интерфейсом для настройки и взаимодействия через пресеты	
Триггер	Пользователь решил создать новый или использовать уже существующий пресет для отправки регулярного типового запроса	
Предусловия	- Пользователь авторизован в системе LibreChat. - У пользователя есть доступ к функции создания и управления пресетами - Интерфейс LibreChat поддерживает работу с пресетами	

Постусл вия	- Запрос отправлен с использованием пресета и обработан системой - Созданный пресет сохранен в системе LibreChat и доступен для повторного использования	
Успешны й сценарий	- Пользователь выбирает функцию «Создание нового пресета» в интерфейсе LibreChat - LibreChat предлагает пользователю форму для создания нового пресета, включая поля «Название», «Описание» (необязательно), «Текст запроса» и «Параметры запроса» - Пользователь заполняет необходимые поля и сохраняет пресет - LibreChat подтверждает успешное сохранение пресета. - Для последующего использования пресета пользователь выбирает функцию «Использование существующего пресета» - Пользователь выбирает из списка нужный пресет и нажимает «Отправить запрос» - LibreChat автоматически подставляет текст и параметры пресета в окно ввода и отправляет запрос - LibreChat отображает полученный от системы ответ пользователю	
Альтерна ивный сценарий 1 Редактир ование существу ющего пресета	- Пользователь выбирает функцию «Редактирование пресетов» - Пользователь выбирает из списка пресет, который необходимо отредактировать - LibreChat отображает текущие значения пресета и предоставляет возможность внести изменения - Пользователь редактирует текст и параметры пресета и сохраняет изменения - LibreChat подтверждает успешное сохранение изменений	

Альтернативный сценарий 2 Удаление пресета	1. Пользователь выбирает функцию «Редактирование пресетов» 2. Пользователь выбирает пресет для удаления 3. LibreChat запрашивает подтверждение удаления пресета 4. Пользователь подтверждает удаление 5. LibreChat удаляет пресет из системы и отображает сообщение об успешном удалении	
---	--	--

UI-Описание	UI-Описание: Интерфейс системы LibreChat должен содержать следующие элементы для работы с пресетами: • Кастомное имя (необязательное текстовое поле) – позволяет задать уникальное имя пресета для идентификации в интерфейсе • Префикс промпта (необязательное многострочное текстовое поле) – предназначен для задания шаблонных инструкций, которые будут автоматически включаться в системные сообщения перед запросами • Максимальное количество контекстных токенов (числовое поле) – позволяет ограничивать количество токенов, учитываемых системой при формировании контекста ответа • Максимальное количество выводимых токенов (числовое поле) – задаёт ограничение для длины ответов системы • Температура (ползунок или числовое поле) – позволяет регулировать степень случайности (креативности) ответов • Топ P (ползунок или числовое поле) – регулирует диапазон вероятностей слов при генерации текста • Штраф за частоту (ползунок или числовое поле) – уменьшает вероятность повторения часто используемых слов • Штраф за присутствие (ползунок или числовое поле) – уменьшает вероятность повторения уже использованных слов • Стоп-последовательности (необязательное текстовое поле) – возможность задавать специальные фразы или символы, после которых генерация текста должна быть прекращена • Повторить отправку файлов (переключатель) – включает или отключает автоматическую повторную отправку всех ранее отправленных файлов при использовании пресета • Детали изображения (ползунок) – позволяет настроить степень детализации при обработке изображений. Низкое, высокое или авто-режим Управление и использование пресетов: • Меню выбора пресета – позволяет выбирать ранее сохранённые пресеты для быстрого использования • Кнопка «Удалить все» – позволяет удалить все ранее созданные пресеты	
--------------------	--	---

- Кнопка «Импорт» – позволяет импортировать пресеты из внешнего источника

AS IS [v.0.1] [AS IS \[v.0.1\] - Schema](#)**PlantUML 1.2025.0**

**This version of PlantUML is 449 days old, so you should
consider upgrading from <https://plantuml.com/download>**

[From string (line 19)]**@startuml****title Выбор ассистента и создание пресета****actor "Пользователь" as User****participant "Интерфейс" as UI****participant "Система" as Sys****User -> UI: 1. Открывает LibreChat****UI -> Sys: 2. Запрашивает список ассистентов (преднастроенные модели)****Sys --> UI: 3. Возвращает список ассистентов****User -> UI: 4. Выбирает ассистента****UI -> Sys: 5. Иницирует сеанс с выбранным ассистентом****Sys --> UI: 6. Подтверждает запуск чата****alt Пользователь использует предустановленные параметры****note left****Сценарий завершается****(пользователь работает с ассистентом****без изменения настроек)****end note****else Пользователь изменяет предустановленные параметры ассистента и создаёт пресет****User -> UI: 7. Открывает настройки****Syntax Error? (Assumed diagram type: sequence)**

6.7.2.1.2.2 Выявленная проблематика и решение

[Описание проблемы и решения](#) [Schema](#)**Предыстория и постановка задачи**

В ходе эксплуатации Librechat (агент) была обнаружена серия проблем, связанных с:

1. Сбросом промпта при использовании агента.
2. Потерей/некорректной передачей пресета конфигурации между клиентской и серверной частью.

После обновления компонента до версии 0.7.7 часть сбоев пропала, но проблему с передачей пресета по-прежнему требовалось решать системно.

Суть проблемы	• Сброс промпта: ранее наблюдалось, что при использования агента или при частом переключении параметров, данные (промпт) могли сбрасываться. Как выяснилось, часть этих багов была устранена при обновлении до версии 0.7.7. • Неправильное использование пресета: в ряде случаев возникала ситуация, когда настройки пользователя, хранящиеся в пресете, терялись либо не применялись при повторных обращениях со стороны UI. Оказалось, что ключевые параметры и идентификатор пресета не всегда корректно передавались в серверную часть и обратно.
Решение	1. Обновление компонента: • Обновлённая версия 0.7.7 устранила несколько внутренних ошибок, связанных со сбросом промпта 2. Передача идентификатора пресета: • Для решения проблемы с пресетом был реализован механизм, при котором идентификатор (ID) пресета всегда явно передаётся от клиентской части на сервер и затем сервер возвращает этот же идентификатор обратно • Такой подход позволил <i>однозначно</i> идентифицировать настройки, хранящиеся на сервере, и повторно их применять в нужном контексте

Технические детали реализации**Расширенный формат запроса от UI:**

- Вместо передачи отдельных параметров (без связи друг с другом) теперь в запросе от UI всегда присутствует поле `preset_id` вместе со всеми необходимыми атрибутами.
- Пример структуры:

```
{
  "preset_id": "some-unique-id",
  "params": {
    "paramA": "valueA",
    "paramB": "valueB"
  }
}
```

Обработка на стороне бэкенда:

- При получении запроса backend извлекает `preset_id` и находит соответствующие настройки (если они уже сохранены)
- После выполнения необходимых операций (валидация, применение логики, генерация ответа) backend возвращает в ответе этот же `preset_id` вместе с результирующими данными
- Обратный ответ может выглядеть так:

```
{
  "preset_id": "some-unique-id",
  "result": {
    "data": "some-calculated-result"
  }
}
```

}

Таким образом, UI всегда «узнаёт» результат, связанный именно с тем пресетом, который был отправлен

- **Возможные сценарии использования:**

- **Создание нового пресета:** UI генерирует новый `preset_id` и отправляет набор параметров на сервер, получая назад подтверждение и итоговые данные
- **Обновление существующего пресета:** UI отправляет тот же `preset_id`, а сервер модифицирует нужные параметры или сохраняет состояние
- **Переключение между пресетами:** UI может хранить несколько `preset_id` и в любой момент «активировать» нужный, гарантируя целостность конфигурации

+ UPD

Глобальные изменения:

- Добавлены пресеты для моделей при описании эндпоинтов
- Добавлены кастомные поля для моделей, используются только в UI:

- `label` - отображаемое название (строка)
- `iconURL` - ссылка на иконку (строка)
- `isOutside` - внешняя или внутренняя модель (boolean)
- Добавлен атрибут `default` для `endpoint` (boolean). Обязательно к заполнению, если скрыто меню эндпоинтов, иначе по умолчанию будет эндпоинт `openAI`

UI и UX изменения:

- Кастомное отображение моделей в меню моделей (В шапке, в настройках и в редакторе промптов)
- Кнопка сброса пресета
- Изменен `iconURL`, добавлена поддержка иконок из папки `/assets/` (актуальный список иконок здесь - <https://gitlab.services.mts.ru/LLMOps/frontend/librechat/-/tree/master/client/public/assets/models>). Для добавления можно использовать относительный путь: `iconURL: /assets/models/mts.svg`

Новый формат librechat.yaml

```

endpoints:
  custom:
    - name: 'Models' # (строка как и было)
      default: true # (новый параметр используется
для выбора эндпоинта по умолчанию)
      apiKey: '12343455' # (строка, как и было)
      baseURL: 'http://api.llmops.mts-corp.ru/v1' #
(строка, как и было)
      models:
        default: ["gpt-4", "qwen-coder-7b", "gpt-4-
turbo", "claude-3-haiku", "deepseek-coder",
"claude-3-opus", "gpt-4o", "gpt-3.5-turbo",
"claude-3-sonnet", "gpt-4o-mini", "gemini-pro",
"mts_anya", "kodify-1.0", "cotype-light-3.0", "qwen-
max", "qwen-turbo", "qwen-plus", "qwen2-7b-instruct",
"qwen2.5-vl-7b-instruct"]
        # fetch: true
        fetch: false # (конфиги работают только для
описанных моделей, поэтому лучше отключить опцию
загрузки моделей динамически и обновлять ручками)

      modelsOptions: # (новый параметр, модели
описываются как объект)
        # MTS
        mts_anya:
          label: "MTS ANYA" # (название,
отображается в меню и как название модели в чате)
          iconURL: "/assets/models/mts.svg" #
(ссылка на иконку модели, поддерживается
относительный путь)
          isOutside: false # (показывает внешняя
модель или внутренняя)
          preset: # (параметры пресета, пока
поддерживаются только эти 3)
            maxContextTokens: "128000"
            max_tokens: "4096"
            temperature: 0.3

        kodify-2.0:
          label: "Kodify 2.0"
          iconURL: "/assets/models/mts.svg"
          isOutside: false
          preset:
            maxContextTokens: "32000"
            max_tokens: "4096"
            temperature: 0.6

```

```

cotype-light-3.0:
  label: "Cotype Light 3.0"
  iconURL: "/assets/models/mts.svg"
  preset:
    maxContextTokens: "128000"
    max_tokens: "4096"
    temperature: 0.6

cotype-plus-32k:
  label: "Cotype Plus 32k"
  iconURL: "/assets/models/mts.svg"
  preset:
    maxContextTokens: "32000"
    max_tokens: "4096"
    temperature: 0.6

kodify-1.0:
  label: "Kodify 1.0 (CotypePro)"
  iconURL: "/assets/models/mts.svg"
  isOutside: false
  description: "kodify-1.0"
  preset:
    maxContextTokens: "128000"
    max_tokens: "4096"
    temperature: 0.6


```

+ UPD

```

# показывать модальку (true/false, по умолчанию false)
SHOW_EULA_MODAL=
# подпись справа в подвале
FOOTER_LABEL=
# имя компании в подвале
FOOTER_COMPANY_NAME=
# url логотипа на шаге авторизации
HEADER_LOGO_URL=
# текст рядом с логотипом на шаге авторизации
HAEDER_LABEL=

```

Описание проблемы и решения **Schema**

6.7.2.1.2.3 Librechat Schemas

[Librechat preset schema](#)

```

PlantUML 1.2025.0

<b>This version of PlantUML is 449 days old, so you should
<b>consider upgrading from https://plantuml.com/download

[From string (line 24) ]

@startuml
title Preset-schema

...
... ( skipping 144 lines )
...
skinparam backgroundColor white
skinparam actorStyle awesome
skinparam ArrowColor #2C3E50
skinparam BorderColor #2C3E50
skinparam ComponentBackgroundColor #ECF0F1
skinparam rectangleBorderThickness 1
skinparam rectangleBorderColor #95A5A6
skinparam noteBackgroundColor #FEF9E7
skinparam noteBorderColor #F39C12
actor "Пользователь" as User
note top of User
<b>Действия пользователя:</b>
1. Просмотр и выбор готовых пресетов
2. Настройка параметров нового пресета
3. Сохранение/импорт пресетов
4. Удаление отдельных пресетов или всех сразу
5. Ведение диалога с AI, используя выбранный пресет
end note
rectangle "Librechat" as UI {
  rectangle "Список пресетов" as PresetList {
    Syntax Error? (Assumed diagram type: component)
  }
}

```

6.7.2.1.3 [Librechat.UC.03] Выбор модели (ассистента) из списка

Цель использования	Предоставить пользователю возможность выбора оптимальной модели для конкретного запроса и рабочего контекста
--------------------	--

Контекст	Пользователь взаимодействует с LibreChat и нуждается в возможности быстро выбирать или менять используемую модель для конкретной задачи
Пользовательские проблемы до использования пресета	TBD
Ценность для пользователя после применения пресета	TBD

6.7.2.1.3.1 Сценарий взаимодействия

AS IS [v.0.1] TO BE []

	Действие пользователя	Интерфейс
Описание	Пользователь имеет возможность выбирать подходящую модель (ассистента) из предложенного списка в интерфейсе LibreChat для выполнения задач, соответствующих определённым требованиям по производительности, точности и специфике запросов	
Участники	• Пользователь — конечный пользователь, взаимодействующий с системой LibreChat • LibreChat — система интеллектуального помощника, предоставляющая интерфейс выбора модели из списка	
Триггер	Пользователь решил выбрать модель (ассистента) перед отправкой запроса, чтобы получить наиболее подходящий результат по качеству и специфике задачи	

Предусловия	• Пользователь авторизован и имеет доступ к функционалу выбора модели • Система LibreChat имеет в наличии список доступных моделей для выбора пользователем • Интерфейс LibreChat отображает актуальную информацию о доступных моделях	
Постусловия	• Пользователь успешно выбрал необходимую модель • Запросы пользователя направляются и обрабатываются выбранной моделью	
Успешный сценарий	1. Пользователь переходит в интерфейс выбора модели 2. LibreChat отображает список доступных моделей с указанием их названия и кратких характеристик 3. Пользователь изучает список моделей и выбирает подходящую модель 4. Пользователь подтверждает свой выбор (кликом на модель) 5. LibreChat сохраняет выбранную модель в текущей сессии (УТОЧНИТЬ ПРО АПСТРИМЫ) 6. Последующие запросы пользователя автоматически направляются выбранной модели 7. LibreChat возвращает ответы, соответствующие выбранной модели	
Альтернативный сценарий 1 Изменение модели после первичного выбора	1. Пользователь решает изменить текущую выбранную модель 2. Пользователь снова переходит в меню выбора моделей 3. LibreChat отображает список доступных моделей с текущим активным выбором 4. Пользователь выбирает другую модель 5. LibreChat переключает активную модель на новую, информирует пользователя о смене модели 6. Дальнейшие запросы пользователя обрабатываются новой моделью	

UI-Описание

Интерфейс системы LibreChat должен обеспечивать следующие элементы для выбора модели:

- **Меню или выпадающий список доступных моделей** (например, GPT-4, GPT-3.5 Turbo, Claude, Qwen, и т.д.)
- Отображение названия и краткой информации (краткое описание) рядом с каждой моделью
- Визуальное выделение активной (текущей) модели в списке
- Возможность быстрого переключения модели непосредственно перед отправкой запроса или в процессе диалога без потери контекста

AS IS [v.0.1] TO BE []

6.7.2.1.3.2 Выявленная проблематика

6.7.2.1.4 [Librechat.UC.04] Закладки (добавление/удаление чата)

Цель использования	Предоставить пользователю возможность выбора оптимальной модели для конкретного запроса и рабочего контекста
Контекст	Пользователь взаимодействует с LibreChat и нуждается в возможности быстро выбирать или менять используемую модель для конкретной задачи
Пользовательские проблемы до использования	TBD
Ценность для пользователя после применения	TBD

6.7.2.1.4.1 Сценарий взаимодействия

AS IS [v.0.1] TO BE []

	Действие пользователя	Интерфейс
Описание	Пользователь хочет сохранять важные или часто используемые диалоги (чаты) в виде закладок, чтобы быстро возвращаться к ним в будущем или удалять более ненужные закладки для эффективного управления информацией	
Участники	• Пользователь — конечный пользователь системы LibreChat • LibreChat — интеллектуальный помощник, предоставляющий функционал управления закладками чатов	
Триггер	Пользователь решил сохранить текущий чат в закладках для последующего быстрого доступа, или, наоборот, удалить чат из списка закладок	
Предусловия	• Пользователь авторизован в системе LibreChat • Пользователь ведёт или ранее вёл диалог, который хочет добавить или удалить из закладок	
Постусловия	• Чат успешно добавлен в закладки или удалён из закладок • Изменения сохранены системой LibreChat • Закладка доступна в списке/удалена из списка	
Успешный сценарий	1. Пользователь открывает чат, который хочет сохранить 2. Пользователь нажимает на иконку закладки («Добавить в закладки») 3. LibreChat подтверждает успешное добавление чата в закладки 4. Чат отображается в списке закладок и доступен для быстрого доступа	

Альтернативный сценарий Удаление чата из закладок	1. Пользователь переходит в меню или панель закладок 2. Пользователь выбирает чат, который необходимо удалить из закладок 3. Пользователь нажимает кнопку «Удалить из закладок» 4. LibreChat запрашивает подтверждение удаления чата из закладок 5. Пользователь подтверждает удаление 6. LibreChat удаляет чат из закладок и уведомляет пользователя об успешном выполнении операции	
--	---	--

UI-Описание	Интерфейс системы LibreChat для управления закладками должен содержать следующие элементы: • Кнопка «Закладки» — расположена на основной панели инструментов и открывает меню управления закладками. • Список сохранённых закладок — отображает ранее добавленные чаты с указанием их заголовков. • Кнопка «Очистить всё» — позволяет удалить сразу все сохранённые закладки. • Форма добавления закладки, содержащая следующие поля: • Заголовок (обязательное текстовое поле) — позволяет задать название закладки для удобной идентификации. • Описание (необязательное многострочное текстовое поле) — служит для добавления дополнительной информации о закладке. • Переключатель «Добавить в текущий чат» — при активации добавляет закладку непосредственно в текущий чат пользователя. • Кнопки действий формы: • «Сохранить» — для сохранения закладки в системе. • «Отмена» — для отмены создания или редактирования закладки. • Меню управления закладками с функциями: • Просмотр списка ранее созданных закладок. • Быстрый переход к сохранённым чатам. • Возможность удаления отдельных закладок. • Кнопка «Очистить всё» для удаления всех закладок одновременно с подтверждением действия во избежание случайных удалений.	
--------------------	---	--

6.7.2.1.4.2 Выявленная проблематика

6.7.2.1.5 [Librechat.UC.05] Отправка сообщения

Цель использования	Предоставить пользователю возможность выбора оптимальной модели для конкретного запроса и рабочего контекста
Контекст	Пользователь взаимодействует с LibreChat и нуждается в возможности быстро выбирать или менять используемую модель для конкретной задачи
Пользовательские проблемы до использования	TBD
Ценность для пользователя после применения	TBD

6.7.2.1.5.1 Сценарий взаимодействия


AS IS [v.0.1] TO BE []

	Действие пользователя	Интерфейс
Описание	Пользователь вводит сообщение в LibreChat и отправляет его на обработку. Система может направить запрос к одной выбранной модели ИИ или одновременно нескольким моделям. Если пользователь выбирает несколько моделей, он получает несколько ответов и может сравнить их, выбрав наиболее подходящий для дальнейшего диалога. Это обеспечивает более гибкую и точную работу с системой, позволяя пользователю протестировать разные варианты ответов и продолжить беседу по лучшему сценарию.	

Участники	• Пользователь – инициирует отправку сообщения и выбирает модель(и) для обработки • Система LibreChat – обеспечивает интерфейс для ввода сообщения, маршрутизацию запроса и отображение полученных ответов	
Триггер	Иницилирующим событием является действие пользователя – нажатие кнопки «Отправить» после ввода текста в поле ввода сообщения	
Предусловия	• Пользователь успешно аутентифицирован в системе • Соединение с сервером установлено, а система находится в рабочем состоянии • Текст сообщения прошёл базовую валидацию (не является пустым, соответствует требованиям формата)	
Постусловия	• Сообщение доставлено и отобразилось в пользовательском интерфейсе • Если применялась параллельная обработка, результаты от всех задействованных моделей агрегированы и представлены пользователю • В случае возникновения ошибок, пользователь уведомлён о неудачной отправке с указанием возможных путей исправления.	

Успешный сценарий	• Ввод сообщения: Пользователь вводит текст в поле ввода • Выбор модели(ей): Пользователь выбирает: • одну конкретную модель, или • несколько моделей для параллельной отправки (например, чтобы сравнить результаты) • Отправка запроса: Пользователь нажимает «Отправить» • Валидация: Система проверяет корректность сообщения и доступность выбранных моделей • Обработка: • Если выбрана одна модель, запрос направляется к ней, и система ожидает ответ • Если выбрано несколько моделей, запрос параллельно отправляется ко всем указанным моделям • Получение ответов: • В случае одной модели система получает единичный ответ и отображает его • При параллельной отправке система собирает ответы от всех моделей • Сравнение и выбор ответа (при параллельной отправке): • Система отображает все полученные ответы • Пользователь сравнивает варианты и выбирает лучший ответ для дальнейшего диалога • Продолжение диалога: Пользователь, при желании, может продолжить обсуждение, опираясь на выбранный ответ, либо сохранить несколько ответов для дальнейшего анализа	
---------------------------------	---	--

Альтернативный сценарий 1 Отправка параллельного запроса нескольким моделям	1. Пользователь вводит текст сообщения в поле ввода LibreChat 2. Пользователь активирует режим «Отправить нескольким моделям» («Параллельный запрос») 3. LibreChat предоставляет список доступных моделей с возможностью выбора нескольких 4. Пользователь отмечает нужные модели и отправляет запрос 5. LibreChat отправляет запрос всем выбранным моделям одновременно 6. LibreChat отображает ответы моделей отдельно, с указанием названия каждой модели 7. Пользователь сравнивает ответы и выбирает наиболее подходящий 8. Пользователь продолжает диалог с выбранным ответом, создавая ветвление диалогов	
--	---	--

UI-Описание	• Поле ввода сообщения: Текстовое поле для ввода вопроса • Список доступных моделей: • Отдельные иконки или чекбоксы для выбора одной или нескольких моделей • Кнопка «Отправить»: Запускает процесс отправки • Отображение ответов: • При отправке к одной модели – единственный ответ в списке сообщений • При параллельной отправке – блоки с ответами от каждой модели, позволяющие сравнивать их • Индикаторы состояния: Отображают прогресс обработки или ошибки • Опция ветвления: • Кнопка или чекбокс «Начать ветвление здесь», позволяющий создать новую ветку диалога на основе выбранного ответа • Возможность вести несколько веток диалога параллельно • Уведомления и подсказки: • Системные сообщения об ошибках или успешной отправке • Рекомендации по дальнейшим действиям при недоступности моделей	 The screenshot displays a dark-themed user interface. At the top, a header reads 'Выберите вариант ветвления' (Select a branching option). Below this, there are three icons: a fork, a plus sign with a person, and a list icon. Under the icons are two checkboxes: 'Начать ветвление здесь' (Start branching here) and 'Запомнить' (Remember). Below this section, there is a smaller window showing a list of models with checkboxes and a 'GPT-4' label. At the bottom, there is a status bar with icons and text.
--------------------	---	---

6.7.2.1.5.2 Выявленная проблематика

6.7.2.2 Сценарии использования LiteLLM [UI]

6.7.2.3 Сценарии использования NoCode aka LangFlow [UI]

6.8 Передача репозитория в деплой (Infra / DevOps)

Подготовка репозитория к деплою и передаче в Infra / DevOps

6.8.1 Цель документа

Данный документ описывает единые требования к оформлению репозитория сервисов, которые передаются в работу инфраструктурной / DevOps-команде для деплоя, сопровождения и эксплуатации.

Цель:

- сократить время на разбор сервиса инфраструктурой,
- снизить количество уточняющих вопросов,
- обеспечить предсказуемый и повторяемый процесс деплоя.

Документ обязателен к применению для всех новых сервисов и при доработке существующих.

6.8.2 Минимальные требования к сервису

Перед созданием задачи на Infra / DevOps убедитесь, что сервис соответствует следующим требованиям.

6.8.2.1 1. Healthcheck endpoint

Сервис должен иметь healthcheck endpoint.

Требования:

- HTTP endpoint (например: /health)
- возвращает 200 OK, если сервис работоспособен
- не зависит от внешних систем критично (или явно описывает деградацию)

Пример:

GET /health

200 OK

Healthcheck используется:

- для readiness/liveness проверок,
- при деплое,
- для мониторинга.

6.8.2.1.1 ВАЖНО! Необходимо предусмотреть расположение сервиса не в единственном экземпляре

6.8.2.2 2. Метрики (если применимо)

Если сервис отправляет метрики - они должны быть доступны в формате Prometheus.

Требования:

- отдельный endpoint (например: /metrics)
- совместимость с Prometheus scrape

Если метрик нет - это должно быть явно указано в README.

6.8.2.3 3. Алерты (при интеграции с инфровым алертингом)

Если сервис:

- ходит в общий инфровый алертинг,
- или ожидается его мониторинг в production,
- то необходимо описать ожидаемые алерты.

Минимально:

- по каким событиям шлются алерты,
- критичность (warning / critical),
- краткое описание условий срабатывания.

Если алертинг не используется - это также явно фиксируется.

6.8.3 Требования к репозиторию

6.8.3.1 4. Репозиторий с кодом

- код сервиса должен находиться в одном репозитории;
- репозиторий указывается явно в задаче на Infra / DevOps;
- доступы к репозиторию должны быть предоставлены заранее.

6.8.3.2 5. Ссылка на репозиторий в задаче

В задаче на инфраструктуру обязательно указывать:

- ссылку на репозиторий,

- ветку или tag, который предполагается к деплою.

Без ссылки задача не принимается в работу.

6.8.4 Обязательная структура репозитория

В репозитории обязательно должны присутствовать следующие элементы.

6.8.4.1 6. Dockerfile

- Dockerfile для сборки production-образа
- без dev-зависимостей (если не оговорено иное)
- с понятной точкой входа (ENTRYPOINT / CMD)

6.8.4.2 7. Файл зависимостей

В зависимости от стека:

- txt / pyproject.toml
- json

или иной стандартный файл зависимостей

Файл должен:

- быть актуальным,
- позволять воспроизводимую сборку образа.

6.8.4.3 8. README.md (обязательно)

README - ключевой документ для инфраструктуры.

Минимальное содержимое README:

6.8.4.3.1 8.1 Общее описание сервиса

- что это за сервис,
- за что отвечает,
- основные зависимости (БД, кеши, внешние API).

6.8.4.3.2 8.2 Как запустить сервис

- локальный запуск,
- запуск через Docker / docker-compose,
- примеры команд.

6.8.4.3.3 8.3 Production-запуск

- особенности production конфигурации,
- параметры масштабирования (воркеры, ресурсы),
- healthcheck endpoint.

6.8.4.3.4 8.4 Переменные окружения

- список всех ENV-переменных,
- какие обязательны,
- примеры значений,
- дефолты (если есть).

6.8.4.3.5 8.5 Возможные проблемы

- типовые ошибки при старте,
- проблемы с БД / миграциями / внешними сервисами,
- способы диагностики.

6.8.4.4 9. Production docker-compose (если требуется)

Если для деплоя используется docker-compose:

- в репозитории должен быть production-compose файл,
- без dev-override логики,
- с описанными зависимостями и healthcheck.

Если compose не используется - это указывается в README.

6.8.5 Процесс передачи в Infra / DevOps

1. Разработчик / владелец сервиса:
 - оформляет репозиторий по данному документу,
 - проверяет запуск сервиса локально и в Docker.
2. Создается задача на Infra / DevOps:
 - прикладывается ссылка на репозиторий,
 - указывается ветка / tag,
 - кратко описывается цель деплоя.
3. Infra / DevOps:
 - не тратит время на восстановление контекста,
 - использует README как основной источник информации,

- задает вопросы только по нетиповым кейсам.

6.9 Ролевая модель в Langflow (NoCode)

6.9.1 Цели создания ролевой модели

1. Безопасность: защита конфиденциальных данных (API-ключи, промпты, логи) и непрерывной работы продакшен-пайплайнов.
2. Разделение обязанностей: разграничение прав между разработчиками пайплайнов и пользователями.

6.9.2 Открытые вопросы

1. Нужно ли учитывать какую-то ролевку/архитектуру ролевки от Облачной платформы Дюгурова?
2. Нужно ли закладывать ролевку и ChatUI тоже (полагаю, этого ожидают клиенты) или только Langflow?
3. Можем ли мы ограничить доступ к определенным источникам данных про проекту/роли?

Важно! Администрирование ролевой модели будет необходимо отразить во внутренней админке продукта.

6.9.3 Основные сущности

Организация

Отображать название и ID. Уникальность названия не требуется. Создается сервис-менеджером.

Проект

Отображать название и ID. В рамках организации название проекта должно быть уникальным. В рамках всех компаний уникальность не требуется. Проекты заводятся админом организации (см. ниже) (ВОПРОС: стоит ли дать права другим ролям создавать проекты?).

Пользователь

Добавляется в организацию по email админом организации. Админа организации заводит сервис-менеджер либо ранее созданные админы.

Предусмотреть возможность загрузки пользователей через файл.

Группа пользователей

Объединение пользователей, которым можно разом назначить определенную роль. Группа назначается пользователю при создании пользователя или позднее. **Требуется обсуждения.**

Ресурс

Сущности, на которые раздаются права внутри проекта.

1. Новые компоненты
2. API-ключи
3. Глобальные переменные
4. Pipelines (потoki)
5. API-endpoint
6. UI с доступом к pipeline.

Действия над ресурсом

Создание/просмотр/редактирование/удаление ролей/пользователей/проектов/новых компонентов/API ключей/глобальных переменных и т.д..

6.9.4 Роли

Предлагается создать несколько преднастроенных ролей, при этом предлагается роли сделать **редактируемыми**. Админу организации будет доступна таблица, где галочками проставлены права на разные модули/фичи и будет возможность:

- Редактировать галочки
- Добавлять роли.

Список модулей/фичей при этом будет нередактируемый.

Пользователи могут состоять в разных проектах с разными правами.

6.9.4.1 Админ организации

Владелец Nocode внутри организации-клиента. Управление пользователями и настройками.

Права:

- Может завести в организации новых пользователей (высылается приглашение на почту).
- Может назначить другого пользователя админом.
- Имеет права админа на все проекты внутри организации.
- Может назначать права на все проекты внутри организации.
- Может создавать проекты.

6.9.4.2 Админ проекта

Аналог в IT: инженер ML/AI, промпт-инженер, low-code разработчик. Создание, модификация и тестирование потоков (flows) в рамках своего проекта.

Права:

- Создание и редактирование потоков: Полный доступ к конструктору: добавление, настройка, соединение компонентов.
- Управление API-ключами в своем проекте: Добавление, редактирование, удаление ключей (например, OpenAI, Anthropic) в рамках своего проекта. *Не может видеть ключи других проектов.*

- Тестирование потоков: Запуск потоков в режиме "промт-панели", просмотр результатов и логов своих выполнений.
- Экспорт/Импорт потоков: Сохранение и загрузка конфигураций потоков (`.json`).
- Создание API-эндпоинтов: Публикация потока как API-эндпоинта для внешнего использования.
- Ограниченный просмотр: Видит только те проекты и потоки, в которые его добавили.
- Добавление пользователей в проект: может добавить пользователей с различными правами в проект, но лишь тех, кто заведен в организацию.

6.9.4.3 Тестировщик (Tester / Reviewer)

Аналог в IT: QA-инженер, продукт-менеджер. Тестирование и оценка готовых потоков без возможности их случайного изменения.

Права:

- Просмотр потоков: Возможность открывать и просматривать конфигурацию потоков в режиме "только для чтения".
- Запуск потоков: Активное тестирование потоков через промт-панель с разными входными данными.
- Просмотр логов выполнений: Анализ результатов и ошибок тестовых запусков.
- Комментирование: Возможность оставлять комментарии прямо на потоке для разработчика.
- Запрещено: Редактирование, удаление, создание новых потоков и управление API-ключами.

6.9.4.4 Пользователь проекта

Аналог в IT: Внешняя система или приложение, конечный пользователь веб-интерфейса. Цель: Только использование развернутых API-эндпоинтов или готовых интерфейсов.

Права:

- Вызов API: Отправка HTTP-запросов на опубликованные эндпоинты.
- Использование готового интерфейса: Взаимодействие с развернутым приложением через предоставленный UI (например, чат-бот).
- Запрещено: Любой доступ к интерфейсу Langflow, просмотр проектов, редактирование, доступ к настройкам.

6.9.4.5 Наблюдатель проекта


Сотрудник компании, которого добавили в проект с целью ознакомления. Цель: Только использование развернутых API-эндпоинтов или готовых интерфейсов.

Права:

- Вызов API: Отправка HTTP-запросов на опубликованные эндпоинты.
- Использование готового интерфейса: Взаимодействие с развернутым приложением через предоставленный UI (например, чат-бот).
- Запрещено: Любой доступ к интерфейсу Langflow, просмотр проектов, редактирование, доступ к настройкам.

ТАБЛИЦА ЕЩЕ В РАБОТЕ		Org Admin	Project Admin	Project User	Project Viewer
Управление пользователям и	Создание, просмотр, редактирование, удаление пользователей. Назначение им ролей.	+			
Управление проектами (project)	Создание, переименование, архивация, удаление проектов. Назначение пользователей в проекты.	+			
Системные настройки	Настройка глобальных переменных (например, дефолтных API-ключей), параметров сервера, бэкенд-конфигураций.	+			
Просмотр артефактов	Доступ ко всем проектам, потокам, компонентам и API- ключам всех пользователей.	+			
Управление кастомными компонентами	Установка, обновление, отключение кастомных компонентов для всего инстанса.				
Аудит и мониторинг	Просмотр логов выполнения, метрик использования				

6.9.5 Схематичное изображение ролевой модели



6.9.6 RBAC в Langflow с использованием Casbin

6.9.6.1 1. Что сейчас есть

6.9.6.1.1 Как работает авторизация

Сейчас в Langflow все просто - есть флаг **is_superuser** на модели User:

- **is_superuser=True** - полный доступ ко всему
- **is_superuser=False** - видишь только свои ресурсы

Все защищенные эндпоинты (около 40 штук) используют одну FastAPI-зависимость:

```
# src/backend/base/langflow/api/utils.py, строка 35
CurrentActiveUser = Annotated[User, Depends(get_current_active_user)]
```

Функция **get_current_active_user** (файл `src/backend/base/langflow/services/auth/utils.py`, строки 249-252) просто проверяет что пользователь активен и возвращает его. Тип **CurrentActiveUser** используется в **76 местах** в 15 файлах.

6.9.6.1.2 Чего нет

- Организаций и команд

- Проектов как единицы совместной работы
- Гранулярных прав (read/write/execute/delete)
- Групп пользователей
- Аудита действий

6.9.6.1.3 Ключевые модели в коде

User (*src/backend/base/langflow/services/database/models/user/model.py*, строки 25-52):

- id, username, password, is_active, is_superuser
- Связи: api_keys, flows, variables, folders

Folder (*src/backend/base/langflow/services/database/models/folder/model.py*, строки 16-31):

- id, name, description, user_id (FK на User), parent_id (FK на себя)
 - Связи: flows, children (вложенные папки)
 - Уникальность по паре (user_id, name)
-

6.9.6.2 2. Выбранный подход

6.9.6.2.1 Почему Dependency Injection Override

FastAPI дает возможность подменять зависимости через **app.dependency_overrides** без изменения исходного кода роутеров. Если подменить **get_current_active_user**, это автоматически затронет все 76 мест где используется **CurrentActiveUser**.

Что это дает:

- Ноль изменений в файлах роутеров
- Минимальный риск конфликтов при мерже с upstream
- Можно включать/выключать RBAC через переменную окружения

6.9.6.2.2 Почему Casbin

- Зрелая библиотека - ее рассматривают сами разработчики Langflow
- Поддерживает RBAC с доменами (права привязаны к проекту)
- Работает с PostgreSQL через async-адаптер
- Проверка прав меньше чем за 1 мс
- Модель авторизации описывается декларативно, политики хранятся в БД

6.9.6.2.3 Почему не другие подходы

Подход	Почему не подходит
Middleware	Та же проблема с маппингом путей. Нет доступа к объекту пользователя на уровне middleware. Конфликты при мерже в main.py
Plugin Architecture	Нужно менять около 30 файлов с эндпоинтами. Высокий риск конфликтов. Забытый хук - дыра в безопасности
Service Layer Proxy	Отдельный сервис-прокси перед Langflow. Добавляет 5-20мс задержки, сложность деплоя и дебага двух сервисов

6.9.6.3 3. Два варианта реализации

Критерий	Вариант А (MVP)	Вариант Б (полный)
Ролевая модель	5 фиксированных ролей, привязка к существующему Folder	Организации, проекты, редактируемые роли, группы
Новых таблиц в БД	2 (user_project_role, casbin_rule)	8 (+organization, rbac_project, role_definition, user_group, user_group_membership, group_project_role)
Новых файлов	около 12	около 30
Файлов Langflow изменено	1 (main.py)	2 (main.py, router.py)
Иерархия	Нет - роли привязаны к Folder напрямую	Организация - Проект - Ресурс
Редактируемые роли	Нет	Да
Группы пользователей	Нет	Да, с каскадным назначением

Критерий	Вариант А (MVP)	Вариант Б (полный)
Импорт пользователей	Нет	Да, CSV/XLSX
API управления RBAC	Минимальный (назначение ролей)	Полный (организации, роли, группы, импорт)
Риск при обновлении upstream	Минимальный	Низкий
Масштабируемость	Ограниченная	Полная

Рекомендация: начать с Варианта А, проверить в проде, потом расширить до Варианта Б. Таблица `user_project_role` при миграции расширяется, а не заменяется - данные не теряются.

6.9.6.4 4. Вариант А (MVP) - что конкретно делаем

6.9.6.4.1 4.1. Новая таблица `user_project_role`

Файл: `src/backend/base/langflow/rbac/models/user_project_role.py`

Поля:

- **id** - UUID, primary key
- **user_id** - FK на user
- **folder_id** - FK на folder
- **role_name** - строка (org_admin / project_admin / tester / project_user / observer)
- **assigned_at** - timestamp
- **assigned_by** - FK на user, nullable

Уникальное ограничение на пару (user_id, folder_id).

Alembic-миграция создает эту таблицу плюс **casbin_rule** (стандартная таблица для casbin-sqlalchemy-adapter с полями id, ptype, v0-v5).

6.9.6.4.2 4.2. Конфигурация Casbin

Файл: `src/backend/base/langflow/rbac/casbin_model.conf`

```
[request_definition]
r = sub, dom, obj, act

[policy_definition]
p = sub, dom, obj, act
```

```
[role_definition]
g = _, _, _

[matchers]
m = g(r.sub, p.sub, r.dom) && r.dom == p.dom && r.obj == p.obj && r.act == p.act
```

- **sub** = user_id
- **dom** = folder_id (проект)
- **obj** = тип ресурса (flow, project, api_key и т.д.)
- **act** = действие (read, create, update, delete, execute)

При старте загружаются 5 фиксированных ролей как seed-политики.

6.9.6.4.3 4.3. Модуль Casbin Enforcer

Файл: `src/backend/base/langflow/rbac/enforcer.py`

При старте приложения инициализирует асинх Casbin Enforcer, подключенный к той же БД что и Langflow. Дает функцию:

```
async def enforce(user_id, folder_id, resource_type, action) -> bool
```

Новые зависимости в `pyproject.toml`:

- casbin>=1.36.0
- casbin-async-sqlalchemy-adapter>=1.4.0

6.9.6.4.4 4.4. EndpointMapper - маппинг URL в ресурс и действие

Файл: `src/backend/base/langflow/rbac/endpoint_mapper.py`

По URL-пути определяет тип ресурса:

Префикс URL	resource_type
/api/v1/flows	flow
/api/v1/projects, /api/v1/folders	project
/api/v1/api_key	api_key
/api/v1/variables	variable
/api/v1/files	file

Префикс URL	resource_type
/api/v1/monitor/messages	message
/api/v1/monitor/builds	build_log
/api/v1/monitor/transactions	transaction
/api/v1/knowledge	knowledge_base

По HTTP-методу определяет действие:

- GET - read
- POST - create (но build/run эндпоинты - execute)
- PATCH/PUT - update
- DELETE - delete

Из URL извлекается UUID ресурса через regex.

Около 15 публичных путей исключены из проверки: /api/v1/login, /api/v1/auto_login, /health, /api/v1/public_flow, /api/v1/starter-projects и др.

При старте приложения сравнивает зарегистрированные роуты FastAPI с известным маппингом. Если найден незнакомый защищенный эндпоинт - выводит предупреждение в лог.

6.9.6.4.5 4.5. ResourceResolver - определение проекта по ресурсу

Файл: `src/backend/base/langflow/rbac/resource_resolver.py`

По типу ресурса и его ID определяет folder_id (проект):

Ресурс	Как определяем folder_id
flow	Запрос в БД: Flow.folder_id
project	folder_id и есть ID проекта
file, message, build_log, transaction	Берем flow_id из пути, потом Flow.folder_id
api_key, variable	Возвращаем None (привязаны к пользователю, не к проекту)

Если вернулся None - пропускаем RBAC, оставляем оригинальное поведение Langflow (owner-only).

6.9.6.4.6 4.6. Dependency Overrides - подмена зависимостей

Файл: `src/backend/base/langflow/rbac/overrides.py`

Три async-функции на замену:

rbac_get_current_active_user (заменяет `get_current_active_user`):

1. Проверить `is_active` (401 если нет)
2. Если `superuser` и `LANGFLOW_RBAC_SUPERUSER_BYPASS=true` - пропустить RBAC
3. Проверить путь по `exempt`-списку - пропустить RBAC
4. `EndpointMapper` определяет `resource_type` и `action`
5. `ResourceResolver` находит `folder_id`
6. Если `folder_id` не найден - вернуть пользователя без RBAC
7. `Casbin enforce` - при отказе 403

rbac_get_current_active_superuser (заменяет `get_current_active_superuser`):

- Стандартная проверка `is_superuser`, но дополнительно пускает пользователей с ролью `org_admin`

rbac_get_current_active_user_mcp - то же что первая, но для MCP-зависимости.

6.9.6.4.7 4.7. Точка интеграции в `main.py`

Файл: `src/backend/base/langflow/main.py`

После строки 372 (после `app.include_router(log_router)`), перед `exception handler`.

Добавляется **7 строк**:

```
import os
if os.getenv("LANGFLOW_RBAC_ENABLED", "false").lower() == "true":
    from langflow.rbac.bootstrap import inject_rbac_system

    @app.on_event("startup")
    async def _rbac_startup():
        await inject_rbac_system(app)
```

Функция `inject_rbac_system` инициализирует `Casbin Enforcer` и подставляет три `dependency_overrides`.

6.9.6.4.8 4.8. API назначения ролей

Файл: `src/backend/base/langflow/rbac/api/members.py`

Метод	Эндпоинт	Что делает
GET	/api/v1/rbac/projects/{folder_id}/members	Список членов проекта с ролями
POST	/api/v1/rbac/projects/{folder_id}/members	Добавить пользователя с ролью
PATCH	/api/v1/rbac/projects/{folder_id}/members/{user_id}	Изменить роль
DELETE	/api/v1/rbac/projects/{folder_id}/members/{user_id}	Удалить из проекта

При добавлении/изменении: запись в user_project_role + Casbin grouping policy (user_id, role_name, folder_id).

6.9.6.4.9 4.9. Структура новых файлов

```
src/backend/base/langflow/rbac/
__init__.py
bootstrap.py          - inject_rbac_system()
enforcer.py           - инициализация Casbin + enforce()
endpoint_mapper.py    - URL -> (resource_type, action)
resource_resolver.py  - resource -> folder_id
overrides.py          - 3 функции подмены зависимостей
seed.py               - загрузка 5 начальных ролей
casbin_model.conf     - конфиг модели Casbin
api/
  __init__.py
  members.py          - эндпоинты назначения ролей
models/
  __init__.py
  user_project_role.py - SQLAlchemy таблица
```

6.9.6.4.10 4.10. Ограничения Варианта А

- **Нет организаций** - нельзя объединить несколько проектов под единым управлением
- **Нет редактируемых ролей** - 5 фиксированных, для изменения прав нужно менять seed-данные
- **Нет групп** - назначение ролей только по одному пользователю
- **Нет импорта** - добавление только через API
- **api_key и variable** не привязаны к проектам - остается owner-only
- **Нет аудита** - проверки авторизации и изменения ролей не логируются

6.9.6.5 5. Вариант Б (полный) - что добавляется сверх Варианта А

6.9.6.5.1 5.1. Дополнительные таблицы - еще 6 штук

Таблица	Зачем	Ключевые поля
organization	Верхний уровень иерархии	id, name (уникальное), description, created_by
rbac_project	Связь организации с Folder	id, organization_id, folder_id (уникальное), name
role_definition	Редактируемая роль с JSON-правами	id, name, organization_id, is_system, permissions (JSON)
user_group	Группа пользователей	id, name, organization_id
user_group_membership	Связь пользователь-группа	user_id, group_id
group_project_role	Роль группы в проекте	group_id, project_id, role_name

Таблица user_project_role расширяется: project_id теперь ссылается на rbac_project вместо folder.

6.9.6.5.2 5.2. Расширение конфига Casbin

- Правило **g2**: (user_id, "org_admin", organization_id) - привязка админа на уровне организации
- Правило **g3**: (user_id, group_id) - связь пользователя с группой
- В матчерах добавляются OR-условия: org_admin автоматически получает доступ ко всем проектам своей организации
- Нужна кастомная функция get_org_for_project(project_id) через in-memory кэш

6.9.6.5.3 5.3. RoleManager - динамическое управление ролями

Синхронизирует таблицу role_definition с политиками Casbin:

- При назначении роли - читает permissions из role_definition, создает политики в Casbin
- При изменении прав роли админом - удаляет старые политики во всех проектах, создает новые
- Тяжелая операция: при 100 проектах и роли с 20 permissions это около 2000 строк casbin_rule. Лучше делать в транзакции и в фоновой задаче

6.9.6.5.4 5.4. GroupManager - управление группами

Каскадные операции:

- Добавляем пользователя в группу - автоматически получает все роли группы во всех проектах
- Назначаем группе роль в проекте - все члены группы получают эту роль
- Для групп больше 50 человек - batch-операции (add_policies вместо add_policy в цикле)

6.9.6.5.5 5.5. API управления RBAC - 5 роутеров

Роутер	Эндпоинты	Кто может
Организации	CRUD (4 штуки)	superuser / org_admin
Роли	CRUD (4 штуки)	org_admin (системные нельзя удалить)
Члены проекта	CRUD (4 штуки)	project_admin и выше
Группы	CRUD + назначение роли (5 штук)	org_admin
Импорт пользователей	Загрузка CSV/XLSX (1 штука)	org_admin

Регистрируются через одну строку include_router в `src/backend/base/langflow/api/router.py`.

6.9.6.5.6 5.6. Seed Data

При первом запуске миграция создает 5 системных ролей (is_system=True) с предустановленными правами в JSON. При создании новой организации системные роли копируются в нее.

6.9.6.6 6. Матрица ролей и действий

Ресурс:Действие	org_admin	project_admin	tester	project_user	observer
flow:read	✓	✓	✓		✓
flow:create	✓	✓			

Ресурс:Действие	org_admin	project_admin	tester	project_user	observer
flow:update	✓	✓			
flow:delete	✓	✓			
flow:execute	✓	✓	✓	✓	
flow:comment	✓	✓	✓		
project:read	✓	✓	✓	✓	✓
project:create	✓				
project:update	✓	✓			
project:delete	✓				
api_key:read	✓	✓	✓		
api_key:create	✓	✓			
api_key:delete	✓	✓			
variable:read	✓	✓	✓		
variable:create	✓	✓			
variable:update	✓	✓			
variable:delete	✓	✓			
user:read	✓	✓	✓	✓	✓
user:invite	✓	✓			
message:read	✓	✓	✓	✓	✓

Ресурс:Действие	org_admin	project_admin	tester	project_user	observer
message:delete	✓	✓			
endpoint:publish	✓	✓			
knowledge_base:read	✓	✓	✓	✓	✓
knowledge_base:create	✓	✓			
knowledge_base:delete	✓	✓			

6.9.6.7 7. Переменные окружения

Переменная	Умолчание	Что делает
LANGFLOW_RBAC_ENABLED	false	Главный переключатель. При false RBAC вообще не грузится
LANGFLOW_RBAC_DEFAULT_DENY	true	true - блокировать неизвестные эндпоинты (безопаснее). false - пропускать (удобно при разработке)
LANGFLOW_RBAC_SUPERUSER_BYPASS	true	Суперпользователи обходят все проверки RBAC
LANGFLOW_RBAC_CACHE_TTL	300	TTL кэша политик Casbin в секундах (только Вариант Б)

6.9.6.8 8. Какие файлы Langflow меняются

6.9.6.8.1 Вариант А

Файл	Что меняем	Строк
src/backend/base/langflow/main.py	Условный блок RBAC startup после строки 372	+7
pyproject.toml	Добавить casbin и casbin-async-sqlalchemy-adapter	+2

6.9.6.8.2 Вариант Б (дополнительно)

Файл	Что меняем	Строк
src/backend/base/langflow/api/router.py	router_v1.include_router(rbac_router)	+1

Весь остальной код живет в новом пакете **langflow/rbac/** - полностью изолирован от кода Langflow.

6.9.6.9 9. Как проходит запрос (Вариант А)

```

HTTP-запрос
|
v
FastAPI резолвит зависимость get_current_active_user
|
v (подменена на rbac_get_current_active_user)
|
|- is_active? --Нет--> 401
|
|- superuser + bypass? --Да--> return user (без RBAC)
|
|- exempt-путь? --Да--> return user (без RBAC)
|
v
EndpointMapper.resolve(path, method)
|

```

```

| - неизвестный эндпоинт + DEFAULT_DENY=true --> 403
|
v
ResourceResolver.resolve(resource_type, resource_id)
|
| - folder_id = None --> return user (оригинальное поведение)
|
v
Casbin enforce(user_id, folder_id, resource_type, action)
|
| - запрет --> 403 Forbidden
|
v
return user --> обработчик эндпоинта

```

6.9.6.10 10. Риски и митигация

6.9.6.10.1 Высокое влияние

Риск	Вероятность	Что делаем
Изменение сигнатуры get_current_active_user в upstream	Низкая	CI-тест, который проверяет сигнатуру при каждом мерже из upstream. Функция стабильна - не менялась с начала проекта
Конфликт с будущим нативным RBAC в Langflow	Средняя	Feature flag позволяет мгновенно выключить. Данные в отдельных таблицах - можно мигрировать

6.9.6.10.2 Среднее влияние

Риск	Вероятность	Что делаем
Новые эндпоинты в upstream не попадают в маппинг	Средняя	При старте сравниваем роуты FastAPI с известным маппингом. Логируем предупреждения. DEFAULT_DENY=true блокирует неизвестные

Риск	Вероятность	Что делаем
Рассинхронизация кэша project-org в multi-instance (Вариант Б)	Средняя	Периодическая перезагрузка каждые CACHE_TTL секунд. Для HA - pub/sub через Redis
Хрупкость маппинга путей	Средняя	Маппинг через regex, не точные строки. Валидация при старте

6.9.6.10.3 Низкое влияние

Риск	Вероятность	Что делаем
Overhead Casbin на производительность	Низкая	Меньше 1мс на проверку в памяти. Основная стоимость - ResourceResolver (1 запрос в БД). Кэшируем flow-folder_id
Merge-конфликт в main.py	Низкая	Изменение в конце create_app, далеко от часто меняемых участков
Обновление прав роли - тяжелая операция (Вариант Б)	Низкая	Делать в транзакции, логировать время. В проде - фоновая задача

6.9.6.11 11. Плюсы и минусы выбранного подхода

6.9.6.11.1 Плюсы

- Ноль изменений в коде роутеров - все 76 использований CurrentActiveUser покрыты автоматически
- Минимальные конфликты при мерже с upstream (main.py +7 строк, pyproject.toml +2 строки)
- Feature flag - RBAC включается/выключается без изменений кода
- Type-safe - используем встроенную систему DI FastAPI
- Casbin - та же библиотека что планируют принять разработчики Langflow
- Полная изоляция RBAC-кода в отдельном пакете langflow/rbac/

6.9.6.11.2 Минусы

- Перехват только на уровне зависимостей - нет per-endpoint гранулярности
- Нужно поддерживать маппинг эндпоинтов-ресурсов, который может расходиться с upstream

- ResourceResolver добавляет 1 запрос в БД на каждый запрос (можно кэшировать)
 - Фиксированные роли в MVP - для изменения прав нужно менять seed-данные
 - api_key и variable в MVP не привязаны к проектам (остается owner-only)
 - Нет аудита в MVP
-

6.9.6.12 12. Миграция с Варианта А на Вариант Б

1. Вариант А задеплоен и проверен в проде
2. Создаем таблицы organization и rbac_project, линкуем существующие Folder
3. Меняем FK folder_id в user_project_role на project_id (FK на rbac_project) - data-миграция сохраняет все назначения
4. Добавляем таблицу role_definition, заполняем из фиксированных ролей
5. Деплоим GroupManager и расширенные API-роутеры
6. Добавляем 1 строку в router.py

Без потери данных. Обратная совместимость. Можно делать по шагам.

6.9.7 Анализ кодовой базы по ролевке LF и оценка предлагаемых решений

6.9.7.1 1. Текущее состояние архитектуры Langflow

6.9.7.1.1 1.1. Технологический стек

- **Фреймворк:** FastAPI (асинхронный веб-фреймворк)
- **ORM:** SQLAlchemy + SQLAlchemy (async)
- **База данных:** PostgreSQL/SQLite
- **Аутентификация:** JWT токены + API ключи
- **Архитектура:** Монолитное приложение с сервис-ориентированной структурой

6.9.7.1.2 1.2. Текущая система аутентификации и авторизации

6.9.7.1.2.1 Аутентификация

Расположение: `src/backend/base/langflow/services/auth/utils.py`

Методы:

- JWT токены (access + refresh)
- API ключи
- Auto-login (режим разработки)

Ключевые функции:

- `get_current_active_user()` - главная зависимость FastAPI
- `get_current_active_superuser()` - проверка прав суперпользователя

6.9.7.1.2.2 Авторизация

Текущее состояние: Примитивная двухуровневая система

- `is_superuser = True` - полный доступ
- `is_superuser = False` - доступ только к своим ресурсам

Критическая зависимость:

```
# Файл: /api/utils/core.py, строка 36
CurrentActiveUser = Annotated[User, Depends(get_current_active_user)]
```

Используется во **всех защищенных эндпоинтах**.

В архитектуре отсутствует:

- Совместный доступ к ресурсам
- Команды/организации
- Гранулярные права (read/write/execute/delete)
- Аудит действий

6.9.7.1.3 1.3. Точки интеграции

Компонент	Расположение	Возможность расширения
Middleware Stack	<code>main.py</code> (функция <code>create_app</code>)	Высокая - простой стек
Dependency Injection	<code>api/utils/core.py</code>	Высокая - поддержка override
Plugin архитектура	новая директория <code>plugins/</code>	Высокая - добавление собственной системы плагинов
Service Layer	<code>services/</code>	Средняя - требует изменений

Ключевая особенность: FastAPI позволяет переопределять зависимости через `app.dependency_overrides` без изменения исходного кода.

6.9.7.2 2. Требования к решению для форка

Критические требования:

- **Минимальные (желательно) изменения кодовой базы Langflow** - упрощает merge обновлений
- **Изоляция кода RBAC** - логика в отдельных модулях/пакетах
- **Отсутствие конфликтов при мерже** - не затрагивать часто изменяемые файлы
- **Стабильность** - не ломаться при обновлении Langflow

6.9.7.3 3. Четыре подхода к интеграции RBAC

6.9.7.3.1 3.1. Подход 1: Переопределение зависимостей (Dependency Injection Override)

6.9.7.3.1.1 Краткое описание

Отдельный Python пакет, переопределяющий зависимости аутентификации FastAPI в runtime без изменения кода Langflow.

Суть: Использование `app.dependency_overrides` для замены `get_current_active_user` на версию с проверкой RBAC.

Изменения в Langflow: незначительны

Интеграция:

```
from langflow.main import create_app
from langflow_rbac import inject_rbac_system

app = create_app()
inject_rbac_system(app) # Единственная строка интеграции
```

6.9.7.3.1.2 Преимущества

- Нулевые изменения Langflow - код остается нетронутым
- Полная изоляция - RBAC в отдельном репозитории
- Нет merge конфликтов - обновления проходят без проблем
- Опциональность - легко включить/отключить

- Type-safe - использует встроенную систему FastAPI

6.9.7.3.1.3 Недостатки

- Ограниченные точки перехвата - только на уровне зависимостей
- Runtime overhead - дополнительный слой разрешения зависимостей
- Требуется анализ путей эндпоинтов для определения ресурсов
- Нет автоматического определения действий (read/write) из HTTP методов

6.9.7.3.1.4 Потенциальные риски

- **Низкий риск:** Изменение структуры зависимостей Langflow (вряд ли)
- **Средний риск:** Необходимость поддержки маппинга эндпоинтов → при обновлении можно пропустить добавление новых эндпоинтов и тогда ролёвка будет работать не везде

6.9.7.3.2 3.2. Подход 2: Middleware-based Authorization

6.9.7.3.2.1 Краткое описание

Middleware перехватывает HTTP запросы, парсит путь/метод для определения ресурса, проверяет права через Casbin.

Суть: Централизованная проверка на уровне HTTP middleware до попадания в эндпоинт.

Изменения в Langflow: незначительны

Интеграция:

```
# В langflow/main.py
from langflow_rbacmiddleware import RBACMiddleware
app.add_middleware(RBACMiddleware) # Добавить после существующих
```

6.9.7.3.2.2 Преимущества

- Централизованная проверка - единая точка авторизации
- Path-based подход - легко аудировать
- Раннее отклонение - блокировка до бизнес-логики
- Отдельный пакет - логика изолирована

6.9.7.3.2.3 Недостатки

- Возможны merge конфликты - main.py часто изменяется
- Сложность парсинга путей - нужен маппинг URL → ресурсы

- Динамические роуты - параметризованные пути требуют поддержки

6.9.7.3.2.4 Потенциальные риски

- Средний риск: Конфликты при merge в `main.py`
- Средний риск: Изменение структуры URL в Langflow требует обновления парсера
- Низкий риск: Ошибки в парсере могут блокировать валидные запросы
- Высокий риск: Необходимость постоянной синхронизации маппинга путей с API Langflow

6.9.7.3.3 3.3. Подход 3: Plugin Architecture

6.9.7.3.3.1 Краткое описание

Форк Langflow с добавлением официальной системы плагинов, RBAC реализуется как плагин.

Суть: Добавление хуков авторизации в ~30 эндпоинтах Langflow + система загрузки плагинов.

Изменения в Langflow: будут затронуты около 30 файлах

Интеграция:

```
# В каждом защищенном эндпоинте
plugin = get_active_plugin()
if plugin:
    await plugin.authorize_request(user, "flow", flow_id, "read")
```

6.9.7.3.3.2 Преимущества

- Максимальная гибкость - хуки в нужных местах
- Чистая абстракция - официальный API плагинов
- Мульти-плагины - можно добавить аудит, логирование

6.9.7.3.3.3 Недостатки

- Много изменений - редактирование эндпоинтов по всей кодовой базе
- Частые merge конфликты - изменения во многих файлах
- Высокая сложность координации - дизайн интерфейса плагинов критичен
- Тестирование совместимости плагинов

6.9.7.3.3.4 Потенциальные риски

- **Высокий риск:** Конфликты при merge в ~30 файлах эндпоинтов (средняя вероятность)
- **Высокий риск:** Рефакторинг эндпоинтов в Langflow потребует обновления хуков

- **Высокий риск:** Сложность поддержки форка при активных изменениях в основном репозитории Langflow
 - **Критический риск:** Забытый хук = незащищенный эндпоинт (уязвимость безопасности)
-

6.9.7.3.4 3.4. Подход 4: Service Layer Wrapper (Proxy)

6.9.7.3.4.1 Краткое описание

Отдельный FastAPI сервис проксирует запросы к Langflow, проверяя права на уровне прокси.

Суть: Архитектура [Client] → [RBAC Service] → [Langflow], общая БД.

6.9.7.3.4.2 Изменения в Langflow: буквально 0 строк

Интеграция: Запуск двух сервисов, клиенты обращаются к RBAC Service на порту 8001.

6.9.7.3.4.3 Преимущества:

- Ноль изменений Langflow
- Независимое развертывание - два процесса
- Легкий rollback - перенаправить на Langflow напрямую
- Общая БД - консистентность данных
- Постепенная миграция - можно роутить частично

6.9.7.3.4.4 Недостатки:

- Запрос проходит через +1 сервис - дополнительная задержка ~5-20ms
- Двойная аутентификация - оба сервиса валидируют токены
- Сложность развертывания - два сервиса для управления
- Сложность отладки - распределенная система
- Ограниченная интерцепция - только HTTP, не внутренние вызовы

6.9.7.3.4.5 Потенциальные риски:

- **Средний риск:** Проблемы синхронизации состояния между сервисами
 - **Высокий риск:** Сложность отладки и мониторинга распределенной системы
 - **Низкий риск:** Точка отказа - если RBAC service упал, доступа нет
 - **Средний риск:** Необходимость поддержки маппинга путей (как в Подходе 2)
-

6.9.7.4

Выводы

1-й выбор: Подход 1 (Dependency Override)- нулевые изменения, минимальные риски

2-й выбор: Подход 2 (Middleware) - минимальные изменения, приемлемые риски (обсуждаемо)

Подход 3 (Fork+Plugin) - высокие риски конфликтов при мерже, много разработки

Подход 4 (Proxy) - операционная сложность, сложность настройки

6.9.7.5 5. Почему Casbin подходит для RBAC в Langflow

В официальном репозитории Langflow в issues идёт обсуждение о добавлении коллаборативного режима и RBAC. Со стороны разработчиков предлагается использовать Casbin для реализации ролевой модели. Ниже приведена оценка внедрения Casbin для реализации нужной нам ролевой модели, рассмотрены его возможности и сложности, с которыми можно столкнуться при реализации требуемого функционала.

6.9.7.5.1 5.1. Обзор Casbin

Casbin - мощная библиотека управления доступом с открытым исходным кодом, поддерживающая различные модели контроля доступа.

Сайт: <https://casbin.org>

GitHub Python: <https://github.com/casbin/pycasbin>

6.9.7.5.2 5.2. Применение ролевой модели в Casbin

Casbin позволяет реализовать предлагаемую ролевую модель организация-проект-пользователь через механизм контекстных политик, где каждое правило авторизации привязывается к конкретному проекту. Пользователь может иметь разные роли в разных проектах (например, быть админом в проекте А и тестировщиком в проекте Б), а админ организации автоматически получает полные права на все проекты внутри своей организации. Группы пользователей реализуются через встроенный механизм групп Casbin, что позволяет назначать роль сразу целой группе без необходимости обновления прав каждого участника по отдельности.

Редактируемые роли требуют дополнительной логики: определения ролей хранятся в базе данных, а при изменении набора прав роли админом происходит автоматическая синхронизация с Casbin - старые правила удаляются, новые добавляются. Специфичные действия (комментирование, публикация эндпоинтов, приглашение пользователей) описываются как отдельные типы действий в политиках Casbin наряду с базовыми операциями чтения, записи и удаления. Благодаря поддержке PostgreSQL и асинхронной работы, Casbin обеспечивает быструю проверку прав (менее 1 миллисекунды) даже при сложной иерархии организаций и проектов.

6.9.7.6 6. Интеграция требований ролевой модели с Casbin

6.9.7.6.1 6.1. Обзор требований

6.9.7.6.1.1 Новая ролевая модель

Сущности:

- **Организация** - верхний уровень иерархии (создается сервис-менеджером)
- **Проект** - уникальность названия в рамках организации
- **Пользователь** - добавляется по email, может состоять в разных проектах
- **Группа пользователей** - объединение для массового назначения ролей
- **Ресурсы** - API-ключи, глобальные переменные, pipelines, endpoints, UI

Роли:

1. **Админ организации** - полные права в организации
2. **Админ проекта** - управление проектом, создание потоков, управление пользователями проекта
3. **Тестирующий** - просмотр и запуск потоков, комментирование (read-only на конфигурацию)
4. **Пользователь проекта** - использование API-endpoints и UI (без доступа к Langflow UI)
5. **Наблюдатель проекта** - аналогично пользователю, но сотрудник компании

Особенности:

- Редактируемые роли (админ может изменять набор прав)
- Иерархия: Организация → Проекты → Ресурсы
- Загрузка пользователей через файл
- Комментирование потоков

6.9.7.6.2 6.2. Сложность реализации на Casbin

Даже с учётом встроенных возможностей Casbin в реализации ролевой модели с его использованием будут сложности.

Почему:

- Требуется **многоуровневая иерархия** (организация → проект → ресурс)
- **Множественное членство** пользователя (разные роли в разных проектах)
- **Динамические роли** с редактируемыми правами
- **Группы пользователей** с каскадным назначением ролей
- **Scope-based авторизация** (права в контексте организации/проекта)

6.9.7.6.3 6.3. Подход к реализации

Исходя из желаемых видов ролей и их связей оптимальным вариантом реализации видится **гибридный подход RBAC + Scoped Policies** (политики с привязкой к проекту): роли назначаются в

контексте конкретного проекта, а политики определяют права роли на типы ресурсов внутри этого проекта. При проверке прав Casbin учитывает роль пользователя в проекте, права этой роли на требуемое действие, и принадлежность ресурса проекту. Админ организации получает специальную обработку с автоматическим доступом ко всем проектам организации. Группы пользователей реализуются через встроенный механизм групп Casbin g3 (способ связать пользователя с группой, а группу с ролью), что позволяет назначить роль сразу группе и автоматически применить её ко всем участникам.

6.9.7.6.4 6.4. Основные компоненты реализации

Расширенная модель данных: Потребуется создание сущностей Organization, Project, UserProjectRole, UserGroup, RoleDefinition для хранения иерархии и настроек ролей.

Адаптация Casbin: Создание обертки ScopedEnforcer (модуль, проверяющий права в рамках конкретного проекта) с методами проверки прав в контексте проекта, получения ролей пользователя и определения принадлежности ресурсов.

Редактируемые роли: Хранение определений ролей в БД с синхронизацией политик Casbin при изменении прав админом через специальный RoleManager.

Группы пользователей: Компонент UserGroupManager (инструмент для управления группами) для создания групп, добавления участников и назначения ролей с автоматическим применением прав ко всем участникам группы.

Специфичные действия: Расширение набора действий помимо CRUD (comment, execute, publish, invite, manage_keys) с проверками в соответствующих эндпоинтов.

6.9.7.7 7. Заключение

Casbin как решение:

- Разработчики Langflow планируют использовать Casbin
- Идеально подходит для RBAC
- Поддержка PostgreSQL и async
- Высокая производительность
- Зрелое и проверенное решение

6.9.7.7.1 7.3. Выводы по расширенной ролевой модели

Ключевые выводы:

1. Casbin **способен** реализовать требуемую модель, но требуется значительная кастомизация
2. Рекомендуется **гибридный подход** (RBAC + Scoped Policies) для баланса гибкости и сложности
3. **Редактируемые роли** требуют дополнительной синхронизации между БД и Casbin

Что потребуется:

- Расширенная модель БД (Organization, Project, UserProjectRole, UserGroup, RoleDefinition)
- Кастомный ScopedEnforcer с поддержкой проверки иерархии
- RoleManager для динамического управления правами ролей

- `UserGroupManager` для каскадного назначения прав
- API для управления организациями, проектами, пользователями, ролями
- Дополнительные действия (comment, publish, invite, manage_keys)

6.9.8 Проектирование UI-ролевки для NoCode

6.9.8.1 Ссылка на макет



Sorry, the widget is not supported in this export.
But you can reach it using the following URL:

<https://www.figma.com/design/rCUeKMHGfdbMGC2iRsoEef/Untitled?node-id=0-1&p=f&t=Cvlzov2uWUjry4QI-0>

<https://www.figma.com/design/rCUeKMHGfdbMGC2iRsoEef/Untitled?node-id=0-1&p=f&t=Cvlzov2uWUjry4QI-0>

6.9.8.2 Введение

Платформа «NoCode» - визуальный low-code конструктор на основе фреймворка LangChain, который позволяет быстро создавать, тестировать и развертывать приложения, работающие с большими языковыми моделями (LLM), используя интерфейс Drag-and-Drop, и значительно упрощает разработку ИИ-агентов и сложных рабочих процессов без написания большого количества кода.

Однако платформа ограничена: у каждого пользователя — только собственные проекты и потоки. Более того, на данный момент пользователь не может приглашать других в свои проекты — совместная работа возможна лишь через передачу собственных учетных данных (логина и пароля).

Этот подход создаёт риски:

- Невозможно отследить, кто именно вносил изменения.
- Нет возможности ограничить действия гостя: любой, получивший доступ, получает полный контроль над всеми проектами, API-ключами и настройками.
- При утрате доверия к участнику приходится менять пароль — это нарушает непрерывность работы.
- Нарушаются базовые принципы информационной безопасности: конфиденциальность, мониторинг и аудит, минимизация привилегий.

Таким образом, введение ролевой модели кардинально повысит безопасность, удобство совместной работы и соответствие современным ожиданиям пользователей.

Без этого платформа остаётся инструментом только для индивидуального использования, а любая форма коллаборации вынужденно происходит в обход принципов безопасного доступа — через совместное использование учётных данных.

6.9.8.3 Основные принципы проектирования

6.9.8.3.1 Минимализм

UI ролевой модели проектируется по принципу **минимальной достаточности**: он предоставляет только те элементы управления, которые необходимы для решения ключевых задач — безопасного делегирования доступа и разделения обязанностей — без избыточной сложности:

- **Преднастроенные роли.** Пользователь выбирает из понятных, семантически названных ролей («Админ проекта», «Тестировщик», «Наблюдатель»), а не настраивает десятки разрешений вручную.
- **Ограниченный набор редактируемых прав.** Админ организации может корректировать роли, но только в рамках фиксированного списка модулей («Управление пользователями», «Потоки», «API-ключи» и т.д.), чтобы избежать хаотичной кастомизации.
- **Контекстно-зависимый интерфейс.** Langflow и другие компоненты автоматически скрывают недоступные действия — пользователь не видит кнопок, которые всё равно не может нажать.

6.9.8.3.2 Иерархия управления доступом

Платформа NoCode будет строиться на трёхуровневой иерархической модели управления доступом, обеспечивающей гибкость и безопасность:

6.9.8.3.2.1 Уровень – Организация

Это корневая сущность, представляющая юридическое лицо, команду или клиентскую учётную запись.

Каждая организация имеет:

- Уникальный идентификатор;
- Название (не обязательно уникальное в глобальном масштабе);
- Список пользователей, принадлежащих этой организации;
- Список проектов, созданных в рамках организации.

Организацию может создать только **сервис-менеджер** (технический администратор платформы).

Внутри организации назначается как **минимум один админ организации**, который управляет пользователями и проектами.

Пользователь может принадлежать к нескольким организациям одновременно.

6.9.8.3.2.2 Уровень – Проект

Это логическая единица работы, объединяющая связанные между собой LLM-поток, API-ключи, эндпоинты и интерфейсы.

Проект всегда принадлежит ровно **одной организации**.

В рамках одной организации **названия проектов** должны быть **уникальными** (глобальная уникальность не требуется).

Проект содержит:

- Потоки;
- API-ключи (привязанные к проекту);
- Глобальные переменные;
- Опубликованные API-эндпоинты.

Создавать проекты могут:

- Админ организации

Проект является основной единицей совместной работы и делегирования прав.

6.9.8.3.2.3 *Уровень - Пользователь и Роль*

Пользователь добавляется в организацию **по email** (приглашением от админа организации).

После присоединения к организации пользователь может быть добавлен **в один или несколько проектов этой организации**.

При добавлении в проект пользователю **назначается роль**, определяющая его права в рамках этого проекта.

Одна и та же учётная запись пользователя **может иметь разные роли в разных проектах** (например: админ в проекте А, тестировщик в проекте В).

Роли определяют разрешения на действия с ресурсами проекта:

- Создание/редактирование/удаление потоков;
- Управление API-ключами;
- Публикация эндпоинтов;
- Запуск и просмотр логов;
- Экспорт/импорт и т.д.

Роли могут быть преднастроенными («Админ проекта», «Тестировщик» и др.) и редактируемыми админом организации через UI.

6.9.8.3.3 **Ключевые принципы иерархии**

Права не наследуются сверху вниз автоматически: членство в организации не дает по умолчанию доступ к проектам. Доступ к проекту — явное действие.

Права не наследуются снизу вверх: действия в проекте не влияют на организацию в целом.

Полная изоляция между организациями: пользователь из организации А не может видеть проекты организации В, даже если у него есть учётная запись в обеих.

Гибкость внутри проекта: владельцы проектов могут точно настраивать, кто и что может делать.

Эта иерархия закладывает основу для безопасной, масштабируемой и удобной работы с ИИ-решениями.

6.9.8.4 Описание пользовательских ролей

В платформе NoCode определяются преднастроенные роли. Каждая роль включает фиксированный набор разрешений, которые могут быть изменены админом организации. Роли применяются **на уровне проекта**, за исключением роли «Админ организации», которая действует на уровне организации.

6.9.8.4.1 Админ организации

Назначение: владелец и управляющий платформой NoCode внутри организации. Отвечает за пользователей, проекты и настройки на уровне организации.

Права на уровне организации:

- Должен иметь возможность приглашать пользователей в организацию по email.
- Должен иметь возможность назначать других пользователей админами организации.
- Должен иметь возможность удалять пользователей из организации.
- Должен иметь возможность создавать, переименовывать, архивировать и удалять проекты.
- Должен иметь возможность добавлять/удалять пользователей в проекты и назначать им любые роли.
- Должен иметь возможность редактировать предопределённые роли и создавать новые (через UI с галочками).
- Должен иметь возможность просматривать все проекты и все ресурсы (потoki, API-ключи, логи) внутри организации.

Запрещено: изменять параметры самой платформы (серверные настройки, глобальные компоненты) — это обязанность сервис-менеджера.

6.9.8.4.2 Админ проекта

Назначение: ответственный за разработку, тестирование и публикацию LLM-решений в рамках конкретного проекта (аналог: ML-инженер, промпт-инженер, low-code разработчик).

Права на уровне проекта:

- Должен иметь возможность создавать, редактировать, клонировать и удалять потоки (pipelines).
- Должен иметь возможность управлять API-ключами проекта (добавлять, редактировать, удалять).
- Должен иметь возможность запускать потоки и просматривать логи своих и чужих запусков в рамках проекта.
- Должен иметь возможность экспортировать и импортировать потоки.
- Должен иметь возможность публиковать потоки как API-эндпоинты.
- Должен иметь возможность добавлять в проект пользователей из списка членов организации и назначать им любые доступные роли.
- Должен иметь возможность просматривать ChatUI, привязанные к проекту.

Запрещено: управлять пользователями на уровне организации, изменять настройки других проектов, видеть API-ключи других проектов.

6.9.8.4.3 Тестировщик (Tester / Reviewer)

Назначение: проверяет корректность работы потоков без риска их случайного изменения (аналог: QA-инженер, продукт-менеджер).

Права на уровне проекта:

- Должен иметь возможность просматривать конфигурацию потоков в режиме «только для чтения».
- Должен иметь возможность запускать потоки через промпт-панель с произвольными входными данными.
- Должен иметь возможность просматривать логи выполнений (включая ошибки и метрики).
- Должен иметь возможность оставлять комментарии к потокам (привязанные к узлам или всему flow).

Запрещено: создавать, редактировать, удалять потоки; управлять API-ключами; публиковать эндпоинты; добавлять пользователей.

6.9.8.4.4 Пользователь проекта

Назначение: внешняя система или конечный пользователь, взаимодействующий с готовым решением.

Права на уровне проекта:

- Должен иметь возможность вызывать опубликованные API-эндпоинты (HTTP-запросы).
- Должен иметь возможность использовать готовые ChatUI-интерфейсы (веб-формы, чат-боты и т.п.).

Запрещено: доступ к интерфейсу Langflow, просмотр списка потоков, просмотр/редактирование API-ключей, просмотр логов, участие в управлении проектом.

6.9.8.4.5 Наблюдатель проекта

Назначение: сотрудник или стейкхолдер, которому требуется ознакомительный доступ к проекту.

Права на уровне проекта:

- Должен иметь возможность вызывать опубликованные API-эндпоинты.
- Должен иметь возможность использовать готовые ChatUI-интерфейсы.

Запрещено: то же, что и у «Пользователя проекта».

6.9.8.4.6 Сервис-менеджер

Назначение: технический администратор платформы (внутренняя роль, не для клиентов), не отображается в клиентской части UI.

Права на уровне платформы:

- Должен иметь возможность создавать организации.
- Должен иметь возможность назначать первых админов организаций.
- Должен иметь доступ к системным настройкам (сервер, глобальные компоненты, аудит).

- Должен иметь возможность просматривать все данные на платформе (в т.ч. все организации, проекты, API-ключи).

6.9.8.4.7 Общие требования к ролям

- Все роли, кроме «Сервис-менеджера», должны отображаться в UI и управляться через админ-панель организации.
- Пользователь может иметь **разные роли в разных проектах**.
- При добавлении пользователя в проект **обязательно** указывается роль.
- Список модулей/фич, по которым выставляются права (например: «Управление API-ключами», «Просмотр логов»), должен быть **фиксированным и не редактируемым** в UI.
- Все права проверяются **на бэкенде**; UI лишь скрывает недоступные элементы.

Ниже представлена диаграмма прецедентов (рис. 1).




Рисунок 1 - Диаграмма прецедентов

6.9.8.5 Сценарии использования

6.9.8.5.1 Создание организации и приглашение первых пользователей

Актор: Сервис-менеджер → Админ организации.

Цель: Настроить клиентскую организацию и добавить команду.

Последовательность:

1. Сервис-менеджер создаёт новую организацию (указывает название).
2. Сервис-менеджер назначает первого пользователя — админом организации (по email).
3. Админ организации получает email-приглашение, регистрируется и входит в платформу.
4. Админ организации приглашает трёх коллег:
 - одного — как разработчика,
 - одного — как тестировщика,
 - одного — как продукт-менеджера.
1. Все приглашённые пользователи получают доступ **только к организации**, но **ещё не к проектам**.

Требования к системе:

- Должна поддерживаться сущность «Организация».
- Должна работать система email-приглашений.
- Должна быть возможность назначать роль «Админ организации».
- Пользователи, добавленные в организацию, не получают автоматического доступа к проектам.

6.9.8.5.2 Админ организации назначает админа проекта

Актор: Админ организации, Разработчик.

Цель: Делегировать управление проектом ответственному лицу.

Последовательность:

1. Админ организации создаёт новый проект (название: «Чат-бот поддержки»).
2. Админ организации открывает раздел «Участники» проекта.
3. Из списка пользователей организации выбирает разработчика.
4. Назначает ему роль «**Админ проекта**».
5. Разработчик получает уведомление и теперь может:
 - создавать потоки,
 - управлять API-ключами,
 - публиковать эндпоинты.

Требования к системе:

- Должна быть страница управления участниками проекта.
- Должна поддерживаться роль «Админ проекта» с полным доступом к ресурсам проекта.
- Назначение роли должно быть явным действием (не по умолчанию).

6.9.8.5.3 Разработчик создаёт поток и приглашает тестировщика

Актор: Админ проекта (Разработчик), Тестировщик

Цель: Организовать безопасное тестирование без риска изменения логики.

Последовательность:

1. Админ проекта разрабатывает поток в NoCode.
2. Сохраняет поток, тестирует.
3. Открывает проект → «Участники» → добавляет пользователя с ролью **«Тестировщик»**.
4. Тестировщик заходит в проект:
 - видит поток в режиме **только для чтения**,
 - может запускать его с разными промптами,
 - может просматривать логи,
 - может оставлять комментарии.
5. Тестировщик **не видит** API-ключи и **не может** редактировать поток.

Требования к системе:

- Должна поддерживаться роль «Тестировщик» с ограниченным набором прав.
- Интерфейс Langflow должен динамически переключаться в режим «только просмотр».
- Должна быть реализована система комментариев к потокам.

6.9.8.5.4 Интеграция внешней системы через API с минимальными правами

Актор: Админ проекта, Внешняя система (бот, CRM, мобильное приложение)

Цель: Подключить продакшен-решение без предоставления доступа к UI.

Последовательность:

1. Админ проекта публикует поток как API-эндпоинт.
2. В настройках проекта создаёт учётную запись для внешней системы.
3. Назначает этой учётной записи роль **«Пользователь проекта»**.
4. Внешняя система получает:
 - URL эндпоинта,
 - API-key для аутентификации.
5. Система вызывает API — успешно.
6. При попытке открыть NoCode или список проектов — получает **ошибку 403** (отсутствие доступа).

Требования к системе:

- Должна поддерживаться роль «Пользователь проекта» с правами только на вызов API/UI.
- Должна быть невозможна утечка данных: API-ключи и потоки скрыты от этой роли.
- Должна работать аутентификация ключу для API-вызовов.

6.9.8.5.5 Демонстрация готового решения заказчику (роль «Наблюдатель»)

Актор: Админ проекта, Заказчик (внешний пользователь)

Цель: Показать рабочий чат-бот без риска раскрытия внутренней логики.

Последовательность:

1. Админ проекта создаёт ChatUI на основе готового потока.
2. Приглашает email заказчика в организацию (роль — участник без прав).
3. Добавляет заказчика в проект с ролью **«Наблюдатель проекта»**.
4. Заказчик заходит в платформу:
 - видит только ChatUI (веб-интерфейс чат-бота),
 - может взаимодействовать с ним,
 - **не видит** NoCode, список потоков, настройки, логи.
5. Заказчик не может экспортировать, копировать или анализировать внутреннюю структуру решения.

Требования к системе:

- Должна поддерживаться роль «Наблюдатель проекта».
- ChatUI должен быть доступен отдельно от NoCode-редактора.

6.9.8.6 Раздел UI-архитектура: страницы и компоненты

Все экраны, связанные с управлением доступом, группируются вокруг сущности **Организация**. Основной точкой входа для администрирования является страница **«Настройка организации»**.

Полный доступ к странице «Настройка организации» — только у **Админа организации**.

Ограниченный доступ к подразделам **«Пользователи и группы»** и **«Управление ролями»** — у **Админа проекта**, но **только в контексте своей организации и только для просмотра**.

В **шапку** (Header) приложения добавляется **селектор Организации** (доступные пользователю) и **ID текущей организации**.

6.9.8.6.1 Главная навигация (меню настроек в шапке)

Меню настроек доступно через **иконку «Настройки»** в правой части **верхней шапки приложения**.

При нажатии на иконку отображается **выпадающее меню** со следующими пунктами:

- **Версия приложения** — отображает текущий номер версии (например: v1.5.0)
- **Настройки** — переход на личные настройки пользователя (профиль, уведомления, безопасность) (**На обсуждение**)
- **Настройки организации** — отображается, только если пользователь является админом организации или админом хотя бы одного проекта в текущей организации.
- **Тема** — переключатель между режимами:
 - Светлая
 - Тёмная
 - Системная (по умолчанию)

При переходе в «Настройки организации»:

- **Админ организации** → полный доступ
- **Админ проекта** → ограниченный доступ (в подразделе «Проекты» только его проекты, только просмотр подразделов «Пользователи и группы» и «Управление ролями»).

6.9.8.6.2 Страница: «Настройка организации»

URL: /org/{org_id}/settings

Доступ:

- **Админ организации:** полный доступ — редактирование, создание, удаление.
- **Админ проекта:** на вкладке «Проекты» только его проекты, вкладки «Пользователи и группы» и «Управление ролями» **только для просмотра**.
- Все остальные роли: страница недоступна (ошибка 403).

Заголовок: «Настройки организации».

Подменю (вкладки):

1. **Проекты** — Админа организации, Админ проекта (только его проекты).
2. **Пользователи и группы** — Админ организации (редактирование), Админ проекта (только просмотр)
3. **Управление ролями** — Админ организации (редактирование), Админ проекта (только просмотр)
4. **Системные настройки** — только для Админа организации (**На обсуждение**)

6.9.8.6.3 Раздел: «Системные настройки»

(доступна только Админу организации)

URL: /org/{org_id}/settings/config

Компоненты:

- Логотип организации (загрузка)
- Глобальные переменные уровня организации
- Другие компоненты

(Необходимо обсудить содержание)

6.9.8.6.4 Раздел «Проекты»

URL: /org/{org_id}/settings/projects

Назначение: централизованное управление проектами в рамках организации.

Для Админа организации:

- Видит **все проекты** организации.
- Может **создавать, редактировать, удалять** проекты.
- Может **назначать админов проектов**.
- Кнопка «**Создать проект**» — активна.

Для Админа проекта:

- Видит **только те проекты, в которых он является участником** (обычно — только свои).
- Для каждого из них имеет **полный доступ**:
 - Может заходить в проект,
 - Редактировать потоки,
 - Управлять API-ключами,
 - Добавлять участников и т.д.
- Не видит проекты, где он не состоит — даже в той же организации.
- Кнопка «+ Создать проект» — скрыта (если не наделён правом явно).

Компоненты:

- Заголовок: «Проекты *иконка проекта*»
- (Для Админа орг.) Кнопка «+ Создать проект»
- Таблица проектов с колонками:
 - Название
 - ID
 - Статус
 - Дата изменения
 - Кнопка удалить (Только у Админа организации)

При клике на проект — переход на **/org/{org_id}/project/{proj_id}**

6.9.8.6.5 Раздел: «Пользователи и группы»

URL: /org/{org_id}/settings/members

Назначение: управление составом организации — добавление и удаление участников.

Доступ:

- **Админ организации:**
 - Может приглашать новых пользователей в организацию по email.
 - Может удалять пользователей из организации.
 - Может назначать других пользователей **админами организации**.
 - Может загружать список пользователей (**Типы документов**).
 - Видит полную информацию: ФИО, email, дату приглашения, статус («приглашён», «активен», «удалён»).
- **Админ проекта:**
 - Видит **только таблицу активных участников** (статус = «активен»).
 - **Не видит** пользователей с непринятыми приглашениями.

- **Не видит** кнопки управления (приглашение, загрузка, удаление, назначение админа).
- Интерфейс отображается в **режиме «Только просмотр»** (например, с полупрозрачным слоем или баннером).

Компоненты:

- **Кнопка «Пригласить пользователя»** (только для Админа организации):
Открывает форму с полями: **Email, ФИО, роль в организации (не для проекта)**. После отправки пользователь получает email-приглашение.
- **Кнопка «Импортировать»** (только для Админа организации)
Файл должен содержать email и ФИО, роль в организации. Остальные поля игнорируются.
- **Таблица участников** (колонки):
 - **Email**
 - **ФИО**
 - **Статус:**
 - *Приглашён* (не принято)
 - *Активен*
 - *Удалён*
 - **Роль в организации:**
 - *Админ организации*
 - *Участник*
 - **Дата добавления**

Поведение при приглашении:

- Приглашённый пользователь получает доступ **только к организации**, но не к проектам.
- Чтобы получить доступ к проекту, его должен **добавить в проект** Админ проекта или Админ организации — и **только тогда указывается роль** («Админ проекта», «Тестировщик» и т.д.).

6.9.8.6.6 Раздел: «Управление ролями»

URL: /org/{org_id}/settings/roles

Назначение: Позволяет администратору организации настраивать и управлять ролями, которые могут быть назначены пользователям при добавлении их в проекты.

Доступ

- **Админ организации:**
 - Полный доступ: просмотр, создание, редактирование, копирование, удаление ролей.
 - Может изменять набор разрешений для каждой роли через интерфейс.
- **Админ проекта:**
 - Только **просмотр списка ролей** (название, описание, количество пользователей).
 - **Не может** редактировать, создавать или удалять роли.
 - Матрица разрешений отображается в **некликабельном (disabled) виде** или скрыта.

Основные компоненты интерфейса

Заголовок страницы

- Текст: «Управление ролями»
- Кнопка **«Создать»** (видна только Админу организации, в правом верхнем углу)

Таблица ролей

Колонки:

- **Название роли** (например: «Админ проекта», «Тестировщик»)
- **Описание** (краткое пояснение назначения роли)
- **Количество пользователей** (суммарно по всем проектам организации)
- **Дата создания**

Форма создания/редактирования роли (модальное окно)

Поля:

- **Название роли** — текстовое поле, обязательно для заполнения
- **Описание** — многострочное поле, опционально
- **Матрица разрешений (фиксированный список модулей)**
Отображается в виде блоков с галочками. Список модулей **нередактируемый** и определён на уровне платформы:
 - Управление пользователями (приглашение, удаление в проекте)
 - Управление проектами (создание, архивация — только на уровне организации)
 - Создание и редактирование потоков
 - Экспорт / импорт потоков
 - Управление API-ключами проекта
 - Просмотр и редактирование глобальных переменных
 - Публикация API-эндпоинтов
 - Запуск потоков и просмотр логов выполнения
 - Оставление комментариев к потокам
 - Просмотр артефактов других пользователей в проекте

Преднастроенные роли

При создании организации автоматически создаются следующие роли (нельзя удалить, но можно копировать и редактировать их клоны):

- Админ проекта
- Тестировщик
- Пользователь проекта
- Наблюдатель проекта

Правила и ограничения

- Роль **«Админ организации»** — системная, недоступна для редактирования и не отображается в списке проектных ролей.
- Удаление роли возможно **только если она не назначена ни одному пользователю** в каком-либо проекте.

- При копировании роли создаётся дубликат с суффиксом «(копия)» и возможностью немедленного переименования.
- Все изменения сохраняются по нажатию кнопки **«Сохранить»**; изменения вступают в силу немедленно для новых и существующих назначений.

Интеграция с другими частями системы

- При добавлении пользователя в проект (страница /project/{id}/members) в выпадающем списке «Роль» отображаются **все роли**, созданные в организации.
- При изменении набора прав роли — изменения **автоматически применяются** ко всем пользователям, у которых назначена эта роль (без необходимости переназначения).

Визуальные требования

- Для Админа проекта: все чекбоксы в матрице — серые, недоступные для взаимодействия.
- При наведении на disabled-галочку — подсказка: *«Только для просмотра. Изменения доступны админу организации.»*
- Успешное создание/редактирование роли — сопровождается системным уведомлением.

6.9.8.6.7 Страница: «Настройки проекта»

URL: /project/{project_id}/settings

Способ открытия:

Клик по проекту в списке на странице **«Проекты»** (/org/{org_id}/settings/projects)

На странице проектов выбранной организации открыть выпадающее меню нужного проекта (нажать на иконку «Три точки» напротив названия) и выбрать пункт **Настройки**.

Назначение: Централизованное управление метаданными, доступом, ресурсами и конфигурацией проекта **без редактирования потоков**.

Доступ:

- **Админ проекта** — полный доступ ко всем разделам
- **Админ организации** — полный доступ

Структура страницы

Страница организована в виде **вкладок**.

Над вкладками располагается **блок с Названием и описанием** проекта, **кнопками экспорта и удаления** проекта, а также **переключатель (switch) для активации или архивации** проекта.

- **Общие настройки**
- **Участники**
- **Лимиты**
- **API-ключи**
- **Глобальные переменные**

Общие настройки

- **Название проекта** — текстовое поле
 - Требование: должно быть уникальным в рамках организации. При конфликте — подсветка ошибки.

- **Описание** — многострочное поле (опционально)
- **Дата создания** — только для чтения
- **Дата изменения** — только для чтения
- **ID проекта** — только для чтения, при наведении появляется кнопка «Копировать».

Внизу находится кнопка **«Редактировать»**. При нажатии на кнопку форма становится активной (поля **Название** и **Описание**, другие только для чтения), кнопка «Редактировать» скрывается, появляются кнопки «Отменить» и «Сохранить» внизу раздела.

Участники

- Отображает всех пользователей, имеющих доступ к проекту.
- **Таблица** с колонками:
 - ФИО
 - Email
 - Роль в проекте (например: «Админ проекта», «Тестировщик»)
 - Дата добавления
 - Добавлен кем
- **Действия:**
 - **«Добавить участника»** — открывает форму для добавления пользователя организации и указать его роль, а также дополнительные права для этого проекта
 - **«Изменить участника»** — открывает форму для изменения участника проекта с возможностью изменить его роль, а также дополнительные права для этого проекта.
 - **«Удалить из проекта»** — с подтверждением

Пользователь не может удалить самого себя, если он единственный админ проекта.

Админ организации может добавлять/удалять кого угодно.

Лимиты

Необходимо обсудить содержание раздела!

API-ключи

(описаны ключи, которые будут использоваться на уровне проектов)

- Управление секретными ключами, используемыми **внутри потоков проекта**.
- Кнопка **«Добавить ключ»** — открывает форму:
 - Название
 - Значение ключа (поле ввода, маскируется после сохранения)
- **Таблица ключей:**
 - Название
 - Тип
 - Маскированное значение (sk-...xyz)
 - Дата создания
- **Действия:**

- Редактировать название и значение
- Удалить навсегда

Ключи **привязаны строго к проекту и недоступны** в других проектах, даже той же организации.

Глобальные переменные

- Хранение конфиденциальных или часто используемых значений (промты, URL, токены, шаблоны).
- Кнопка **«Добавить переменную»** — форма:
 - Имя (например: WELCOME_MESSAGE) — только латиница, цифры, _
 - Значение (многострочное поле)
 - Описание (опционально)
 - Флаг **«Секрет»** — если включён, значение маскируется везде (как API-ключ)
- **Таблица переменных:**
 - Имя
 - Описание
 - Тип («Обычная» / «Секрет»)
 - Дата создания
- **Действия:**
 - Редактировать
 - Удалить

Секретные переменные **никогда не логируются и не отображаются в UI** выполнения.

Общие требования

- Все данные сохраняются **только по нажатию «Сохранить»** (нет автосохранения).
- При удалении API-ключа или переменной — отображается предупреждение: «Этот ресурс может использоваться в потоках. Удаление может нарушить их работу.»
- Все действия логируются в аудит: *кто изменил ключ, добавил участника и т.д.*
- Интерфейс **не содержит** ссылок на редактор потоков, логи выполнений или ChatUI — только управление проектом как сущностью.

6.10 Чат MWS GPT

6.10.1 Интеграция получения статуса премиум-подписки через MTS ID

6.10.1.1 Ссылки

Задача на разработку - [\[LLMPLA-1392\]](https://track.pf.mts.ru/browse/LLMPLA-1392) Интеграция получения статуса премиум-подписки через MTS ID²⁸

²⁸ <https://track.pf.mts.ru/browse/LLMPLA-1392>

6.10.1.2 Описание задачи

Необходимо реализовать поддержку получения статуса премиум-подписки пользователя через MTS ID и унифицировать механизм проверки подписки в системе.

Требуется:

Логика проверки подписки

1. На этапе аутентификации получать статус подписки пользователя через MTS ID.
2. В случае отсутствия активной подписки в MTS ID выполнять проверку статуса подписки через CloudPayments.
3. Отмену подписки на текущем этапе оставить реализованной только через CloudPayments.

Требования

- Методы проверки подписки через CloudPayments и MTS ID должны быть реализованы как низкоуровневые.
- Все взаимодействие с подпиской должно осуществляться через единый унифицированный слой (например, метод checkPremium или аналогичный).
- Унифицированные методы должны инкапсулировать логику проверки подписки через:
 - MTS ID,
 - CloudPayments.
- Вся бизнес-логика приложения должна использовать только единые методы проверки подписки, без прямого обращения к CloudPayments или MTS ID.

6.10.1.3 Реализация

6.10.1.3.1 Особенности

На момент разработки в MTS ID **отсутствовал эндпоинт для проверки статуса премиум-подписки**. Поэтому было решено разработать мок-сервис, имитирующий проверку через MTS ID.

Также было решено сделать **кэширование данных**, чтобы каждый раз не обращаться к MTS ID и CloudPayments. Жизнь кэша по умолчанию составляет 1 час.

Управление проверками (отключение и указание значения моковых данных, а также время жизни кэша) реализовано через **переменные окружения**.

6.10.1.3.2 Переменные окружения (env)

`MTS_ID_API_BASE` (string)- базовый url API MTS ID;

`MTS_ID_USE MOCK` (boolean)- флаг использования мок-сервиса MTS ID.

`MTS_ID MOCK_ACTIVE` (boolean) - статус активности подписки для мок-сервиса MTS ID.

`MTS_ID MOCK_TARIFF` - тариф для мок-сервиса

`MTS_ID MOCK_USER` (string с перечислением через запятую) - id пользователей, у которых активна подписка мок-сервиса MTC ID.

`MTS_ID_SKIP_CHECK` (boolean) - пропуск проверки через MTC ID.

`PREMIUM_CACHE_TTL_MS` (number) - время жизни кэша статуса подписки.

6.10.1.3.3 Бэкенд

Был разработан сервис **premium** (`api/server/services/premium`), состоящий из следующих файлов:

6.10.1.3.3.1 `premiumService.js`

- модуль, из которого экспортируются две основные функции:

- `checkPremium(userId: string, useCache: boolean)` - функция проверки активности подписки. **userId** - id пользователя, у которого проверяется подписка, **useCache** - флаг, отвечающий за то - будем ли мы брать информацию из кэша или нет. Функция выполняется по следующим этапам:
 - i. **Проверяется берем ли мы информацию из кэша.** Если берем, то проверяем, не просрочен ли он. Если нет, то возвращаем информацию из кэша с дополнительным флагом "fromCache: true", на этом вызов завершается. Если не берем данные из кэша или они уже просрочены, то переходим к следующему шагу.
 - ii. **Проверяется подписка через MTS ID.** Так как на момент реализации используется мок-сервис, в данном блоке функция обращается к провайдеру, в котором уже, в зависимости от настроек системы, идет дальнейшая проверка - либо через мок-сервис, либо через MTC ID. Если ответ успешен (подписка активна), мы возвращаем ответ, на этом вызов завершается. Если же подписка неактивна - переходим к следующему шагу.
 - iii. **Проверяется подписка через CloudPayments.** В этом случае информация возвращается.
 - iv. Если на любом из этапов происходит ошибка, функция возвращает текст ошибки с неактивным статусом подписки. На этом завершается вызов ошибки.
 - v. Если нет ошибок, то система кэширует данные (функция `_saveToCache`) и функция возвращает полученную информацию.
- `cancelPremium(subscriptionId: string, source: string = 'cloudpayments')` — функция отмены активной премиум-подписки пользователя. `subscriptionId` — идентификатор подписки, которую необходимо отменить; `source` —

источник подписки ('cloudpayments' | 'mts-id'), по умолчанию 'cloudpayments'.

Функция выполняется по следующим этапам:

- i. **Проверка поддержки источника отмены.** Если переданный source отличается от 'cloudpayments', функция логирует предупреждение о том, что отмена для данного источника не реализована, и возвращает объект { success: false, error: 'Cancellation not implemented for \${source}' }. На этом выполнение завершается.
- ii. **Попытка отмены подписки через CloudPayments.** Если источник корректен, функция вызывает низкоуровневый метод cancelCloudPaymentsSubscription(subscriptionId), который взаимодействует с внешним API платёжной системы.
- iii. **Обработка результата отмены.** Полученный статус интерпретируется следующим образом:
 - Если status === 0 — отмена прошла успешно, логируется информационное сообщение, возвращается { success: true, code: 0 }.
 - Если status !== 0 — отмена не выполнена, логируется предупреждение с кодом статуса, возвращается { success: false, code: status }.
 - **Обработка ошибок.** Если на любом из этапов возникает исключение (ошибка сети, некорректный ответ API и т.п.), функция логирует ошибку с деталями и возвращает объект { success: false, error: err.message }.

Примечание: На текущем этапе отмена подписки реализована только для источника cloudpayments. Поддержка отмены через MTS ID может быть добавлена в будущем при наличии соответствующего API-эндпоинта.

6.10.1.3.3.2 mtsIdProvider.js

- **checkMtsId(userId: string)** — функция-провайдер (маршрутизатор), которая определяет источник проверки статуса премиум-подписки через MTS ID и делегирует выполнение соответствующему сервису. userId — идентификатор пользователя, для которого выполняется проверка. Функция возвращает Promise, который резолвится в объект вида { active: boolean, source: string, data?: object }.

Функция выполняется по следующим этапам:

- i. **Определение режима работы.** Функция проверяет конфигурационный флаг config.FLAGS.USE_MTS_ID MOCK, который устанавливается через переменную окружения MTS_ID_USE MOCK. Этот флаг определяет, будет ли использоваться мок-сервис для имитации проверки подписки или реальный внешний API MTS ID.
- ii. **Маршрутизация запроса.** В зависимости от значения флага выполняется один из двух сценариев:

- **Режим мока (`USE_MTS_ID MOCK === true`):** вызывается функция `checkMtsIdMockSubscription(userId)` из модуля `./mtsIdMockService`. В этом режиме проверка подписки эмулируется на основе локальных настроек (список тестовых пользователей `MTS_ID MOCK_USER`, статус `MTS_ID MOCK_ACTIVE`, тариф `MTS_ID MOCK_TARIFF`).
 - **Режим продакшена (`USE_MTS_ID MOCK === false`):** вызывается функция `checkMtsIdSubscription(userId)` из модуля `./mtsIdService`. В этом режиме выполняется реальный сетевой запрос к внешнему API MTC ID (базовый адрес берется из `MTS_ID_API_BASE`).
- iii. **Возврат результата.** Результат выполнения выбранного сервиса (мока или реального) возвращается вызывающей стороне без модификации.

Примечание: Данная функция инкапсулирует логику выбора источника данных, позволяя вышестоящим слоям (например, `premiumService.js`) не зависеть от того, используется ли в данный момент мок или реальная интеграция. Обработка ошибок, специфичных для каждого источника, выполняется внутри соответствующих сервисов (`mtsIdMockService` или `mtsIdService`).

6.10.1.3.3.3 `mtsIdMockService.js`

- **`checkMtsIdMockSubscription(userId: string)`** — функция эмуляции проверки статуса премиум-подписки через MTC ID. Используется в тестовых и разработческих средах для имитации ответа внешнего API без реальных сетевых запросов. `userId` — идентификатор пользователя, для которого выполняется проверка. Функция возвращает Promise, который резолвится в объект вида `{ active: boolean, source: string, mocked: boolean, data: object }`.
- Функция выполняется по следующим этапам:
- i. **Чтение конфигурации из переменных окружения.** Функция считывает три переменные окружения, управляющие поведением мок-сервиса:
 - `MTS_ID MOCK_ACTIVE` — глобальный флаг активности подписки. Если значение `'true'`, подписка считается активной по умолчанию.
 - `MTS_ID MOCK_TARIFF` — название тарифа, которое возвращается в данных подписки (по умолчанию `'pro'`).
 - `MTS_ID MOCK_USER_IDS` — список разрешённых `userId` через запятую. Если список пуст, подписка активна для всех пользователей (при условии `MTS_ID MOCK_ACTIVE=true`). Если список заполнен, подписка активна только для пользователей из этого списка.
 - ii. **Определение статуса активности подписки.** Статус `isActive` вычисляется по следующей логике:
 - Если `MTS_ID MOCK_ACTIVE !== 'true'` — подписка неактивна для всех пользователей.

- Если `MTS_ID MOCK_ACTIVE === 'true'` и список `MTS_ID MOCK_USER_IDS` пуст — подписка активна для любого пользователя.
 - Если `MTS_ID MOCK_ACTIVE === 'true'` и список заполнен — подписка активна только если `userId` присутствует в списке (после обрезки пробелов и фильтрации пустых значений).
- iii. **Логирование результата.** Функция записывает в лог отладочное сообщение с информацией о пользователе, вычисленном статусе активности и тарифе. Это упрощает диагностику поведения мок-сервиса в процессе разработки и тестирования.
 - iv. **Формирование и возврат ответа.** Функция возвращает стандартизированный объект.

Примечание: Мок-сервис не выполняет никаких внешних запросов и не взаимодействует с реальной инфраструктурой МТС ID. Он предназначен исключительно для локальной разработки, тестирования интеграции и демонстрации функционала. В продакшен-среде рекомендуется использовать реальный сервис (`mtsIdService.js`) с отключенным флагом `MTS_ID_USE MOCK`.

6.10.1.3.3.4 `mtsIdService.js`

- **`checkMtsIdSubscription(userId: string, options: object = {})`** — функция проверки статуса премиум-подписки через реальный API МТС ID. На текущем этапе представляет собой заглушку (`stub`), имитирующую будущую интеграцию с внешним сервисом. `userId` — идентификатор пользователя, для которого выполняется проверка; `options` — объект дополнительных параметров (может содержать `apiToken` для аутентификации). Функция возвращает `Promise`, который резолвится в объект вида `{ active: boolean, source: string, data?: object, configured: boolean }`.

Функция выполняется по следующим этапам:

- i. **Подготовка параметров запроса.** Функция принимает `userId` и опциональный объект `options`, который в будущей реализации может содержать:
 - `apiToken` — токен доступа к API МТС ID для аутентификации запроса.
 - Другие параметры, необходимые для взаимодействия с внешним сервисом (таймауты, версии API и т.п.).
- ii. **Определение статуса активности подписки.** На текущем этапе реализации функция возвращает заглушку:
 - `isActive` всегда устанавливается в `true` независимо от `userId`.
 - В будущей версии здесь будет выполняться реальный HTTP-запрос к внешнему API МТС ID (базовый адрес берётся из `MTS_ID_API_BASE`).

- iii. **Формирование и возврат ответа.** Функция возвращает стандартизированный объект.

Примечание: Данная функция является временной заглушкой до момента предоставления полноценного API со стороны MTC ID. В продакшен-режиме рекомендуется использовать мок-сервис (`mtsIdMockService.js`) для тестирования логики приложения, так как реальная интеграция на текущем этапе не функциональна. При появлении документации к API MTC ID функция должна быть доработана для выполнения реальных сетевых запросов с обработкой токенов, таймаутов и ошибок.

6.10.1.3.3.5 `cloudPaymentsService.js`:

- **`checkCloudPaymentsSubscription(userId: string)`** – функция проверки статуса активной премиум-подписки через платёжную систему CloudPayments. `userId` – идентификатор пользователя (`AccountId`), для которого выполняется проверка. Функция возвращает Promise, который резолвится в объект вида `{ active: boolean, source: string, transactionInfo?: object }`.

Функция выполняется по следующим этапам:

- i. **Запрос подписок пользователя.** Функция обращается к внешнему API CloudPayments через утилиту `cloudPayments.subscriptions.find()`, передавая `userId` в качестве `AccountId`. Получает список всех подписок, связанных с данным пользователем.
- ii. **Фильтрация и сортировка активных подписок.** Из полученного списка подписок выполняется:
 - **Фильтрация:** оставляются только подписки со статусом `'Active'`.
 - **Сортировка:** подписки сортируются по дате последней транзакции (`LastTransactionDateIso`) в порядке убывания (сначала самые свежие).
 - **Выбор:** из отфильтрованного списка выбирается первая подписка (самая актуальная). Если активных подписок нет – `currentSubscription` устанавливается в `null`.
- iii. **Определение статуса активности.** Статус `isActive` устанавливается в `true`, если найдена активная подписка (`currentSubscription?.Status === 'Active'`), в противном случае – `false`.
- iv. **Формирование и возврат ответа.** Функция возвращает стандартизированный объект.
- v. **Обработка ошибок.** При возникновении ошибки (сеть, неверный ответ API и т.п.) функция логирует ошибку с деталями и пробрасывает исключение дальше для обработки вышестоящим слоем.

- **cancelCloudPaymentsSubscription(subscriptionId: string)** — функция отмены активной подписки через платёжную систему CloudPayments. subscriptionId — идентификатор подписки, полученный из transactionInfo.subscriptionId. Функция возвращает Promise<number> — статус операции от подписки.

Функция выполняется по следующим этапам:

- Вызов API отмены подписки.** Функция делегирует выполнение утилите cloudPayments.subscriptions.cancel(subscriptionId), которая отправляет запрос к внешнему API CloudPayments на отмену рекуррентного платежа.
- Возврат статуса операции.** Функция возвращает числовой статус, полученный от API CloudPayments:
 - 0 — отмена выполнена успешно.
 - Любое другое значение — код ошибки от платёжной системы.

6.10.1.3.3.6 config.js

— модуль централизованной конфигурации сервиса премиум-подписки. Парсит переменные окружения и экспортирует структурированные настройки для остальных модулей.

Секция	Ключ	Переменная окружения	По умолчанию	Описание
CACHE	TTL_MS	PREMIUM_CACHE_TTL_MS	300000 (5 мин)	Время жизни кэша статуса подписки
FLAGS	USE_MTS_ID_MOCK	MTS_ID_USE_MOCK	false	Переключает MTC ID провайдер на мок-режим
FLAGS	SKIP_MTS_ID_CHECK	MTS_ID_SKIP_CHECK	false	Полностью пропускает проверку через MTC ID

Важно: Флаги активируются только при значении 'true' (строка). Изменения конфигурации применяются после перезапуска приложения.

6.10.1.3.4 Фронтенд

Информация о тарифах и текущем статусе подписки приходит в следующих эндпоинтах:

- GET /api/user

Ответ:

```
{
  ...,
  "premium": {
    "active": boolean, //активность подписки
    "source": "mts-id-mock" | "mts-id" | "cloudpayments", //источник
подписки
    "transactionInfo": { // информация о тарифе (если источник
"cloudpayments")
      "lastTransactionDate": date | null, //дата последнего платежа
      "nextTransactionDate": date, //дата следующего платежа
      "currency": string, //валюта платежа
      "amount": number, //сумма платежа
      "subscriptionId": string //индификатор подписки
    } | null
  }
}
```

- GET /api/premium/tariffs

Ответ:

```
{
  "tariffs": [ //список тарифом
    {
      "title": string, //название тарифа
      "id": string, //индификатор тарифа
      "current": boolean, //статус тарифа
      "price": number, // цена тарифа
      "features": [ //возможности подписки
        {
          "label": string, //название функционала
          "icon": string //название иконки
        },
        ...
      ]
    }
  ]
}
```

```

    ]
    },
    ...
  ]
}

```

На стороне фронта уже была разработана форма для управления подпиской (изменение тарифа, отмена подписки, просмотр текущего тарифа). Необходимо разработать отдельную форму для пользователей с активным МТС Премиум.

Формы отображаются через единое диалоговое окно (`client/src/components/Premium/SubscriptionSettings/SubscriptionSettingsModal.tsx`). В зависимости от текущего статуса подписки/выбранного тарифа отображается определенная форма:

- **Тариф "Бесплатно"** - отображается форма выбора тарифа, изображенная на рисунок 1 (`client/src/components/Premium/SubscriptionSettings/Screens/TariffsList.tsx`).




Рисунок 1 - Окно "Выбор тарифа"

- **Тариф "Pro"** - отображается форма текущего тарифа с информацией о самом тарифе: что в него входит, до какой даты работает и сколько стоит. Также есть возможность отменить подписку и посмотреть историю платежей. Форма изображена на рисунке 2 (`client/src/components/Premium/SubscriptionSettings/Screens/CurrentTariffScreen/`).

CurrentTariffScreen.tsx).




Рисунок 2 - окно "Управление подпиской. Текущий тариф"

Для пользователей с подпиской МТС Премиум была разработана отдельная форма, так как в данном случае управление подпиской осуществляется через МТС ID (`client/src/components/Premium/SubscriptionSettings/Screens/MtsIdTariffInfo/MtsIdTariffInfo.tsx`). У таких пользователей активен тариф **"Pro"**. На форме необходимо было отобразить следующее:

- Сообщение, что у пользователя активирован МТС Премиум;
- Сообщение, что управление подпиской осуществляется через МТС ID;
- Отображение текущего тарифа и его описание.

Форма изображена на рисунке 3.




Рисунок 3 - окно "Управление подпиской" у пользователей с подпиской МТС Премиум

Часть элементов формы было решено их вынести в **отдельные компоненты**.

1. `client/src/components/Premium/components/TariffFeaturesList.tsx` - Компонент для отображения списка возможностей тарифа.
2. `client/src/components/Premium/components/SubscriptionStatusBadge.tsx` - Компонент для отображение статуса тарифа ("Активен", "Истек" и т.п.).
3. `client/src/components/Premium/components/InfoNote.tsx` - компонент для отображения примечаний к подписке и тарифу.
4. `client/src/components/Premium/components/CancelSubscriptionSection.tsx` - Компонент для отмены подписки.
5. `client/src/components/Premium/components/PaymentInfoCard.tsx` - Компонент с данными об оплате подписки.

7 Техническая поддержка MWS GPT

7.1 FAQ

7.1.1 Как начать работу?



Прочитайте наш гайд [Как начать работу?](#) (see page 173)

7.1.2 Какие модели у вас есть?



У нас очень много LLM и каждый раз список пополняется
Чтобы получить актуальный список доступных моделей - посетите UI (<https://ui.llmops.mts-corp.ru/login>) или сделайте вызов метода GET /v1/models

7.1.3 Какая модель лучше для ... ?



Однозначного ответа нет, качество ответа по большей части зависит не от модели, а от вашего промпта

Для того, чтобы выбрать какая модель подойдет для вашей задачи нужно следовать нескольким простым шагам:

1. **Сделать качественный промпт** (Почитать подробнее о том, как делать качественные промпты можно здесь - <https://www.promptingguide.ai/ru>)
2. **Сравнить ответы нескольких моделей** (Выберите несколько моделей, и отправьте один и тот же промпт в них, сравните качество ответов и выберите ту, которая вас больше всего устраивает)

3. **Докрутить параметры моделей** (Не забудьте поиграть с параметрами LLM, это очень сильно влияет на качество ответа, чтобы узнать о том, как влияют разные параметры на ответ модели, можете почитать здесь - <https://www.promptingguide.ai/ru/introduction/settings>)

7.1.4 Отправляю запрос с локального компьютера из внутренней сети, а он не проходит

- ✓ Проверьте, не используете ли вы прокси
Если вы используете прокси, допустим, для загрузки внешних библиотек, укажите пожалуйста параметр `no_proxy` для внутренних и локальных адресов
`"localhost,*.mts.ru,*.mts.ru,*.mts-corp.ru"`

7.1.5 Отправляю запрос а он ругается на сертификаты

- ✓ Установите сертификаты с <https://pki.mts.ru/>
При использовании библиотеки `requests` в `python` (наследуется в библиотеке `OpenAI`) обязательно укажите ему переменную окружения `REQUESTS_CA_CERTIFICATES`=путь до вашего бандла сертификатов

7.1.6 Как сделать RAG ?

- ✓ Ознакомьтесь с документацией `Langchain` - <https://docs.langchain.com/oss/python/langchain/rag>
Или используйте наш No-Code конструктор - <https://langflow.llmops.mts-corp.ru/login>
Как сделать RAG в `Langflow` - <https://docs.langflow.org/chat-with-rag>

7.1.7 Как сделать агента ?



Ознакомьтесь с документацией Langchain - <https://docs.langchain.com/oss/python/langchain/agents>
Или используйте наш No-Code конструктор - <https://langflow.llmops.mts-corp.ru/login>
Как сделать агента в Langflow - <https://docs.langflow.org/agents>

7.1.8 Почему запрос обрабатывается так долго?



LLM не работают с "гарантированным RPS"
Скорость ответа моделей зависит от количества возвращаемого текста
Модели генерируют выходные токены, и параметром скорости модели является TPS (возможно, вы могли наблюдать, что в нашем чате модели отвечают так, будто печатают текст, это и есть генерация токенов)
Для того чтобы поддержать позитивный User-Experience у нас есть функционал асинхронной генерации
Для вашего пользователя это будет выглядеть так же, как и в нашем чате, ответ модели будет возвращаться как будто печатается текст, это очень важно в случае, если ваша интеграция генерирует очень большой ответ
Это позволяет пользователю не ждать ответ N секунд, а сразу видеть результаты генерации
Более подробно про асинхронные ответы можно почитать в нашей документации на главной странице раздела в Confluence [MWS GPT \(ex. LLMOps Platform\)](#) (see page 9) или в разделе [Как начать работу?](#) (see page 173)

7.1.9 Модель лежит, я получаю ошибку `APITimeoutError: Request timed out`, что делать?



Модели генерируют ответы токенами, и их скорость измеряется в TPS (Tokens Per Second)
И как вы могли заметить, в чате модели отвечают этими самыми токенами (кусочками текста, как будто печатают)

Так же у воркера модели есть такой параметр как Concurrency (сколько конкуретных запросов модель обрабатывает в event-loop, от 32 до 128 на 1 воркер в случае нашей платформы)

Как это работает:

Пришло 32 запроса, и модель всем из event-loop отвечает токенами в зависимости от блокировок

Если приходит 33 запрос - он попадает в очередь, пока не закончится генерация одного из 32 текущих запросов

Задачу очереди решают параллельные воркеры

Как ускорить ваш запрос? Более подробно про асинхронные ответы можно почитать в нашей документации на главной странице раздела в Confluence [MWS GPT \(ex. LLMOps Platform\)](#) (see page 9) или в разделе [Как начать работу?](#) (see page 173)

В таком случае вы сразу будете получать "токены" которые генерируются для вашего ответа

Как ускорить синхронный запрос?

Ускорить запрос невозможно, т.к. скорость ответа зависит не от ресурсов под моделью, а от скорости токенизации и длинны ответа

Соответственно если мы генерируем ответы длиной 1 000 токенов и 10 000 токенов со скоростью модели в 1000 TPS то:

1ый ответ мы сгенерируем за 1 секунду, а второй за 10 соответственно

SLA на Request time "Модели" не существует, т.к. скорость зависит от длинны ответа и токенизатора модели

SLA сервиса на данный момент по классу критичности (business support) - 99%

В дальнейшем планируется расширение класса критичности до Mission Critical - 99.95%

С Аптаймом сервиса можете ознакомиться в нашей графанае - <https://grafana-gbp.genai.mts-corp.ru/login> (логин: reader, пароль: reader)

7.1.10 Как посмотреть доступность платформы?



С доступностью платформы можете ознакомиться в нашей графанае - <https://grafana-gbp.genai.mts-corp.ru/login> (логин: reader, пароль: reader)

7.1.11 Кто может проконсультировать по внедрению LLM в мой продукт?



Консультации по внедрению проводит ЦК Диджитализации процессов
Можете обратиться к коллегам - <https://hub.mts.ru/my-team/?org-id=1930a9da-248e-4856-b68c-d51a870c970d>

7.1.12 Где посмотреть полезный контент по внедрению LLM?



Вы можете посмотреть записи мероприятий в которых мы рассказывали про работу с LLM на главной странице нашего раздела в Confluence [MWS GPT \(ex. LLMOps Platform\)](#) (see page 9)

7.1.13 Как понять, какая LLM локальная, а какая внешняя?



В <https://ui.llmops.mts-corp.ru/login> в селекторе моделей доступен признак "Внутренняя/Внешняя" у каждой модели
Добавить в API данный параметр не можем, потому что спецификация не будет соответствовать OpenAI и может нарушить интеграцию с уже готовыми сервисами и библиотеками

7.1.14 Как понять, какие LLM можно использовать с чувствительной информацией?



Модели с признаком "Внутренняя"
Они запускаются у нас на серверах и ваши данные никуда не уходят

7.1.15 У меня техническая проблема/нужна консультация



Создать заявку на консультацию, помощь или решение инцидента можно по шаблонам:

- [Консультации](#):²⁹
 - По работе с API;
 - По работе с UI;
 - По работе с No-code.
- [Инциденты](#):³⁰
 - Недоступность/некорректная работа платформы или элементов платформы.
- [Сервисные запросы](#):³¹
 - Вопросы по ключам;
 - Запрос на добавление модели;
 - Получение статистики по потреблению.

7.1.16 У меня ключ старого формата (ASGK), что делать?



У вас ключ в старом формате, вы скорее всего очень давно его получали
вам надо обменять его на новый формат

curl http://api.llmops.mts-corp.ru/_asgk_exchange -H "X-ASGK-TOKEN: <your asgk>"

7.1.17 У меня еще остались вопросы, где задать?



Заходите в наш чат в Telegram - <https://t.me/+0UQwJZCR7WozMDYy> (с 20 марта только для чтения)

Канал в MTS LINK Чаты - <https://my.mts-link.ru/r/7PReMU>

²⁹ <https://servicedesk.mts.ru/blueprints/7ce995fc-e920-4518-8053-f33e5ecd759b>

³⁰ <https://servicedesk.mts.ru/blueprints/9a26890c-a320-4bcc-acff-450fc9f1311d>

³¹ <https://servicedesk.mts.ru/blueprints/7eed53d4-7dbe-4ada-a27c-df46e1519eb0>

7.2 Как начать работу?



Важные моменты:

Данная инструкция подходит тем, кто решил интегрировать MWS GPT в свой продукт, если вы обычный пользователь, который хочет пользоваться чатом или devx плагином, перейдите пожалуйста в соответствующий раздел:

- Инструкция по работе с чатом - [3_1_Инструкция_по_установке_и_информацией_необходимой_для_эксплуатации.pdf](#)³²
- Инструкция по работе с DevX - <https://devx.mts-corp.ru/copilot>

7.2.1 Получение ключа

Итак, вы решили подключить MWS GPT к своему продукту, что нужно сделать в первую очередь? Правильно, получить API ключ



Важные моменты:

- API ключ выдается только для заведенных в <https://product.mts.ru/> продуктов, это особенности внутреннего биллинга потребления
- API ключ выдается раз в неделю по понедельникам
- API ключ в автоматическом режиме высылается на CPO, PO и Техлида продукта, которые указаны на портале <https://product.mts.ru/>
- На данный момент API ключ не высылается повторно, если по какой-то причине ключ вам не пришел, попросите CPO/PO/Техлида проверить почту, возможно ключ высылался ранее

³²https://confluence.mts.ru/download/attachments/2030507840/3_1_%D0%98%D0%BD%D1%81%D1%82%D1%80%D1%83%D0%BA%D1%86%D0%B8%D1%8F_%D0%BF%D0%BE_%D1%83%D1%81%D1%82%D0%B0%D0%BD%D0%BE%D0%B2%D0%BA%D0%B5_%D0%B8_%D0%B8%D0%BD%D1%84%D0%BE%D1%80%D0%BC%D0%B0%D1%86%D0%B8%D0%B5%D0%B8%CC%86%2C_%D0%BD%D0%B5%D0%BE%D0%B1%D1%85%D0%BE%D0%B4%D0%B8%D0%BC%D0%BE%D0%B8%CC%86_%D0%B4%D0%BB%D1%8F_%D1%8D%D0%BA%D1%81%D0%BF%D0%BB%D1%83%D0%B0%D1%82%D0%B0%D1%86%D0%B8%D0%B8.pdf?api=v2&modificationDate=1763118616058&version=1

7.2.1.1 Заполнение формы в MWS Tables

Для того, чтобы получить API ключ, вам нужно заполнить форму в MWS Tables: <https://tabs.mts.ru/share/shrp9ik1zQriP6geyDS3A/fom6GMTAQMFsm1jCPn>

7.2.1.2 Как заполнять поля в форме?

7.2.1.2.1 Ссылка на ваш продукт PPinfo

Поле заполняется ссылкой или кодом вашего продукта в <https://product.mts.ru/>

Ваш код продукта указан и в ссылке, и на странице




Предупреждаем:

Не нужно указывать в этом поле ничего, кроме кода продукта
Если вы напишете:

- "Блин, у меня нет продукта..."
- "Я не знаю код продукта"
- "А мы еще не завели продукт в product.mts.ru"

Или любой другой контент помимо кода продукта - ключ вам не придет, форма обрабатывается автоматически



7.2.1.2.2 E-mail, кому предоставить доступ

В этом поле указывайте ваш Email, оно нужно для того, чтобы отследить кто запрашивал API ключ



Важные моменты:

Ключ не придет на почту, которую вы указали, ключ приходит только на CPO, PO и Техлида указанных в <https://product.mts.ru/>

7.2.2 Настройка доступов на Firewall

Внутренняя инсталляция MWS GPT находится в контуре "Тайна связи" <https://servicedesk.mts.ru/applications/details/J00000001039826>

Это значит, что чтобы "достучаться" до платформы - вам нужно сделать заявку на доступы на <https://fw.mts.ru/>

7.2.2.1 Заявка на Firewall

Для того, чтобы заполнить заявку, вам нужно указать адреса "Source" (Источник) и "Destination" (Назначение)

Source адреса - ip адреса вашей системы

Destination адреса - ip адреса MWS GPT (11.61.64.1 - 11.61.64.254, порты: 80, 443)



Важные моменты:

11.61.64.1 - 11.61.64.254 - это не два адреса, а пул адресов

Запрашивайте доступ сразу на всю подсеть, потому что кластер MWS GPT со временем расширяется, а для обеспечения максимальной надежности - каждый хост в кластере является балансировщиком

Такой подход позволяет нам выдерживать аварии до 70% потери кластера

API всегда будет доступен по единому DNS имени <https://api.llmops.mts-corp.ru/>

Балансировка DNS управляется с помощью GSLB <https://ocean.mts.ru/docs/tutorial/api/dns#create-gslb-record>

7.2.2.1.1 Пример заявки на FW:

[Личный кабинет](#)
[Поиск](#)
[Истекающие доступы](#)

+
-

Снимаются ограничения по срокам действия доступов. Заявки на продление создавать не нужно.

Личный кабинет > Заявка № 17610331806836 > Правило №1

Источник

MTC-inside
NAT

11.217.89.10-11.217.89.30

Назначение

MTC-inside
NAT

11.61.64.1-11.61.64.30

Информация

Описание

Доступ до MWS GPT

Срок действия

бессрочно

Действие

Добавить

Протоколы/Порты

TCP[80(http),443(https)]

**Важные моменты:**

В случае возникновения проблем на FW:

- Заявка выполнена, но доступа нет
- Пропали доступы
- Не согласовывается заявка

И с прочими подобными вопросами, просьба обращаться к команде <https://fw.mts.ru/>
Информацию о fw.mts.ru можно прочитать тут - https://product.mts.ru/product/BI_2814/main
Команда MWS GPT не управляет этим сервисом и не может повлиять на проблемы с FW

7.2.3 Отправляем запросы в MWS GPT

MWS GPT поддерживает спецификацию OpenAI на 100%

Это значит, что у нас нет кастомных эндпоинтов или изменений в структуре, и вы можете отправлять запросы к нам по аналогии с OpenAI

7.2.3.1 Спецификация OpenAI API

Ознакомиться более детально со спецификацией OpenAI API вы можете здесь - <https://platform.openai.com/docs/api-reference/introduction> (потребуется VPN)

Так же вы можете ознакомиться со спецификацией здесь - <https://github.com/openai/openai-openapi>

7.2.3.2 Postman коллекция

Так же вы можете использовать уже готовую коллекцию OpenAI API - <https://www.postman.com/devrel/openai/documentation/k25n3c8/openai-api>

7.2.3.3 Библиотеки для интеграции

Вы можете использовать официальные библиотеки OpenAI для реализации вызовов через MWS GPT

Язык программирования	Библиотека
Golang	https://github.com/openai/openai-go
.NET	https://github.com/openai/openai-dotnet
Java	https://github.com/openai/openai-java

Язык программирования	Библиотека
Ruby	https://github.com/openai/openai-ruby
NodeJS	https://github.com/openai/openai-node
Python	https://github.com/openai/openai-python

7.2.3.4 Интеграция с 3rd-party сервисами и библиотеками

MWS GPT поддерживает интеграцию с сторонними сервисами и библиотеками, к примеру - OpenSearch или Langchain



Важные моменты:

Для более конкретной информации по интеграции LLM с 3rd-party сервисами, просим ознакомиться с документацией сервисов

Ключевой момент для интеграции:

Не забудьте переопределить endpoint для вызова API

\$OPENAI_API_BASE - <https://api.llmops.mts-corp.ru/v1/>

\$OPENAI_API_KEY - sk-... (ваш ключ, который вы получили ранее)



Важные моменты:

Многие системы по дефолту для OpenAI спецификации используют эндпоинт OpenAI Библиотека OpenAI которую наследуют большинство сервисов позволяет переопределить эндпоинт, это делается через указание переменной окружения \$OPENAI_API_BASE или через явную передачу параметра OPENAI_API_BASE через класс OpenAIClient

7.2.4 Я все сделал, но у меня еще остались вопросы

Ознакомьтесь с [FAQ \(see page 167\)](#) или

Заходите в наш чат в Telegram - <https://t.me/+0UQwJZCR7WozMDYy> (только для чтения с 20 марта)

Канал в MTS LINK ЧАТЫ - <https://my.mts-link.ru/r/7PReMU>

7.3 Модели и Бенчмарки

Доступные модели на платформе

МОДЕЛЬ	МОДАЛЬНОСТЬ	Внутренняя	AVG OUT TPS	Deprecation date	EOL date	Входные токены, 1000 шт., без НДС	Входные токены, 1000 шт., без НДС
bge-m3	embeddings	✓	-	-	-	0,01 ₽	0,01 ₽
claude-3-5-haiku	text-to-text	✗	-	-	19.02.26	0,16 ₽	0,80 ₽
claude-3-5-sonnet	text-to-text	✗	-	-	28.10.25	0,60 ₽	3,00 ₽
claude-3-7-sonnet	text-to-text	✗	-	-	19.02.26	0,60 ₽	3,00 ₽
claude-3-haiku	text-to-text	✗	-	19.02.26	19.04.26	0,05 ₽	0,25 ₽
claude-4-5-haiku-20251001	image-text-to-text	✗	-	-	-	0,20 ₽	1,00 ₽
claude-4-5-opus	image-text-to-text	✗	-	-	-	1,00 ₽	5,00 ₽
claude-4-6-opus	image-text-to-text	✗	-	-	-	2,00 ₽	7,50 ₽
claude-4-opus	text-to-text	✗	-	-	-	3,00 ₽	15,00 ₽
claude-4-sonnet	text-to-text	✗	-	-	-	0,60 ₽	3,00 ₽
cotype-plus-32k	text-to-text	✓	-	14.01.26	14.02.26	н/д	н/д

cotype-pro	text-to-text	✓	-	14.01.26	14.02.26	н/д	н/д
cotype-pro-2.5	text-to-text	✓	1024.00 tok/s	-	-	н/д	н/д
cotype-pro-2_128k_030325	text-to-text	✓	-	14.01.26	14.02.26	н/д	н/д
cotype-pro-vl-32b	image-text-to-text	✓	448.00 tok/s	-		н/д	н/д
deepseek-chat	text-to-text	✗	-	-	-	0,05 ₽	0,22 ₽
deepseek-coder	text-to-text	✓	2742.00 tok/s	-	-	н/д	н/д
deepseek-r1-distill-qwen-14b	text-to-text	✓	1995.00 tok/s	-	-	0,90 ₽	0,90 ₽
deepseek-reasoner	text-to-text	✗	-	-	-	0,11 ₽	0,44 ₽
devstral-small	text-to-text	✓	1614.00 tok/s	-	-	0,70 ₽	0,70 ₽
glm-4.6-357b	text-to-text	✓	1792.00 tok/s	-	-	1,90 ₽	1,90 ₽
gpt-3.5-turbo	text-to-text	✗	-	-	28.09.26	0,60 ₽	1,20 ₽
gpt-4	text-to-text	✗	-	-	28.09.26	6,00 ₽	12,00 ₽
gpt-4-turbo	text-to-text	✗	-	-	28.09.26	2,00 ₽	6,00 ₽
gpt-4o	image-text-to-text	✗	-	-	-	0,50 ₽	2,00 ₽
gpt-4o-mini	image-text-to-text	✗	-	-	-	0,03 ₽	0,12 ₽
gpt-5	image-text-to-text	✗	-	-	-	0,25 ₽	2,00 ₽

gpt-5-mini	image-text-to-text	✗	-	-	-	0,05 ₺	0,40 ₺
gpt-5-nano	image-text-to-text	✗	-	-	-	0,01 ₺	0,08 ₺
gpt-5.1	image-text-to-text	✗	-	-	-	0,25 ₺	2,00 ₺
gpt-5.2	image-text-to-text	✗	-	-	-	0,35 ₺	2,80 ₺
gpt-o1	-	✗	-	-	28.07.25	3,00 ₺	12,00 ₺
gpt-o3-mini	text-to-text	✗	-	-	-	0,22 ₺	0,88 ₺
gpt-oss-120b	text-to-text	✓	2721.00 tok/s	-	-	0,75 ₺	0,75 ₺
gpt-oss-20b	text-to-text	✓	3858.00 tok/s	-	-	0,55 ₺	0,55 ₺
grok-4	image-text-to-text	✗	-	-	-	0,60 ₺	3,00 ₺
grok-4-1-fast-non-reasoning	image-text-to-text	✗	-	-	-	0,04 ₺	0,10 ₺
grok-4-1-fast-reasoning	image-text-to-text	✗	-	-	-	0,04 ₺	0,10 ₺
kimi-k2-instruct	text-to-text	✓	1318.00 tok/s	-	-	3,00 ₺	3,00 ₺
kodify-1.0	text-to-text	✓	-	14.02.26	14.02.26	н/д	н/д
kodify-2.0	text-to-text	✓	-	14.02.26	14.02.26	0,40 ₺	0,40 ₺
mts-anya	text-to-text	✓	1376.00 tok/s	-	-	0,92 ₺	0,92 ₺
qwen-coder-7b	text-to-text	✓	3328.00 tok/s	-	-	н/д	н/д

qwen-image	text-to-image	✓	-	-	-	н/д	н/д
qwen-max	text-to-text	✗	-	-	-	н/д	н/д
qwen-plus	text-to-text	✗	-	-	-	н/д	н/д
qwen-turbo	text-to-text	✗	-	-	-	н/д	н/д
qwen2.5-vl-32b-instruct-awq	image-text-to-text	✓	-	-	-	0,85 ₽	0,85 ₽
qwen2.5-vl-7b-instruct	image-text-to-text	✓	-	-	-	2,35 ₽	2,35 ₽
qwen3-235b-a22b-instruct	text-to-text	✓	2728.99 tok/s	-	-	1,00 ₽	1,00 ₽
qwen3-coder-480b-a35b	text-to-text	✓	8315.00 tok/s	-	-	1,70 ₽	1,70 ₽
qwen3-coder-next	text-to-text	✓	soon	-	-		
qwen3.5-35b-a3b	image-text-to-text	✓	soon	-	-		
Qwen3.5-397B-A17B-FP8	image-text-to-text	✓	soon	-	-		
sd3.5-large-image	text-to-image	✓	-	-	-	н/д	н/д
sdxl-lightning-image	text-to-image	✓	-	-	-	н/д	н/д
whisper-medium-local-preview	audio-to-text	✓	-	-	-	н/д	н/д
whisper-turbo-local-preview	audio-to-text	✓	-	-	-	н/д	н/д
z-image-turbo	text-to-image	✓	-	-	-	н/д	н/д

7.4 Чек-лист технологической зрелости MWS GPT

Документирование Продукта/Платформы	Комментарий, пояснения
☐ Наличие документированной архитектуры – HLD	HLD готов для обоих контуров: 1. MWS 2. Inside
☐ Документация на систему	Draft документации готов.
☐ Руководство пользователя (клиента)	Тот же самый draft фактически.
☐ Руководство администратора	Отсутствует
Готовность основных технологических ресурсов эксплуатации	
☐ Наличие тестовых стендов	Отсутствует, но есть в планах.
☐ Резервное копирование	Есть, но не в полном объеме. Есть: 1. Биллинг 2. Базы данных Нет: 1. MongoDB 2. Верификации бекапов
☐ Мониторинг	Есть, но не в полном объеме. Сейчас в работе.
☐ Интеграция системы мониторинга с платформой наблюдаемости	Отсутствует, но есть в планах.
☐ Интеграция системы мониторинга с ITSM-системой	Отсутствует, но есть в планах.
Готовность основных технологических процессов эксплуатации	

☐ Подтверждённая готовность работать в соответствии со стандартными процессами MWS	Есть, но не до конца есть понимание данных стандартов.
☐ Управление инцидентами	Нет.
☐ Управление изменениями	Нет
☐ Управление проблемами	Нет
DRP/DRT?	Нет. Можем составить.
Порядок предоставления доступов	Есть, но не финальная версия.
Техническая поддержка	
L1	
☐ Персонал нанят, обучен, информирован, функцию принял.	Нет
☐ Выполнены настройки в S1 (группы, роли, SLA)	Нет
☐ Каналы подачи обращений от клиента созданы (при их отличии от стандартных)?	Нет
L2	
☐ Персонал нанят, обучен, информирован, функцию принял.	Да
☐ Группы в S1 созданы	Нет
L3	как организована? Готовы? Средства и правила коммуникации готовы?
☐ При участии партнёра/вендора в линиях поддержки и/или в технологической цепочке – наличие договора и SLA	SLA команды L3 – в рабочее время команды (Business Support). SLA есть.

☐ Модель здоровья (доступность)	Общедоступной нет. Внутренние Dashboards по сервисам есть.
Проверки ИБ пройдены	Да

01.Чек-лист документации при передаче ИТ-продукта на техническую поддержку - Техническая поддержка #CloudMTS - Confluence³³

³³ <https://confluence.mts.ru/pages/viewpage.action?pageId=602011574>